Der Daten-Lifecycle

Session 1: Data Science - Ein Überblick

Simon Munzert
Hertie School

Überblick

1. Willkommen!
2. Was ist Data Science?
3. Was kann Data Science in der Verwaltung – und was nicht?
4. Ziele für dieses Modul

Herzlich Willkommen!

Vorstellungsrunde

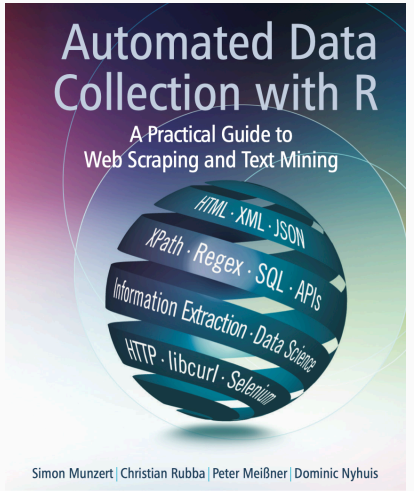
Hertie School

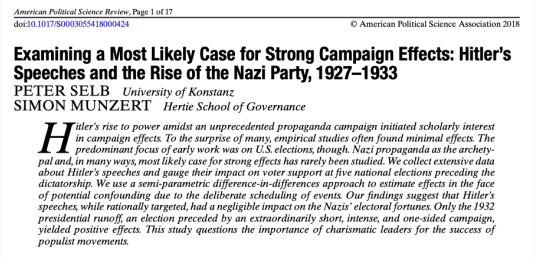
Über mich

Ich bin Simon Munzert [si'mən munsɜrt], oder Simon [saɪmən].

munzert@hertie-school.org

Professor für Data Science und Public Policy | Director, Data Science Lab



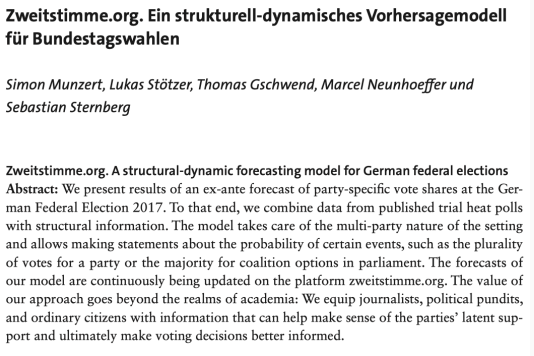


American Political Science Review, Page 1 of 17
doi:10.1017/S0003055418000424 © American Political Science Association 2018

Examining a Most Likely Case for Strong Campaign Effects: Hitler's Speeches and the Rise of the Nazi Party, 1927–1933

PETER SELB *University of Konstanz*
SIMON MUNZERT *Hertie School of Governance*

Hitler's rise to power amidst an unprecedented propaganda campaign initiated scholarly interest in campaign effects. To the surprise of many, empirical studies often found minimal effects. The predominant focus of early work was on U.S. elections, though. Nazi propaganda as the archetypal and, in many ways, most likely case for strong effects has rarely been studied. We collect extensive data about Hitler's speeches and gauge their impact on voter support at five national elections preceding the dictatorship. We use a semi-parametric difference-in-differences approach to estimate effects in the face of potential confounding due to the deliberate scheduling of events. Our findings suggest that Hitler's speeches, while rationally targeted, had a negligible impact on the Nazis' electoral fortunes. Only the 1932 presidential runoff, an election preceded by an extraordinarily short, intense, and one-sided campaign, yielded positive effects. This study questions the importance of charismatic leaders for the success of populist movements.

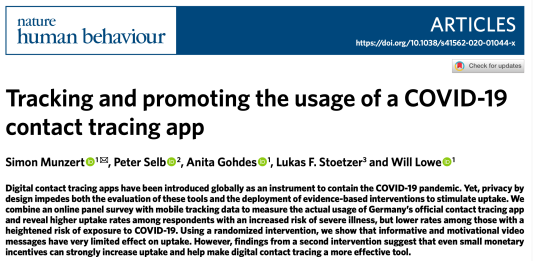


Zweitstimme.org. Ein strukturell-dynamisches Vorhersagemodell für Bundestagswahlen

Simon Munzert, Lukas Stötzer, Thomas Gschwend, Marcel Neunhoeffer und Sebastian Sternberg

Zweitstimme.org. A structural-dynamic forecasting model for German federal elections

Abstract: We present results of an ex-ante forecast of party-specific vote shares at the German Federal Election 2017. To that end, we combine data from published trial heat polls with structural information. The model takes care of the multi-party nature of the setting and allows making statements about the probability of certain events, such as the plurality of votes for a party or the majority for coalition options in parliament. The forecasts of our model are continuously being updated on the platform zweitstimme.org. The value of our approach goes beyond the realms of academia: We equip journalists, political pundits, and ordinary citizens with information that can help make sense of the parties' latent support and ultimately make voting decisions better informed.



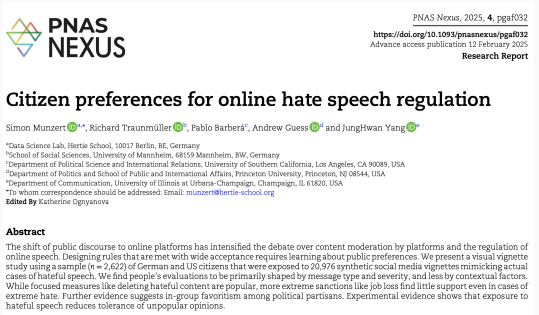
nature human behaviour ARTICLES https://doi.org/10.1038/s41562-020-01044-x

Check for updates

Tracking and promoting the usage of a COVID-19 contact tracing app

Simon Munzert[1,2], Peter Selb[2], Anita Gohdes[1], Lukas F. Stoetzer[3] and Will Lowe[1]

Digital contact tracing apps have been introduced globally as an instrument to contain the COVID-19 pandemic. Yet, privacy by design impedes both the evaluation of these tools and the deployment of evidence-based interventions to stimulate uptake. We combine an online panel survey with mobile tracking data to measure the actual usage of Germany's official contact tracing app and reveal higher uptake rates among respondents with an increased risk of severe illness, but lower rates among those with a heightened risk of exposure to COVID-19. Using a randomized intervention, we show that informative and motivational video messages have very limited effect on uptake. However, findings from a second intervention suggest that even small monetary incentives can strongly increase uptake and help make digital contact tracing a more effective tool.



PNAS NEXUS

PNAS Nexus, 2025, 4, pgaf032
https://doi.org/10.1093/pnasnexus/pgaf032
Advance access publication 12 February 2025
Research Report

Citizen preferences for online hate speech regulation

Simon Munzert[a,*], Richard Traunmüller[b], Pablo Barberá[c], Andrew Guess[d] and JungHwan Yang[e]

[a]Data Science Lab, Hertie School, 10017 Berlin, BE, Germany
[b]School of Social Sciences, University of Mannheim, 68159 Mannheim, BW, Germany
[c]Department of Political Science and International Relations, University of Southern California, Los Angeles, CA 90089, USA
[d]Department of Politics and School of Public and International Affairs, Princeton University, Princeton, NJ 08544, USA
[e]Department of Communication, University of Illinois at Urbana-Champaign, Champaign, IL 61820, USA
*To whom correspondence should be addressed: Email: munzert@hertie-school.org
Edited By Katherine Ognyanova

Abstract

The shift of public discourse to online platforms has intensified the debate over content moderation by platforms and the regulation of online speech. Designing rules that are met with wide acceptance requires learning about public preferences. We present a visual vignette study using a sample (n = 2,622) of German and US citizens that were exposed to 20,976 synthetic social media vignettes mimicking actual cases of hateful speech. We find people's evaluations to be primarily shaped by message type and severity, and less by contextual factors. While focused measures like deleting hateful content are popular, more extreme sanctions like job loss find little support even in cases of extreme hate. Further evidence suggests in-group favoritism among political partisans. Experimental evidence shows that exposure to hateful speech reduces tolerance of unpopular opinions.

Vorstellungsrunde

Über Euch

📇 Euer Name

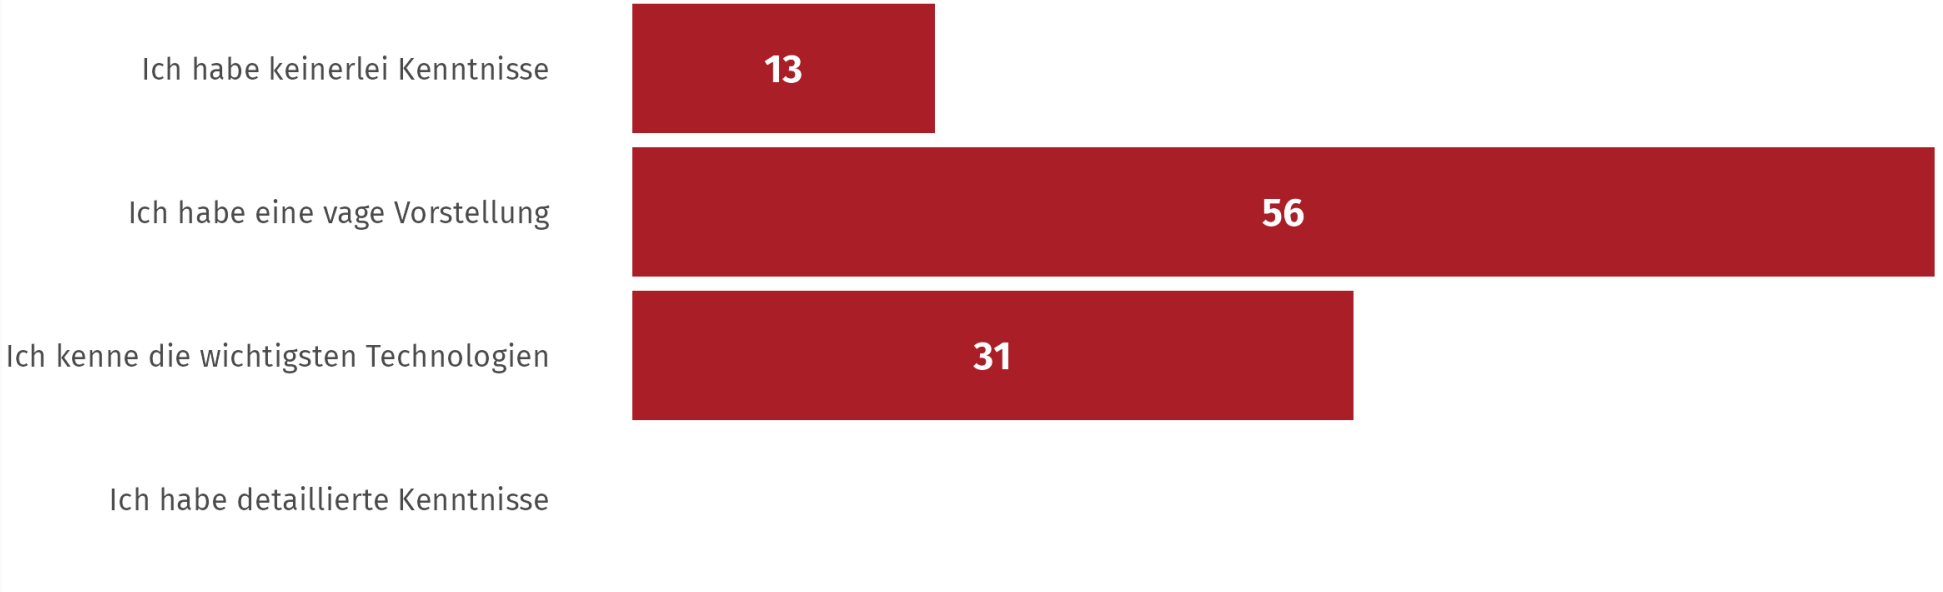
📨 Eure Behörde und Rolle

🎓 Was erhofft Ihr Euch vom Modul? Maximal 3 Wörter!



Wie gut kennt Ihr den technischen Stack Eurer Behörde?

*% der Teilnehmer*innen (n = 16). Infrastruktur, Cloud, Systeme, Software*

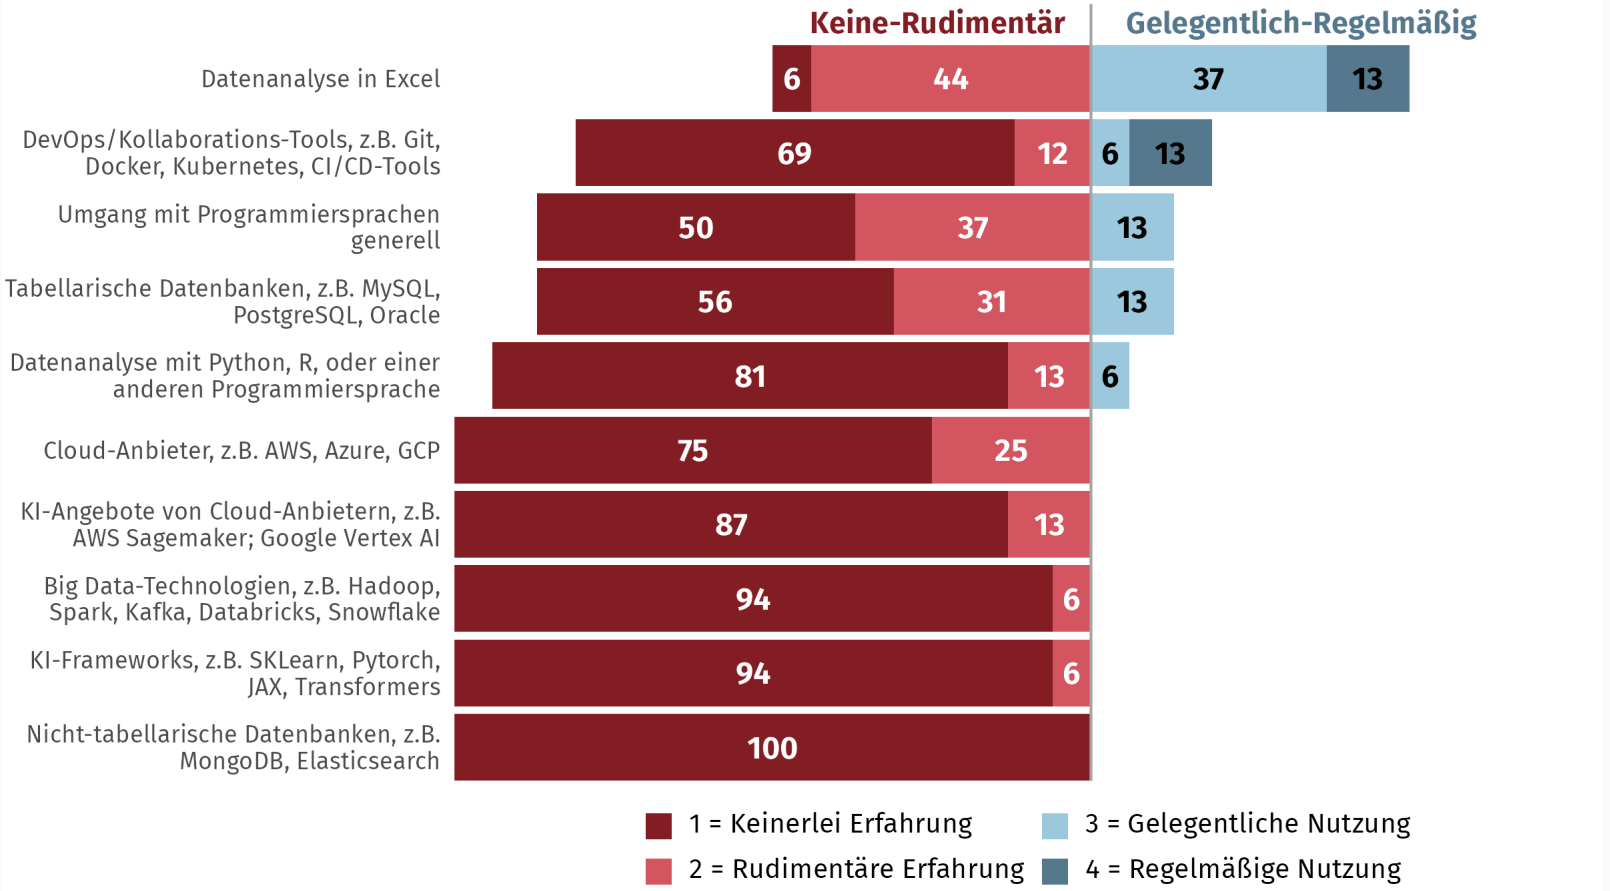


Onboarding-Befragung

Hertie School

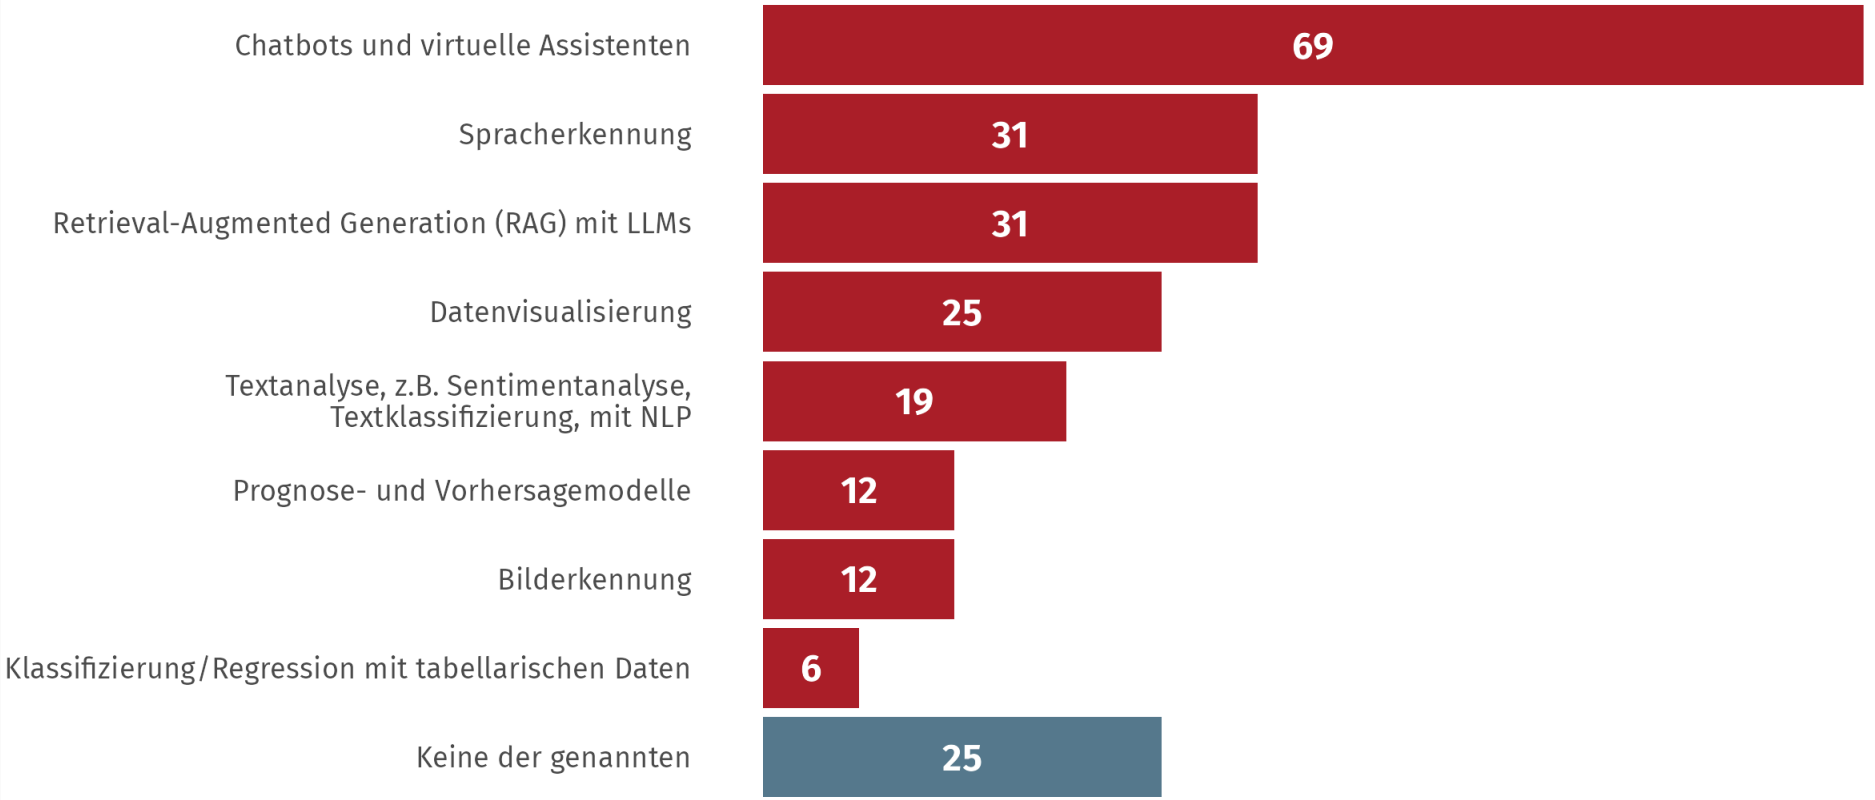
Erfahrungen mit Daten- und KI-Technologien

*% der Teilnehmer*innen (n = 16)*



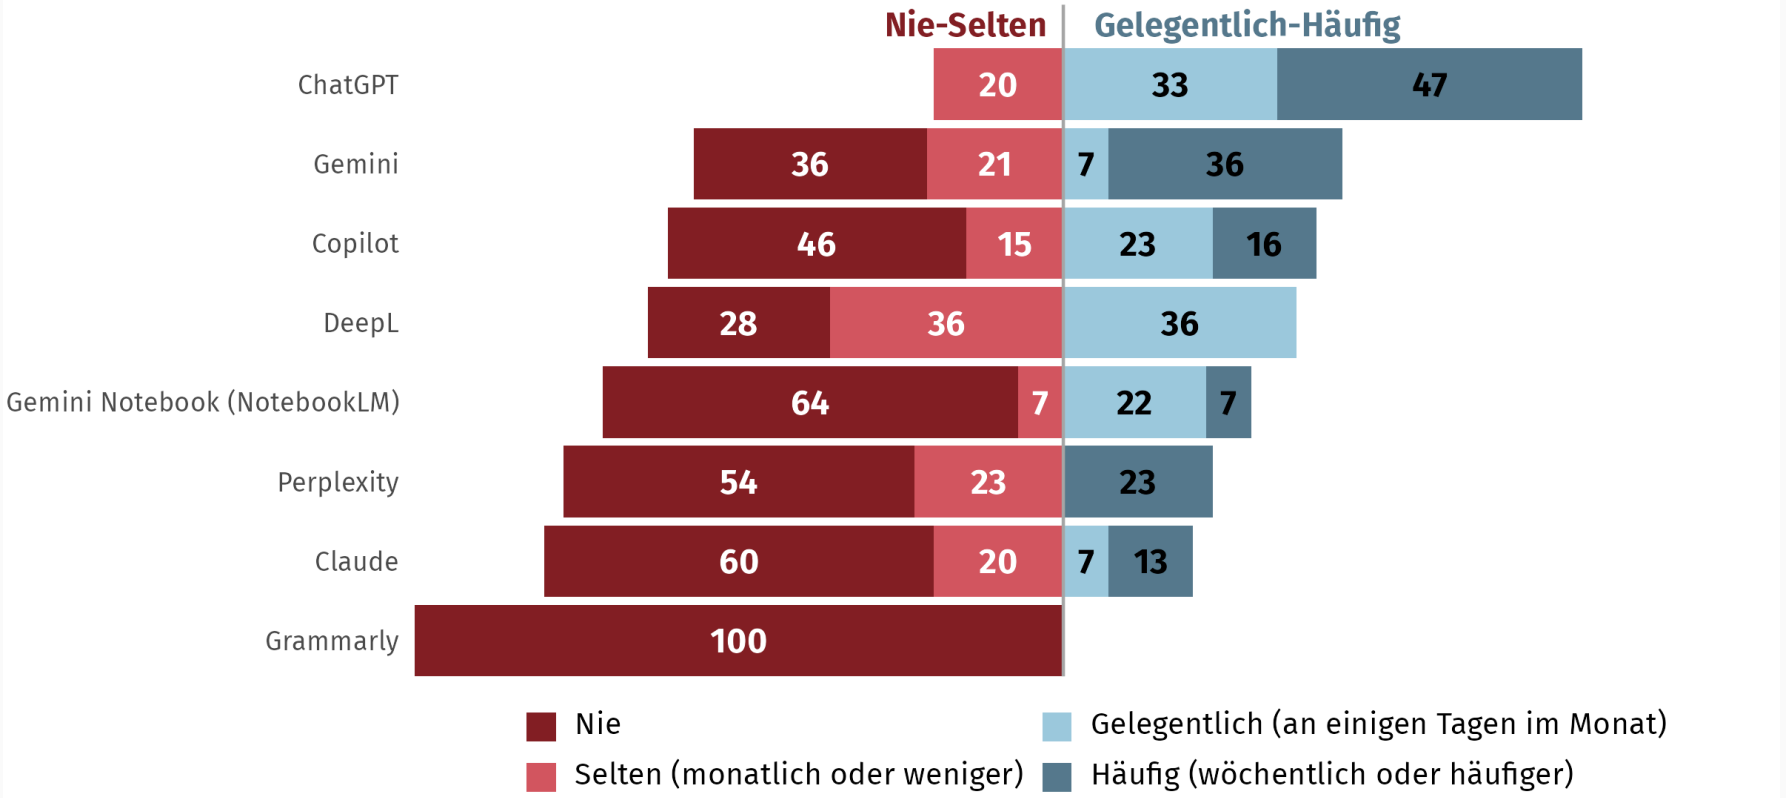
Bereits im Projekt umgesetzte KI- und Datenanalyseverfahren

*% der Teilnehmer*innen, Mehrfachnennung (n = 16)*



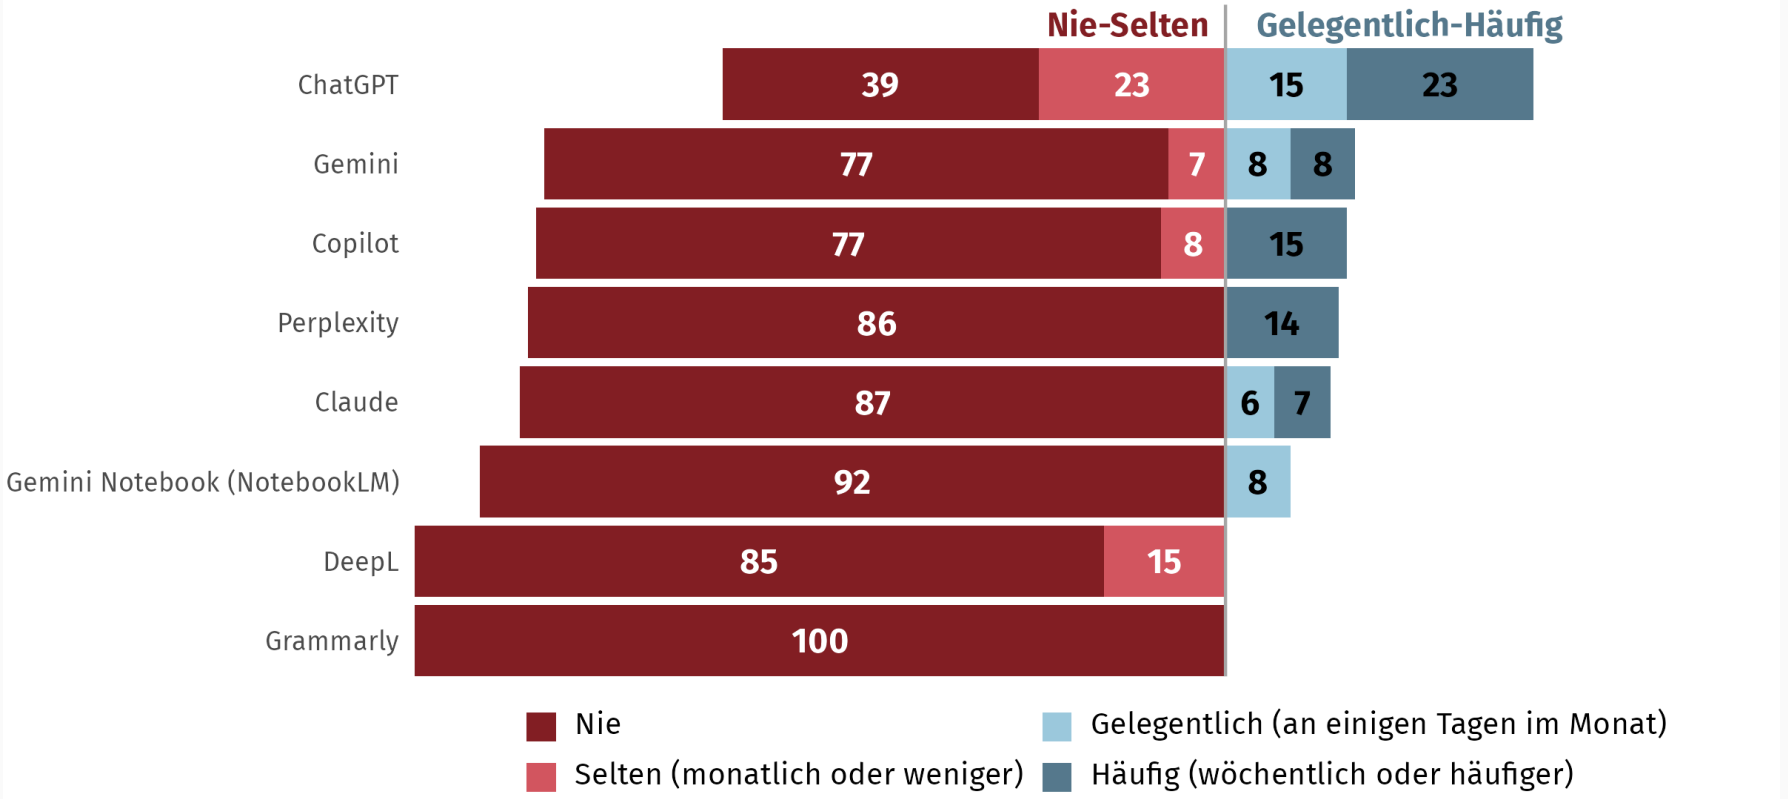
Nutzung von KI-Tools: privat

*% der Teilnehmer*innen (n = 16)*
Außerdem genannt: in Browser integrierte KI, Ollama, Hermes Agent (mit Deepseek), Meta AI



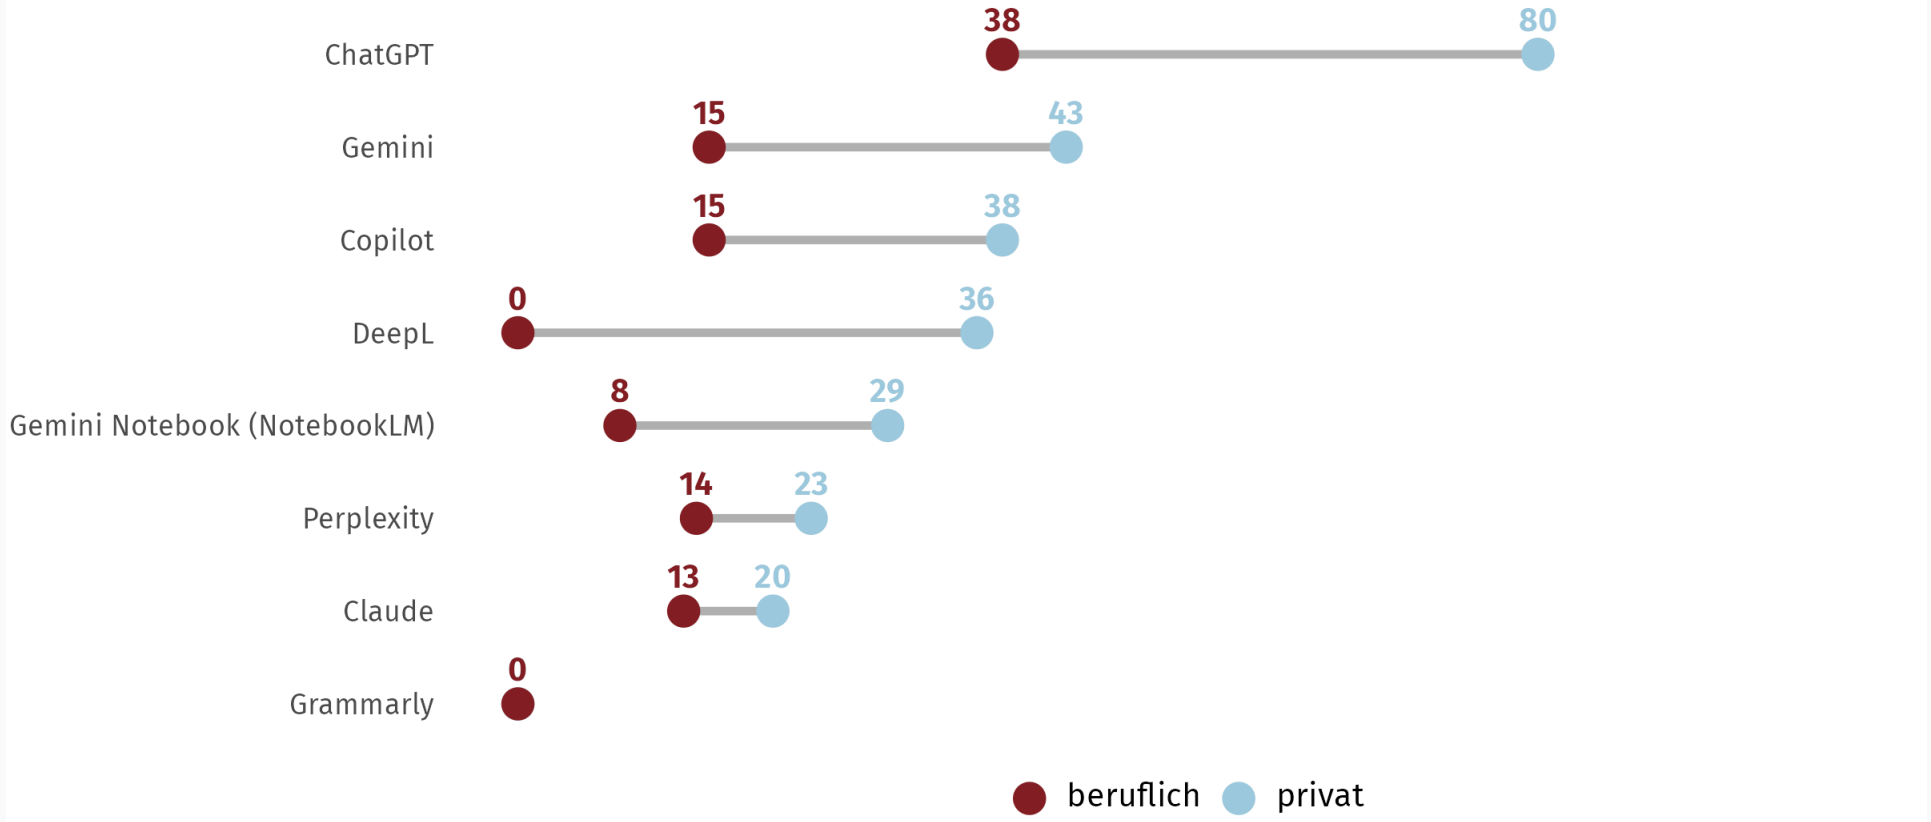
Nutzung von KI-Tools: beruflich

*% der Teilnehmer*innen (n = 16)*
Außerdem genannt: LLMoin, KIPITZ, Stadtinternes KI-Tool, Nele ai, LeoGPT (Verwaltungseigene Lösung), interner Chatbot



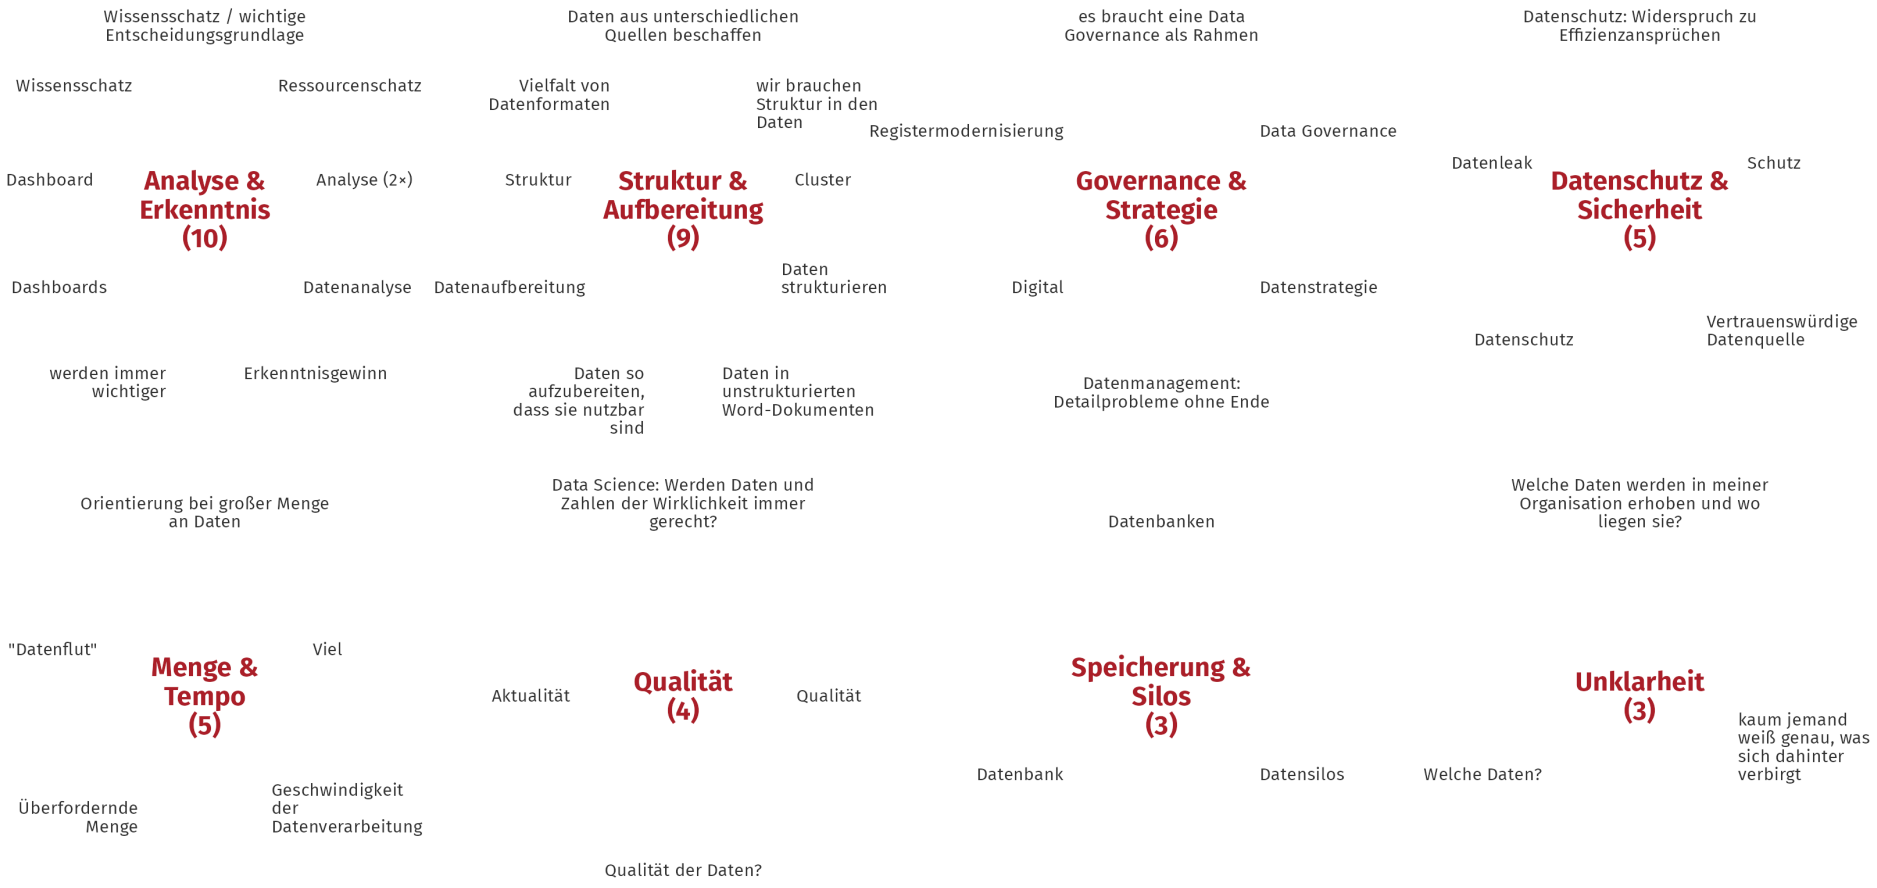
Gelegentliche oder häufige Nutzung: privat vs. beruflich

% der Antwortenden, die das Tool mindestens an einigen Tagen im Monat nutzen



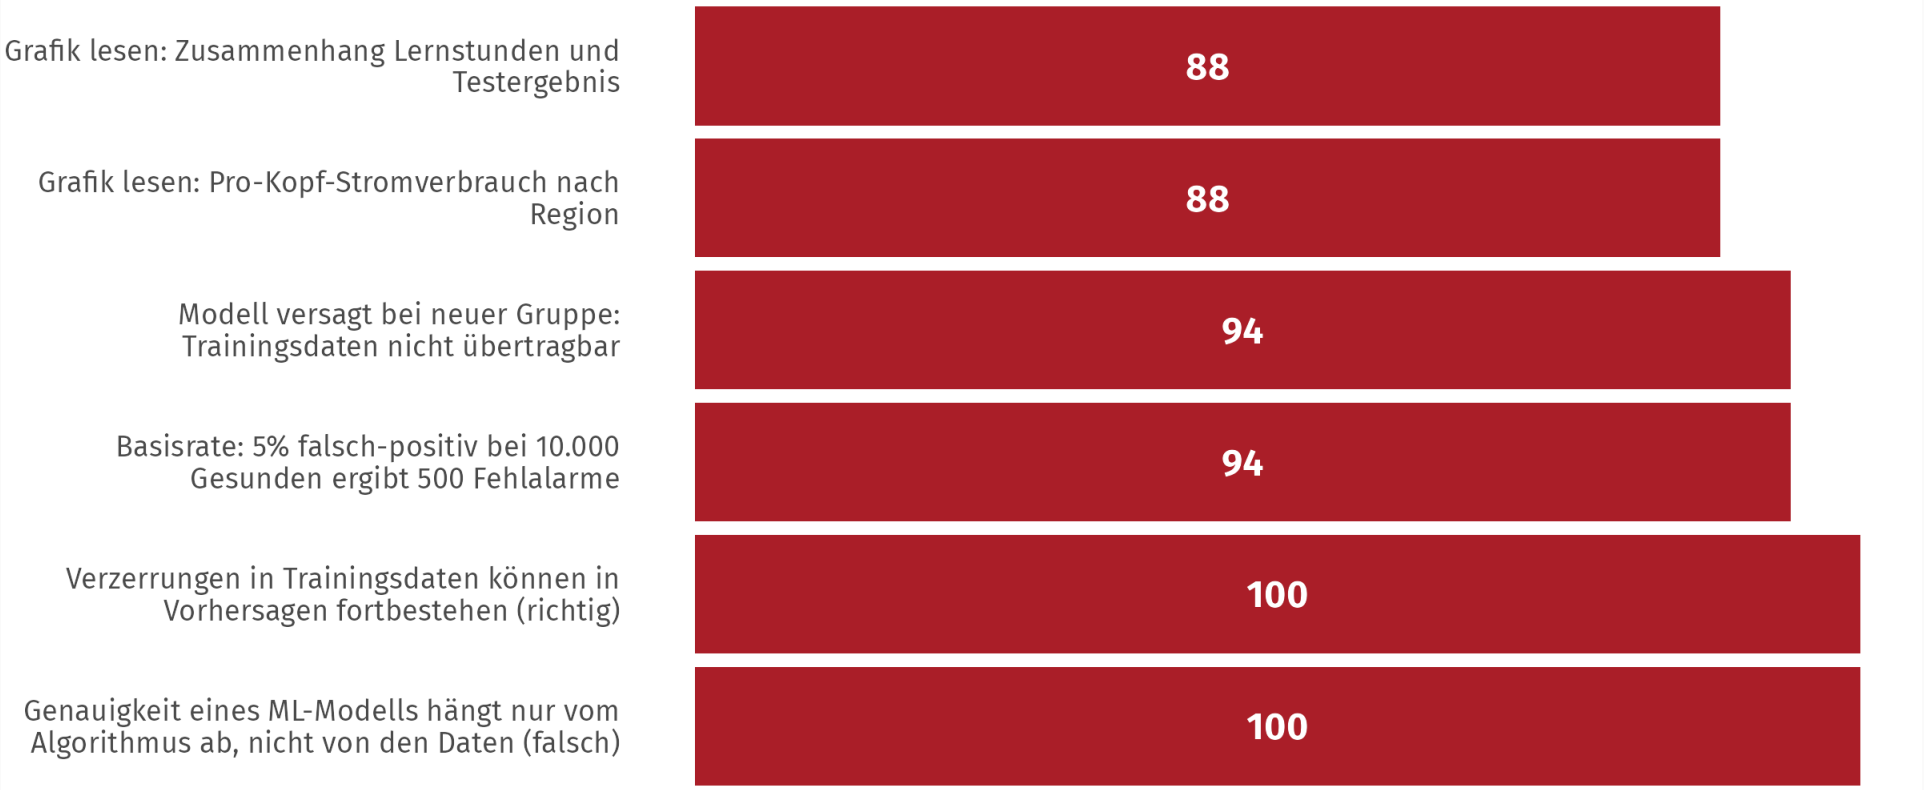
Was Euch zu „Daten“ und „Data Science“ einfällt

45 Nennungen von 16 Personen (je bis zu drei), zu acht Themen gruppiert; in Klammern: Anzahl Nennungen



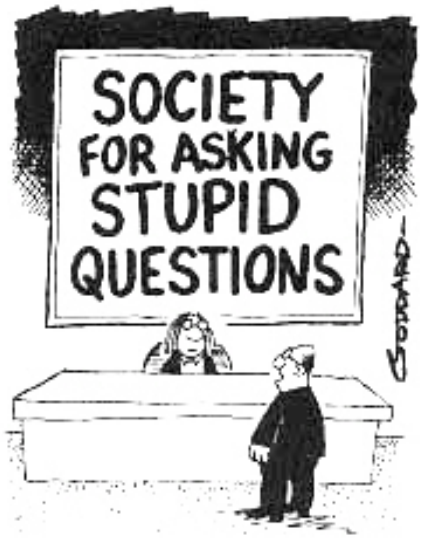
Wissensquiz: Anteil richtiger Antworten

*% der Teilnehmer*innen (n = 16)*



Workshop-Etikette

- Wir haben viele Themen vor uns. Ich habe Material vorbereitet, aber entscheidend ist: **Signalisiert Eure Interessen und Bedarfe** – ich vertiefe gerne, schwenke um oder greife andere Beispiele auf, soweit möglich.
- Ich bin kein Experte für Eure Behörde oder Eure spezifischen Themen. **Bringt Euer Fachwissen und Eure Erfahrung ein.** Sie bilden die Grundlage für eine fundierte, evidenzbasierte Diskussion über Data Science im öffentlichen Sektor.
- Bitte nutzt die Gelegenheit, **jederzeit Fragen zu stellen**. Es gibt keine schlechten Fragen – jede trägt zur gemeinsamen Diskussion bei.



"Excuse me, but is this The Society for Asking Stupid Questions?"

Kursmaterialien

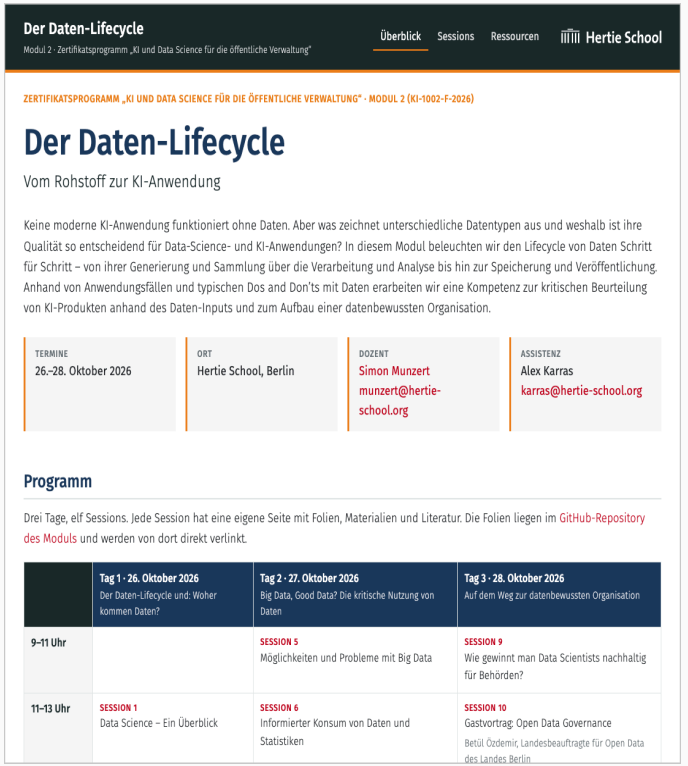
Hertie School

Alle Materialien dieses Moduls stehen offen im Netz, unabhängig von Moodle:

simonmunzert.com/zertifikat-daten

- **Folien** aller Sessions, als HTML und PDF
- **Code, Daten und Fallstudien** der beiden Praxis-Sessions
- **Literatur, Podcasts und Links** zu jeder Session

Die Seite bleibt bestehen. Ihr könnt also auch dann noch darauf zugreifen, wenn Ihr nach dem Zertifikat keinen Moodle-Zugang mehr habt.



Diskussion

Was möchtet Ihr über Daten und Data Science lernen?

Was sind Eure Erwartungen an dieses Modul?

Excalidraw - excalidraw.com

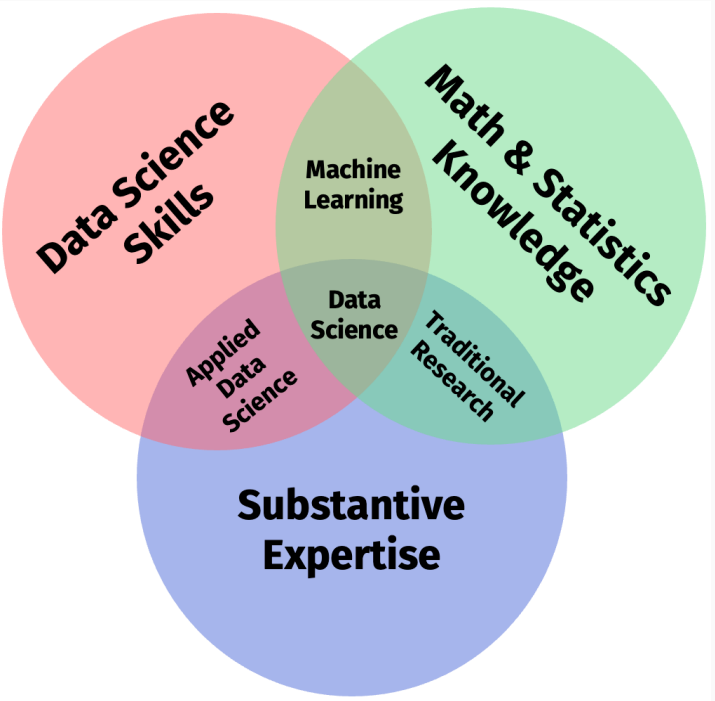
Was ist Data Science?

Was ist Data Science?

> "Der interdisziplinäre Forschungszweig Data Science befasst sich mit dem Management und der Analyse von Daten." - Daniel Keim, Kai-Uwe Sattler
>
> "Data Science ist ein interdisziplinäres Wissenschaftsfeld, welches wissenschaftlich fundierte Methoden, Prozesse, Algorithmen und Systeme zur Extraktion von Erkenntnissen, Mustern und Schlüssen sowohl aus strukturierten als auch unstrukturierten Daten ermöglicht." - Wikipedia
>
> "Data Science ist ein Konzept, das Statistik, Datenanalyse, Informatik und die damit verbundenen Methoden vereint, um aktuelle Phänomene anhand von Daten zu verstehen und zu analysieren." - Chikio Hayashi

✎ **Zwischen Disziplinen** angesiedelt, anwendungsorientiert

Eine visuelle Definition



`Quelle` Drew Conway, 2010 (angepasst)

Die Data-Science-Pipeline

Vorbereitung

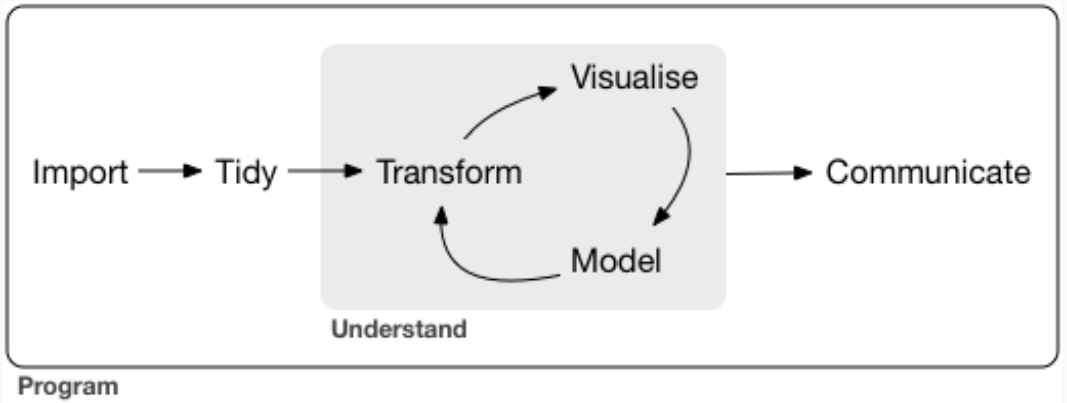
- **Problemstellung** Vorhersage, Inferenz, Beschreibung
- **Design** Konzept erstellen, Datenerfassung aufsetzen
- **Datenerhebung** rekrutieren, sammeln, überwachen

Die Data-Science-Pipeline

Vorbereitung

- **Problemstellung** Vorhersage, Inferenz, Beschreibung
- **Design** Konzept erstellen, Datenerfassung aufsetzen
- **Datenerhebung** rekrutieren, sammeln, überwachen

Datenverarbeitung



`Quelle` H. Wickham, M. Çetinkaya-Rundel, G. Gronemund: R for Data Science

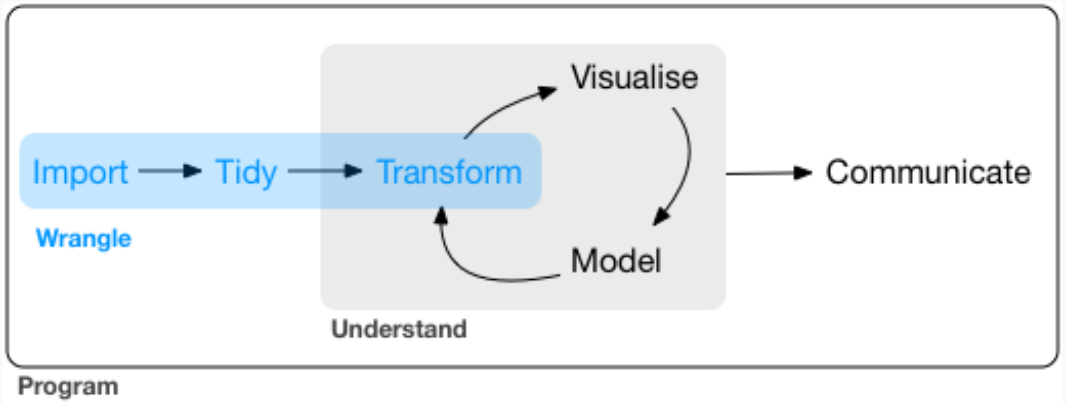
Die Data-Science-Pipeline

Vorbereitung

- **Problemstellung** Vorhersage, Inferenz, Beschreibung
- **Design** Konzept erstellen, Datenerfassung aufsetzen
- **Datenerhebung** rekrutieren, sammeln, überwachen

Datenverarbeitung

- **Aufbereiten**: importieren, bereinigen, anreichern



`Quelle` H. Wickham, M. Çetinkaya-Rundel, G. Gronemund: R for Data Science

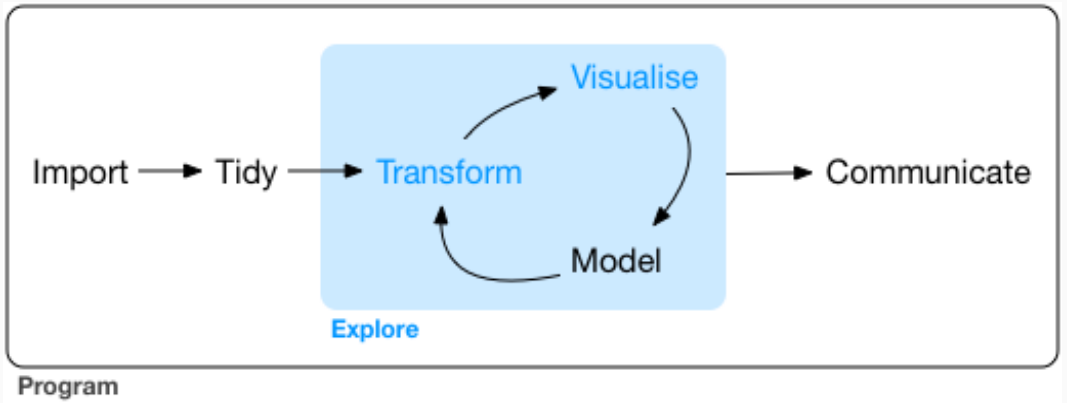
Die Data-Science-Pipeline

Vorbereitung

- **Problemstellung** Vorhersage, Inferenz, Beschreibung
- **Design** Konzept erstellen, Datenerfassung aufsetzen
- **Datenerhebung** rekrutieren, sammeln, überwachen

Datenverarbeitung

- **Aufbereiten**: importieren, bereinigen, anreichern
- **Explorieren**: visualisieren, beschreiben, entdecken



`Quelle` H. Wickham, M. Çetinkaya-Rundel, G. Gronemund: R for Data Science

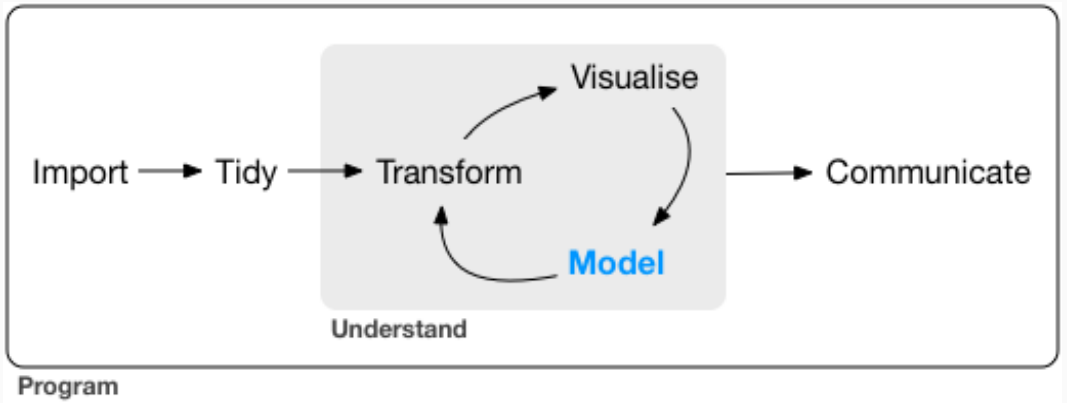
Die Data-Science-Pipeline

Vorbereitung

- **Problemstellung** Vorhersage, Inferenz, Beschreibung
- **Design** Konzept erstellen, Datenerfassung aufsetzen
- **Datenerhebung** rekrutieren, sammeln, überwachen

Datenverarbeitung

- **Aufbereiten**: importieren, bereinigen, anreichern
- **Explorieren**: visualisieren, beschreiben, entdecken
- **Modellieren**: testen, inferieren, vorhersagen



`Quelle` H. Wickham, M. Çetinkaya-Rundel, G. Gronemund: R for Data Science

Die Data-Science-Pipeline

Vorbereitung

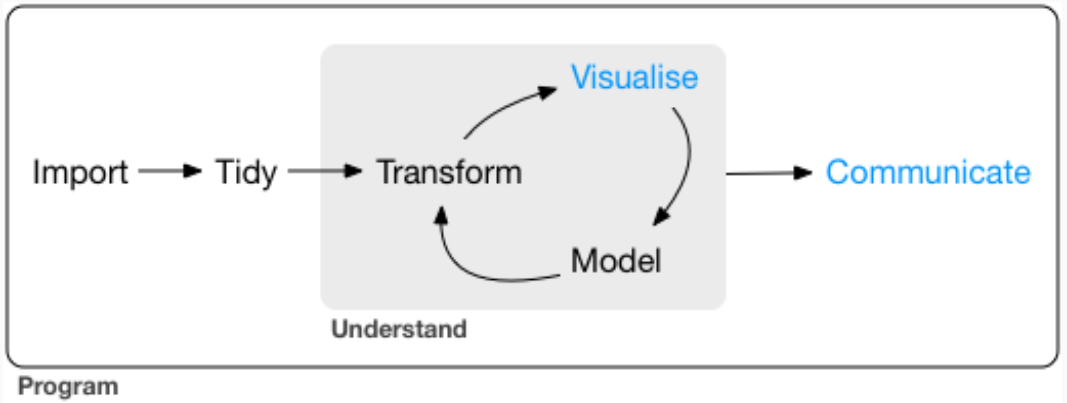
- **Problemstellung** Vorhersage, Inferenz, Beschreibung
- **Design** Konzept erstellen, Datenerfassung aufsetzen
- **Datenerhebung** rekrutieren, sammeln, überwachen

Datenverarbeitung

- **Aufbereiten**: importieren, bereinigen, anreichern
- **Explorieren**: visualisieren, beschreiben, entdecken
- **Modellieren**: testen, inferieren, vorhersagen

Verbreitung

- **Kommunikation**: Öffentlichkeit, Entscheidungsträger
- **Veröffentlichen**: Zeitschriften, Software, Berichte
- **Produktivieren**: nutzbar, robust, skalierbar machen



`Quelle` H. Wickham, M. Çetinkaya-Rundel, G. Gronemund: R for Data Science

Die Data-Science-Pipeline

Vorbereitung

- **Problemstellung** Vorhersage, Inferenz, Beschreibung
- **Design** Konzept erstellen, Datenerfassung aufsetzen
- **Datenerhebung** rekrutieren, sammeln, überwachen

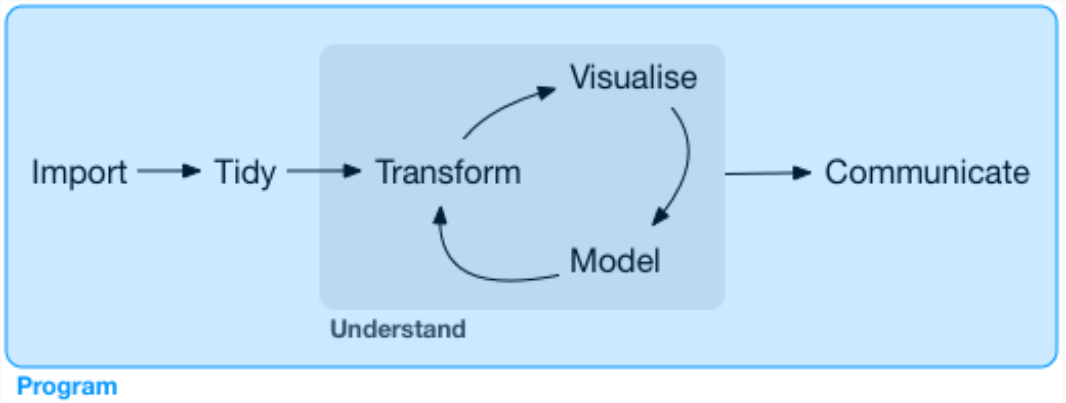
Datenverarbeitung

- **Aufbereiten**: importieren, bereinigen, anreichern
- **Explorieren**: visualisieren, beschreiben, entdecken
- **Modellieren**: testen, inferieren, vorhersagen

Verbreitung

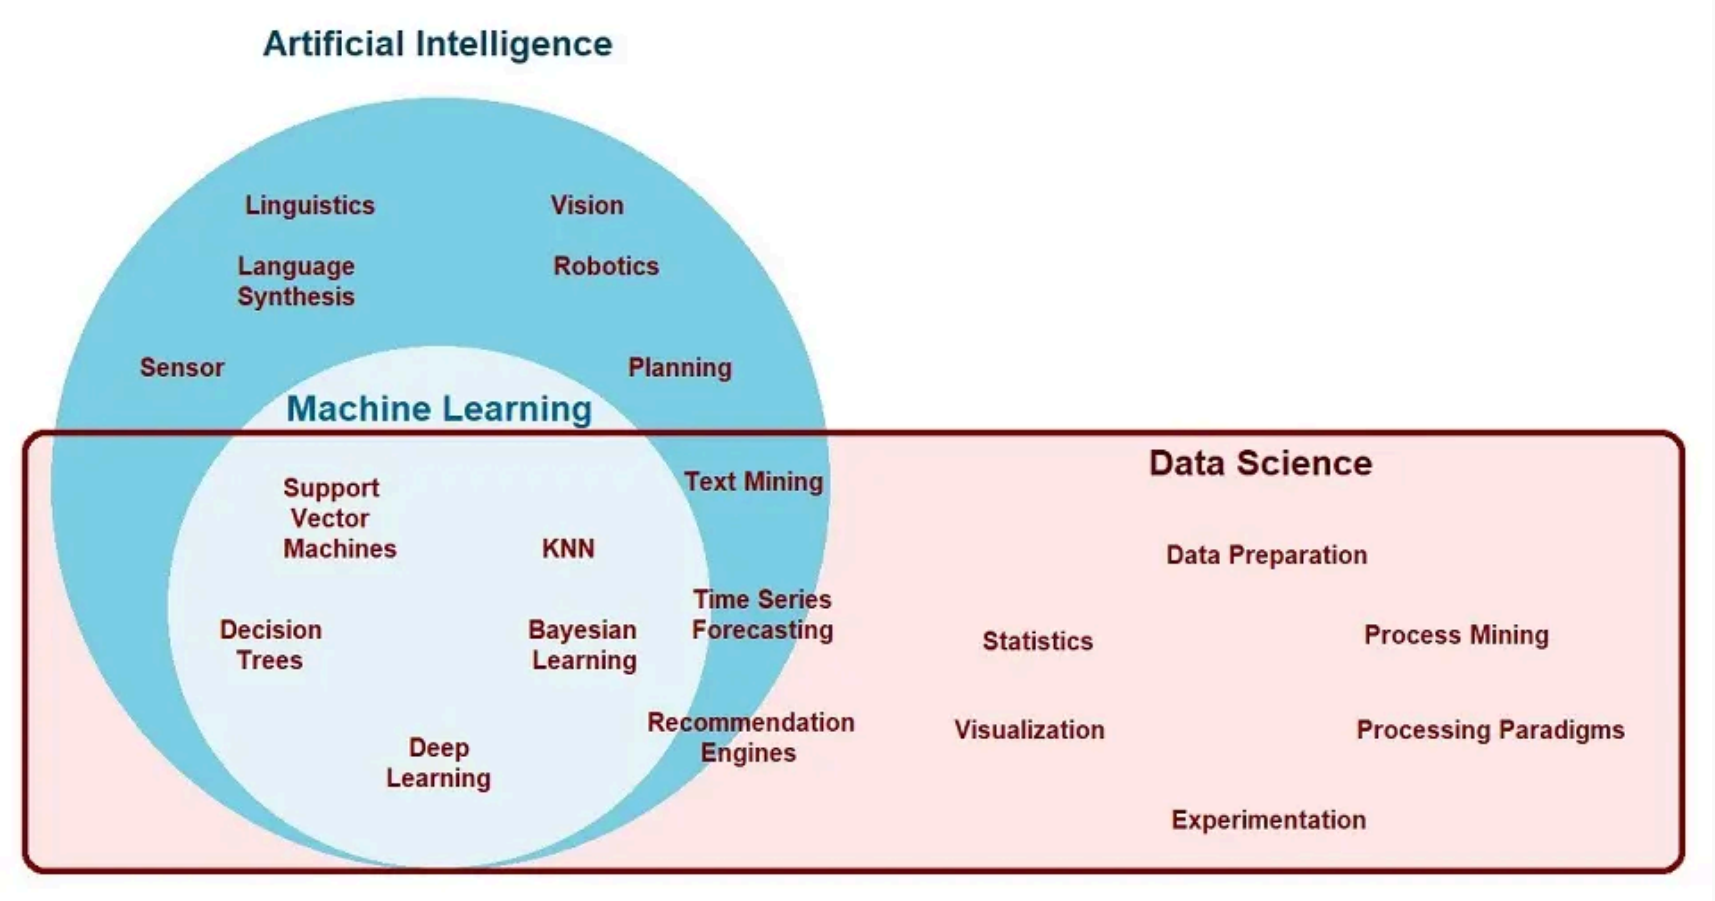
- **Kommunikation**: Öffentlichkeit, Entscheidungsträger
- **Veröffentlichen**: Zeitschriften, Software, Berichte
- **Produktivieren**: nutzbar, robust, skalierbar machen

Meta-Fähigkeit: Programmierung



`Quelle` H. Wickham, M. Çetinkaya-Rundel, G. Gronemund: R for Data Science

Was Data Science mit KI zu tun hat



Ekta Shah, EJable

Keine KI ohne Daten

1. Der Engpass sind die Daten, nicht die Modelle

- Modelle gibt es inzwischen von der Stange: Sprachmodelle, Klassifikatoren, Prognoseverfahren.
- Was es nicht von der Stange gibt: **die Daten Eures Hauses**. Ob eine Anwendung funktioniert, entscheidet sich an Verfügbarkeit, Qualität und Rechtsgrundlage der Daten.
- **80/20-Faustregel aus der Praxis**: Der Großteil der Arbeit in Data-Science-Projekten entfällt auf Beschaffen, Bereinigen und Strukturieren von Daten, nicht das Modellieren.

2. Die Verwaltung sitzt auf einem Datenschatz

- Register, Fachverfahren, Akten, Statistiken: Daten entstehen überall, meist als **Nebenprodukt** von Verwaltungshandeln.
- Häufig fragmentiert, nicht maschinenlesbar, ohne Metadaten, in Silos. Die Datenstrategie der Bundesregierung (2023) nennt das als zentrale Hürde.

3. Datenkompetenz ist Führungskompetenz

- Ihr entscheidet über Beschaffung, Freigabe, Datenstrategie, Teamaufbau, und bewertet die Versprechen von Anbietern.
- Der AI Act verlangt für Hochrisiko-Systeme explizit Daten-Governance (Art. 10). Wer die Datenbasis nicht beurteilen kann, kann KI-Systeme nicht verantworten.

Was das für Euch bedeutet

Typische Entscheidungen, die Datenkompetenz brauchen

- **Beschaffung**: Ein Anbieter verspricht 95% Genauigkeit. Mit welchen Daten wurde das gemessen – und mit welchen wird es bei uns laufen?
- **Vorlagen und Berichte**: Ist die Statistik auf Seite 3 belastbar? Was sagt das Dashboard wirklich?
- **Prüfung und Aufsicht**: Woran erkennt man ein problematisches Datenprodukt, bevor es Schaden anrichtet?
- **Freigabe und Austausch**: Welche Daten dürfen und sollten wir wie öffnen, teilen, verknüpfen, speichern?
- **Organisation**: Was braucht eine Daten-Einheit, damit sie nach dem Pilot nicht einschläft?



Was kann Data Science in der Verwaltung – und was nicht?

Data Science in der Forschung - mehr als KI

Hertie School

1. Beschreibung

- Wie ist der Zustand der Welt?
- Wie entwickeln sich Trends?
- Wie gestalten sich Gruppenunterschiede?

Der Wert für die Politikgestaltung

- Im Zentrum des **Monitorings**
- „Wie viele Menschen konsumieren Fehlinformationen im Internet?“
- „Wie entwickelt sich die Arbeitslosigkeit in Bezirken?“
- „Wie viele Radunfälle gab es pro Straßenabschnitt?“

2. Erklärung

- Welche Wirkung hat eine Maßnahme?
- Ist sie über Gruppen heterogen?
- Was sind Wirkungsmechanismen?

Der Wert für die Politikgestaltung

- Im Mittelpunkt der **Evaluation**
- „Hat die Digitalisierungsmaßnahme zu Zeitersparnis geführt?“
- „Bei wem wirkte die Anti-Fake-News-Kampagne?“
- „Warum hat die Intervention nicht zu den erwarteten Ergebnissen geführt?“

3. Vorhersage

- Wie wird Person X sich verhalten?
- (Wann) wird Ereignis X eintreten?
- Zu welchem Typ gehört eine Beobachtung?

Der Wert für die Politikgestaltung

- Steht im Mittelpunkt der **Vorhersage**, aber auch der **Zielsetzung** und **Messung**.
- „Wird die Person rückfällig werden?“
- „Enthält dieser Post Hate Speech?“
- „Wie stark wird die Wasserverschmutzung an einem bestimmten Tag sein?“

Journal of Economic Perspectives—Volume 30, Number 2—Spring 2016—Pages 151–178

The Billion Prices Project: Using Online Prices for Measurement and Research

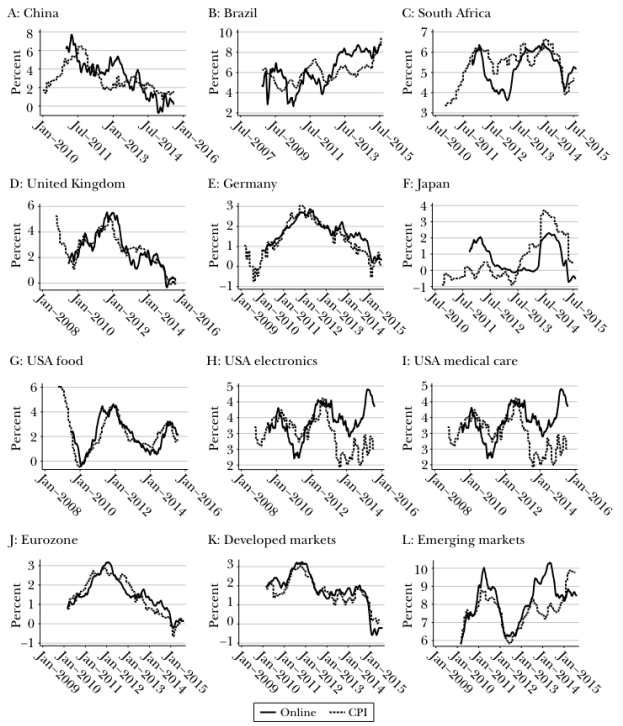
Alberto Cavallo and Roberto Rigobon

New data-gathering techniques, often referred to as "Big Data," have the potential to improve statistics and empirical research in economics. This paper presents one example of how this can be achieved by using the vast number of online prices displayed on the web. We describe our work with the Billion Prices Project at MIT, and emphasize key lessons that can be used for both inflation measurement and some fundamental research questions in macro and international economics. In particular, we show how online prices can be used to construct daily price indexes in multiple countries and to avoid measurement biases that distort evidence of price stickiness and international relative prices.

The basic procedure used in most countries to collect inflation data has remained roughly the same for decades. A large number of people working for national statistical offices visit hundreds of stores on a monthly or bimonthly basis to collect prices for a preselected basket of goods and services. The micro data are then processed and used to construct consumer price indexes and other related indicators. This process is expensive, complex, and often too slow for some users of the data. Infrequent sampling and slow updates to the baskets can complicate

Figure 4

Online versus Consumer Price Index (CPI) Annual Inflation Rates



Source: Authors using online price indexes computed by PriceStats and consumer price indexes sourced from the national statistical office in each country.

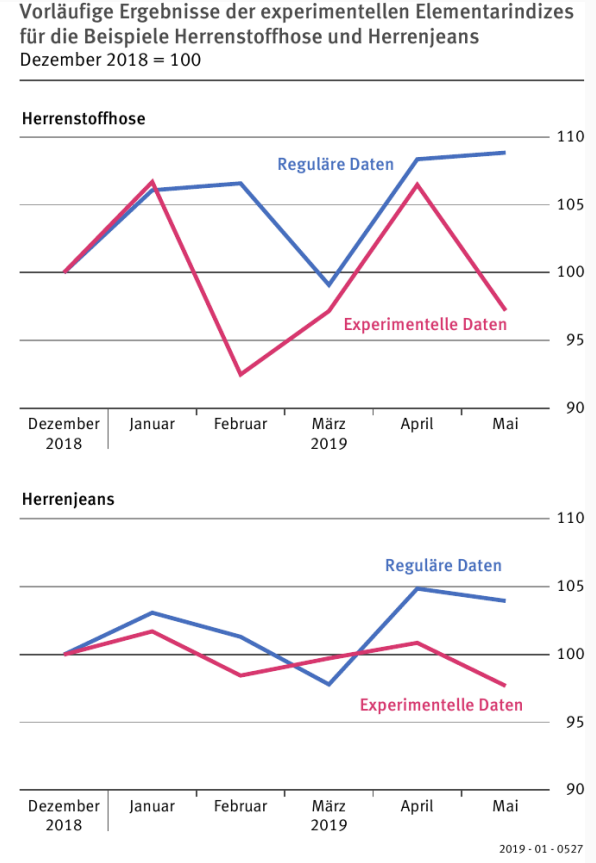
Notes: Figure 4 compares inflation as measured by online prices and by the offline prices in the official consumer price index for a selection of countries, sectors, and regions. Annual inflation rates for daily online price indexes are computed as the percentage change in the average of the previous 30 days compared to the same average 365 days before. The series are nonseasonally adjusted. Indexes are "all-items" with the exception of China, where an online supermarket index is shown next to the official food index. Global aggregates in the last row are computed using 2010 consumption weights in each country and CPIs from official sources.

Das Billion-Prices-Projekt (MIT): https://thebillionpricesproject.com/

Fall 1: Preisstatistik per Web Scraping

Der Fall

- Den **Verbraucherpreisindex** erstellt das Statistische Bundesamt (Destatis) mit den Statistischen Landesämtern: Preiserheber notieren monatlich mehrere hunderttausend Preise in Geschäften.
- Grundlage sind Preisstatistikgesetz und EU-HVPI-Verordnung. Destatis gehört zum Geschäftsbereich des Innenministeriums, ist fachlich aber unabhängig (§ 1 BStatG).
- Online-Anteil im Warenkorb: 5% (Basisjahr 2005), über 10% (Basisjahr 2015); seit der Basis 2020 nicht mehr separat ausgewiesen. Rund **10.000 Produkte** wurden monatlich im Internet erhoben – lange von Hand, zu einem festen Zeitpunkt.
- Seit 2018 automatisiert Destatis das mit einem **generischen Web-Scraping-Programm**, u.a. für Mietwagen, Medikamente, Fernbus- und Bahnreisen. Stand 2026: Web Scraping ergänzt „zunehmend die manuelle Erhebung", dazu Transaktionsdaten für Pauschalreisen und Flüge (Qualitätsbericht VPI, April 2026).



`Quelle` Blaudow/Seeger (2019), WISTA 4/2019, Grafik 6. Blau: reguläre Erhebung (ein Preis pro Monat), rot: stündliches Web Scraping.

Fall 1: Preisstatistik per Web Scraping

Hertie School

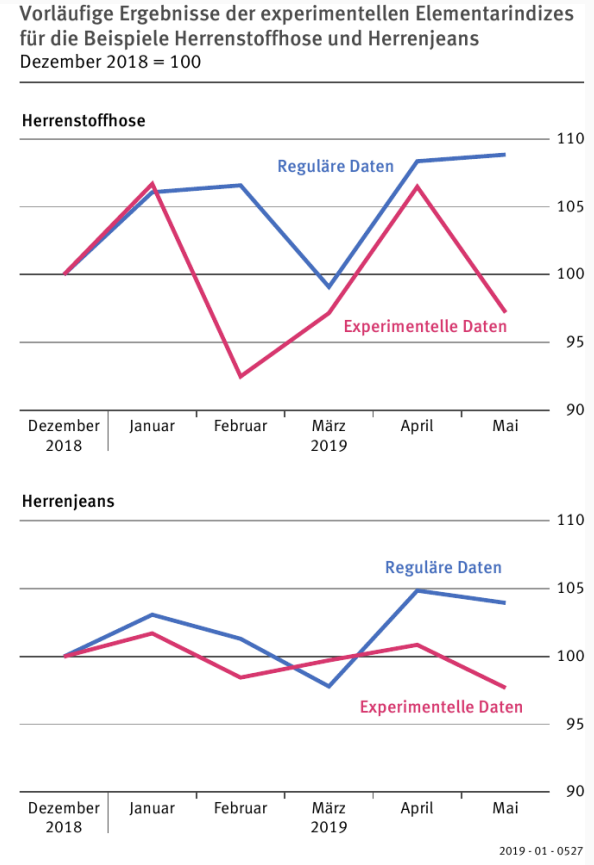
Vorteile

- **Viel mehr Preise, viel häufiger**: statt einem Preis pro Produkt und Monat beliebig viele; Sonderangebote und Preisschwankungen werden sichtbar (siehe Grafik).
- Günstiger und schneller als Preiserheber im Laden; Krisenmonitoring wird möglich.

Grenzen

- Online-Preise sind nicht immer gezahlte Preise. **Wer kauft wann wo?** Ohne Gewichtung ist der Index verzerrt.
- **Produktabgrenzung** bleibt Handarbeit: Ist die Hose von heute noch die von gestern?
- Websites ändern sich. **Wartung und Validierung** sind Dauerkosten.

✎ **Wiederkehrende Fragen:** Woher kommen Daten (Sessions 2-3)? Wen repräsentieren sie (Session 5)?



`Quelle` Blaudow/Seeger (2019), WISTA 4/2019, Grafik 6. Blau: reguläre Erhebung (ein Preis pro Monat), rot: stündliches Web Scraping.

Fall 2: Flächenmonitoring in der EU-Agrarförderung

Der Fall

- Agrarsubventionen sind an die **Nutzung von Flächen** gebunden. Jahrzehntelang wurde das per **Vor-Ort-Kontrolle** einer Stichprobe von rund 5% der Betriebe geprüft.
- Seit 2018 erprobt die EU **„Checks by Monitoring“**: Satellitenbilder der Copernicus-Satelliten Sentinel-1 (Radar, wetterunabhängig) und Sentinel-2 (optisch) liefern für **jede Parzelle** eine Zeitreihe über die Saison.
- Algorithmen erkennen darin **Marker** wie Mahd, Pflügen oder Bewuchs und gleichen sie mit den Angaben der Landwirte ab.
- Mit der GAP-Reform 2023–27 ist ein solches **Flächenmonitoringsystem** für alle Mitgliedstaaten verpflichtend (DVO (EU) 2022/1173).

`Literatur` JRC: Checks by Monitoring; EU-Kommission: IACS und GAP 2023–27



Sentinel-2-Aufnahme des BASF-Agrarversuchsgeländes bei Limburgerhof, 22.09.2016. `Quelle` ESA, contains modified Copernicus Sentinel data (2016), CC BY-SA 3.0 IGO

Fall 2: Flächenmonitoring in der EU-Agrarförderung

Hertie School

Vorteile

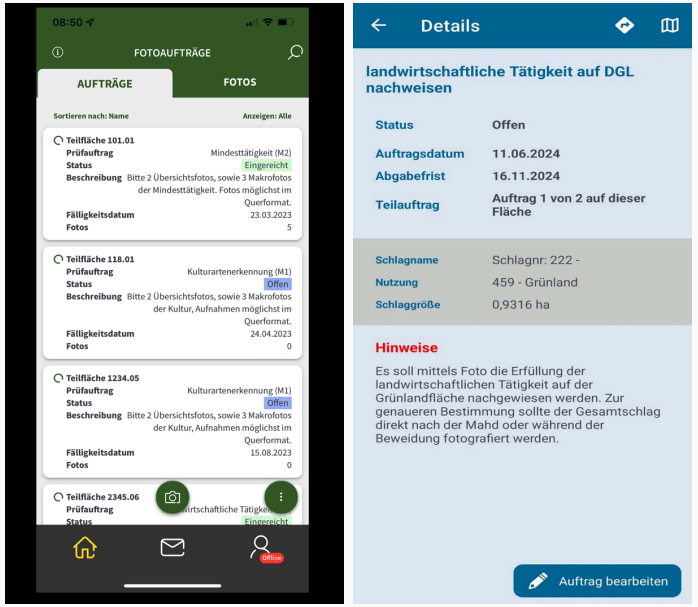
- **Vollerhebung statt Stichprobe**, kontinuierlich, ohne Betriebsbesuch.
- **Ampel statt Sanktion**: grün bestätigt, gelb unklar, rot widersprüchlich. Landwirte können nachbessern, bevor Strafen fällig werden.

Grenzen

- Wolken, kleine Parzellen, ähnliche Kulturen: Der Klassifikator **irrt systematisch** in bestimmten Lagen.
- Ohne verlässliche **Ground Truth** (Vor-Ort-Daten zum Trainieren und Validieren) kein verlässliches Modell.
- Akzeptanz: Bei gelb oder rot gibt es einen **Fotoauftrag**: Landwirte müssen per Geofoto-App nachweisen, was das Modell nicht erkennt. Fast jedes Bundesland hat eine eigene App, die Mitwirkung ist meist Pflicht.

✎ **Wiederkehrende Fragen:** Was ist eine Messung, und wann ist sie valide (Session 5)? Wie validiert man ein Modell (Session 7)?

`Quellen` Merkblatt LEA-Foto-App (RLP); Apps: LaFIS-GEOFOTO (ST), HeLawi (HE), MonaNRW, LEA-Foto (RLP), LaFIS-GEOFOTO (MV)



Fotoaufträge in LaFIS-GEOFOTO (Sachsen-Anhalt) und HeLawi (Hessen); darunter die Geofoto-Apps von ST, HE, NRW, RLP und MV. `Quelle` App Store

Fall 3: Risikoscoring

Die Fälle

Deutschland: Steuerverwaltung

- Seit 2017 erlaubt **§ 88 Abs. 5 AO** den Finanzämtern **Risikomanagementsysteme**: Ein Algorithmus wählt aus, welche Steuererklärungen ein Mensch prüft; der Rest wird vollautomatisch veranlagt. Die Kriterien sind per Gesetz geheim.
- Bislang **regelbasiert** (ca. 3.000–4.000 Parameter, drei Risikoklassen); NRW testet seit 2025 KI-Unterstützung.

Niederlande: Toeslagenaffaire

- Die Steuerbehörde nutzte ein Risikomodell zur **Betrugsaufdeckung beim Kinderbetreuungszuschlag**. Ein Risikoindikator: **(doppelte) Staatsangehörigkeit**.
- 2013–2019 wurden rund **26.000 Eltern** als Betrüger eingestuft und mussten fünfstellige Beträge zurückzahlen – überwiegend zu Unrecht.
- Folgen: Rücktritt des Kabinetts Rutte III (Januar 2021), Bußgelder der Datenschutzbehörde (2,75 und 3,7 Mio. €), Entschädigungsprogramm. Schon 2020 hatte ein Gericht das verwandte System **SyRI** gestoppt.



Briefe der Abteilung „Toeslagen“ der niederländischen Steuerbehörde. `Quelle` mystic_mabel, Flickr via Wikimedia Commons, CC BY-SA 2.0

`Zum deutschen Fall` § 88 AO; Steuertipps (2025); Bundesrechnungshof (2025); Berliner Senat (2024)

Fall 3: Risikoscoring

Vorteile

- **Routine skalieren**: Millionen Fälle sortieren, Prüfkapazität auf auffällige Fälle lenken.
- Eingebaute Kontrolle: § 88 Abs. 5 AO verlangt eine **Zufallsauswahl** von Fällen für die vollständige Prüfung – so bleibt das System überprüfbar.

Probleme

- **Verzerrte Merkmale neutralisieren**: Staatsangehörigkeit als Risikofaktor macht Diskriminierung zum Systemmerkmal.
- **Fehlerkosten abwägen**: Eine zusätzliche Prüfung kostet wenig, eine Rückforderung kann Existenzen ruinieren.

✎ **Wiederkehrende Fragen:** Falsch positiv, falsch negativ, Basisraten (Session 6). Datenstrategie und Governance (Session 9–10).

`Literatur` § 88 AO; Autoriteit Persoonsgegevens: Bußgeld gegen Belastingdienst (2021)



Briefe der Abteilung „Toeslagen“ der niederländischen Steuerbehörde. `Quelle` mystic_mabel, Flickr via Wikimedia Commons, CC BY-SA 2.0

Weitere nennenswerte Fälle

- **Predictive Policing**: PRECOBS in Bayern und Baden-Württemberg sagt Einbruchsrisiken für Gebiete vorher; die Evaluation des Max-Planck-Instituts fand allenfalls moderate Effekte. Die automatisierte Datenanalyse mit Palantir-Software in Hessen und Hamburg erklärte das Bundesverfassungsgericht 2023 in Teilen für verfassungswidrig.
- **A-Level-Noten in England (2020)**: Weil Prüfungen pandemiebedingt ausfielen, vergab ein Algorithmus Noten, auch auf Basis der historischen Ergebnisse der jeweiligen Schule. Fast 40% der Lehrerprognosen wurden herabgestuft; nach Protesten binnen Tagen zurückgenommen (Überblick, HEPI).
- **Sprachbiometrie beim BAMF**: Software schätzt aus zweiminütigen Sprachproben die Herkunftsregion von Asylsuchenden, als „Indiz", nicht als Beweis. Fehlerquote nach BAMF-Angaben 15–20%, eine unabhängige Evaluation fehlt (BT-Drs. 20/3238, netzpolitik.org).
- **AMS-Algorithmus (Österreich)**: Ein Modell sollte Arbeitslose nach Integrationschancen in drei Gruppen einteilen; Frauen, Ältere und gesundheitlich Beeinträchtigte bekamen Abzüge, weil sie früher schlechter vermittelt wurden. Nach fünf Jahren Rechtsstreit 2025 für zulässig erklärt, wird aber nicht eingeführt (Allhutter et al. 2020, AMS-Presseaussendung 2025).
- **Corona-Warn-App (2020–2023)**: Datensparsames Design, Open Source, rund 48,7 Mio. Downloads und 9 Mio. Warnungen bei 214 Mio. Euro Kosten. Beispiel dafür, dass Datenschutz und Nutzen kein Widerspruch sein müssen, aber auch dafür, wie schwer Wirkung messbar ist, wenn man kaum Daten erhebt (BT-Drs. 20/7845, Quellcode).

✎ Auffällig: Die **spektakulären Fehlschläge** betreffen häufig **Vorhersagen über einzelne Menschen**. Die sind aber notorisch schwierig (Salganik et al. 2020, Cantrell et al. 2026).

Übung

Was kann Data Science und KI, was nicht?

Whiteboard | AI-Anwendungen | Performanz | Schädlichkeit

Was kann Data Science und KI tun, was nicht?

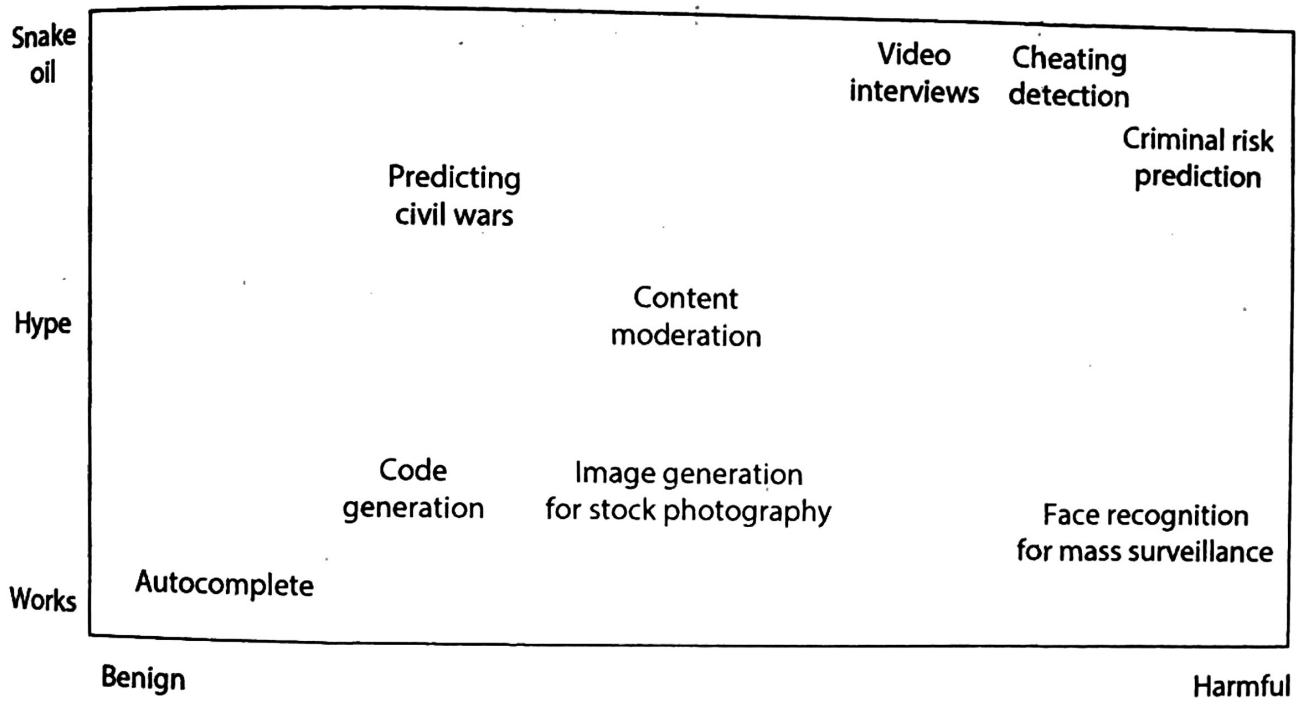


FIGURE 1.2. The landscape of AI snake oil, hype, and harms, showing a few illustrative applications.

`Quelle` Narayanan/Kapoor, AI Snake Oil, S.29

Ziele für dieses Modul

Lernziele

Nach diesem Modul könnt Ihr ...

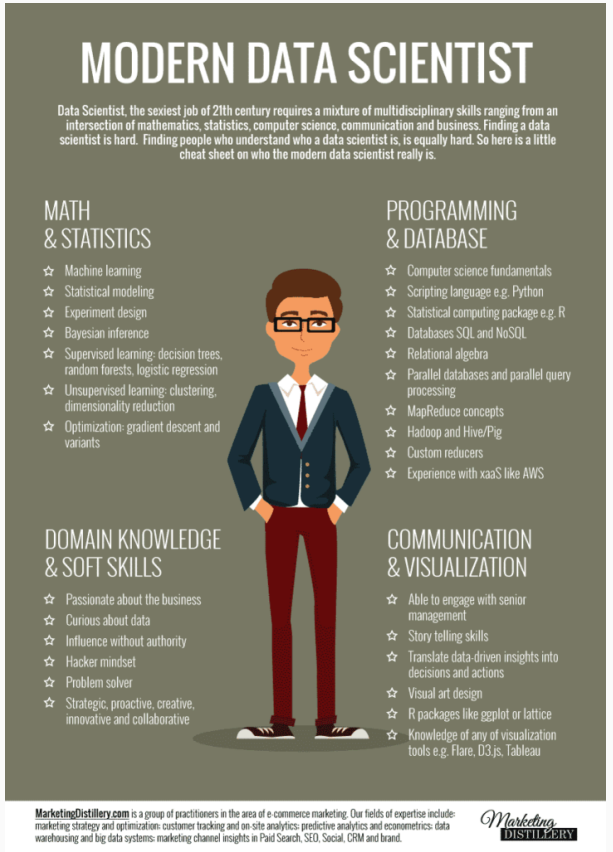
1. **Datentypen und Datenquellen einordnen**: strukturiert und unstrukturiert, prozessproduziert und erhoben, Formate und Standards; beurteilen, was in Eurem Haus davon vorhanden ist.

2. **Datenqualität beurteilen**: Repräsentativität, Messung, Verzerrung; erkennen, wann „viele Daten“ keine guten Daten sind.

3. **Statistiken und Visualisierungen kritisch lesen** und selbst so kommunizieren, dass Entscheidungen darauf aufbauen können.

4. **KI-Produkte anhand ihrer Datenbasis bewerten**: Welche Daten gingen hinein, wie wurde validiert, welche Fehler kostet was?

5. **Grundzüge einer datenbewussten Organisation entwerfen**: Datenstrategie, Infrastruktur, Open Data, Menschen.



Modulüberblick

	Tag 1: Der Daten-Lifecycle und: Woher kommen Daten?	**Tag 2: Big Data, Good Data? Die kritische Nutzung von Daten**	**Tag 3: Auf dem Weg zur datenbewussten Organisation**
9-11 h		*Session 5* Möglichkeiten und Probleme mit Big Data	*Session 9* Wie nutzt man Data Science nachhaltig in Behörden?
11-13 h	*Session 1* Data Science - Ein Überblick	*Session 6* Informierter Konsum von Daten und Statistiken	*Session 10* Gastvortrag: „Open Data Governance", Betül Özdemir, Landesbeauftragte für Open Data des Landes Berlin
13-14h	*Mittagspause*		
14-16 h	*Session 2* Wo kommen die Daten her?	*Session 7* Praxis-Session II: Daten weiterverarbeiten und strukturieren	*Session 11* Wrap-up und Ausblick
16-18 h	*Session 3* Daten gewinnen und zur Verfügung stellen	*Session 8* Kommunikation von und mit Daten	
18-19 h	*Session 4* Praxis-Session I: Daten sammeln und einlesen: Web Scraping und OCR		
19h		*Gemeinsames Abendessen*	

Was wir nicht behandeln werden

Programmierung

- Kenntnisse in Python, R, SQL usw. sind für die Datenwissenschaft unerlässlich
- Die Lernkurve ist steil und erfordert viel Übung
- Wir werfen einen (kleinen) Blick hinter die Kulissen



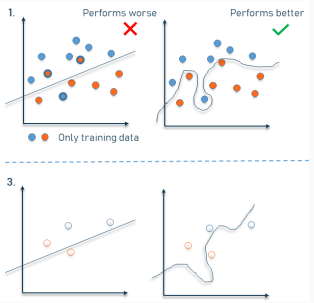
Aktive Modellierung

- Seriöse AI-Modellierung erfordert mehr theoretisches und praktisches Wissen, als wir in diesem Workshop abdecken können.
- Die Konzentration auf die Grundsätze statistischer Argumentation sollte ausreichen, um Daten und Modelle kritisch zu beurteilen.

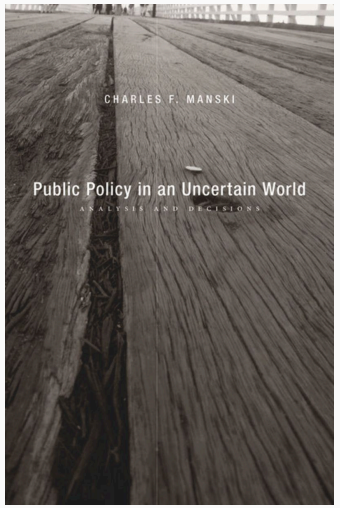


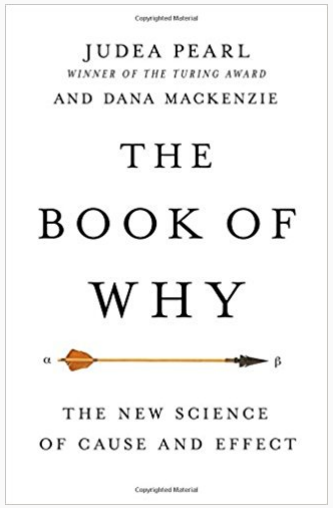
Fortgeschrittenes Maschinelles Lernen, NLP

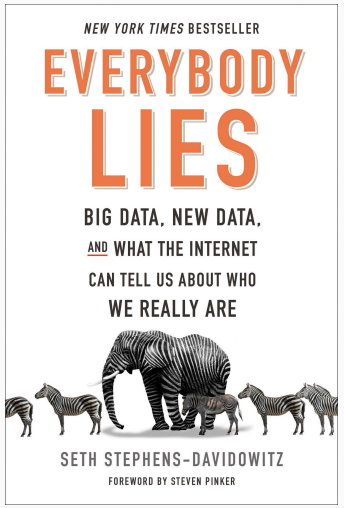
- ML, DL, NLP sind Technologien, die viele der spannendsten Anwendungen der Datenwissenschaft vorantreiben.
- Modul 3 wird hier anschließen; wir werden uns auf die Datengrundlagen konzentrieren.

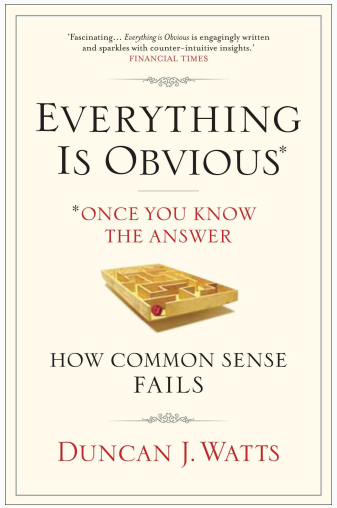


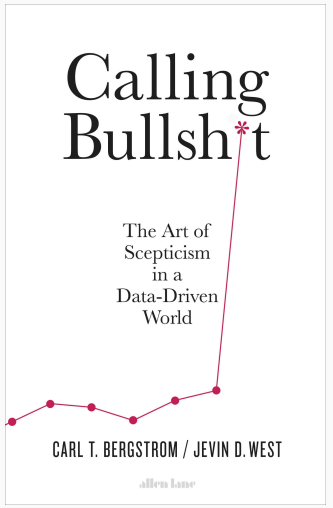
Weiterführende Literatur

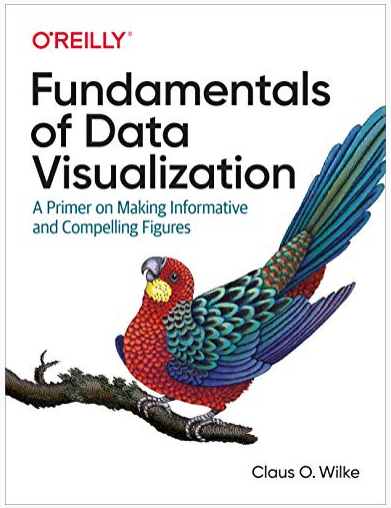


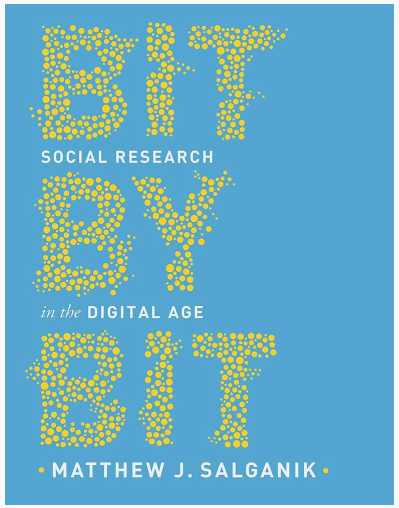


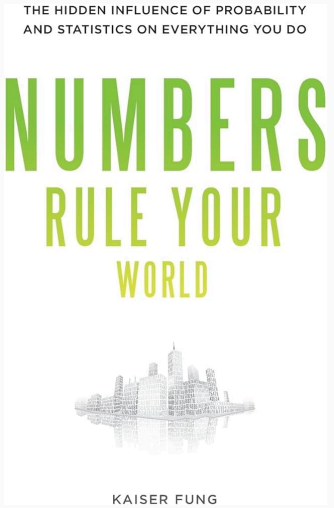


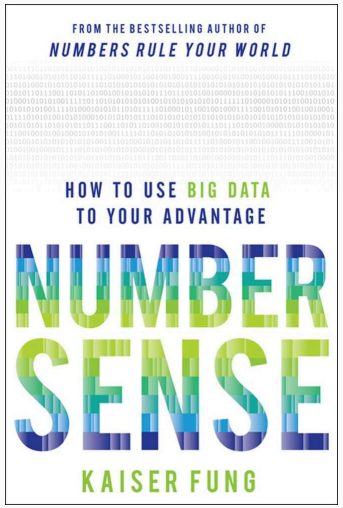


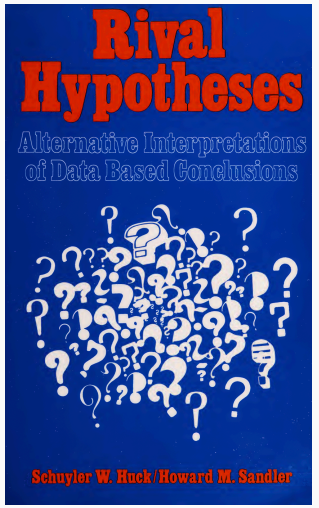


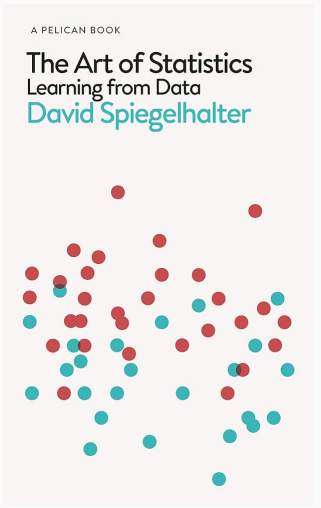


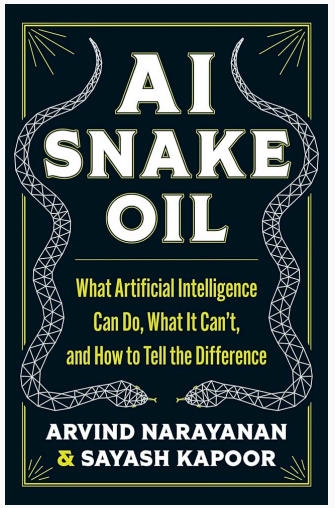












Weiterführende Podcasts

