Der Daten-Lifecycle

Session 2: Wo kommen die Daten her?

Simon Munzert
Hertie School

Überblick

1. Was sind Daten?
2. Datentypen - ein Überblick
3. Woher kommen die Daten?
4. Eure Daten

Was sind Daten?

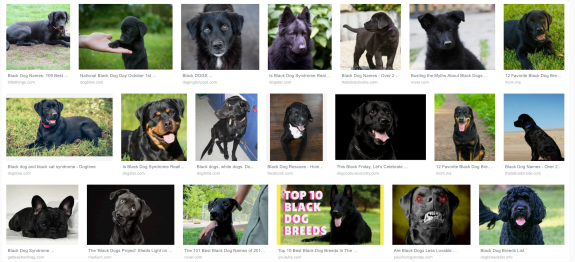
Grundgedanken

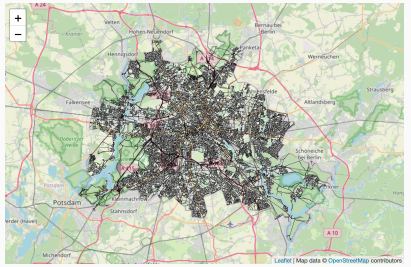
Hertie School

1. Alles ist Daten.

	A	B	C	D	E	F	G
1	OrderDa	Regio	Rep	Item	Unit	Unit Cos	Total
2	1/6/21	East	Jones	Pencil	95	1.99	189.05
3	1/23/21	Central	Kivell	Binder	50	19.99	999.50
4	2/9/21	Central	Jardine	Pencil	36	4.99	179.64
5	2/26/21	Central	Gill	Pen	27	19.99	539.73
6	3/15/21	West	Sorvino	Pencil	56	2.99	167.44
7	4/1/21	East	Jones	Binder	60	4.99	299.40
8	4/18/21	Central	Andrews	Pencil	75	1.99	149.25
9	5/5/21	Central	Jardine	Pencil	90	4.99	449.10
10	5/22/21	West	Thompso	Pencil	32	1.99	63.68
11	6/8/21	East	Jones	Binder	60	8.99	539.40
12	6/25/21	Central	Morgan	Pencil	90	4.99	449.10
13	7/12/21	East	Howard	Binder	29	1.99	57.71
14	7/29/21	East	Parent	Binder	81	19.99	1,619.19
15	8/15/21	East	Jones	Pencil	35	4.99	174.65
16	9/1/21	Central	Smith	Desk	2	125.00	250.00







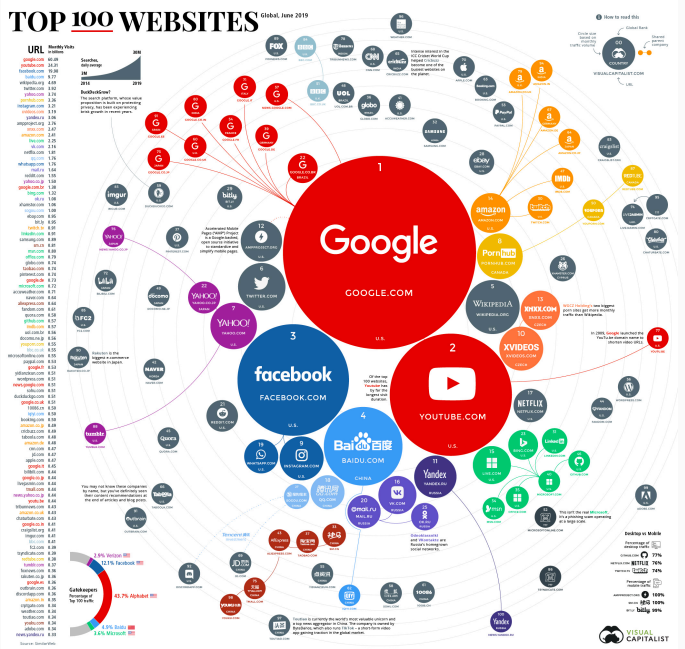


Grundgedanken

Hertie School

1. Alles ist Daten.

2. Daten sind nicht gleich Information.

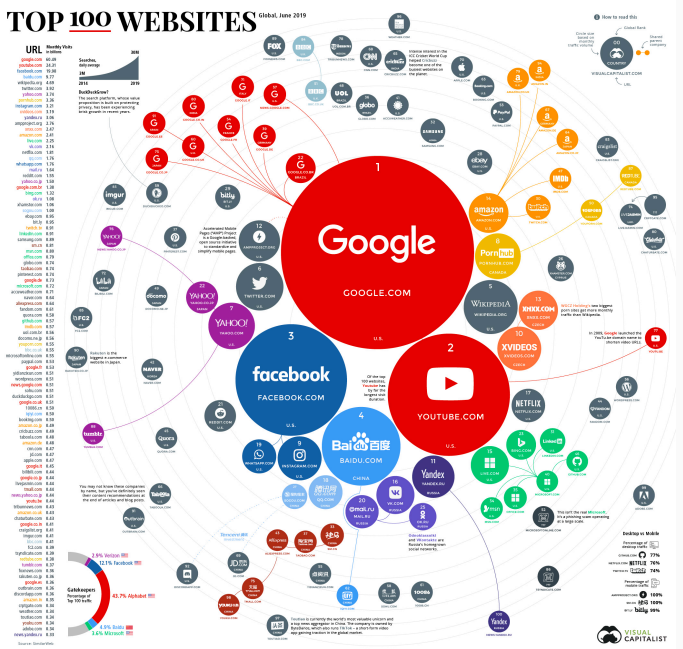




Grundgedanken

Hertie School

1. Alles ist Daten.
2. Daten sind nicht gleich Information.
3. Wir können Daten klassifizieren danach, ...





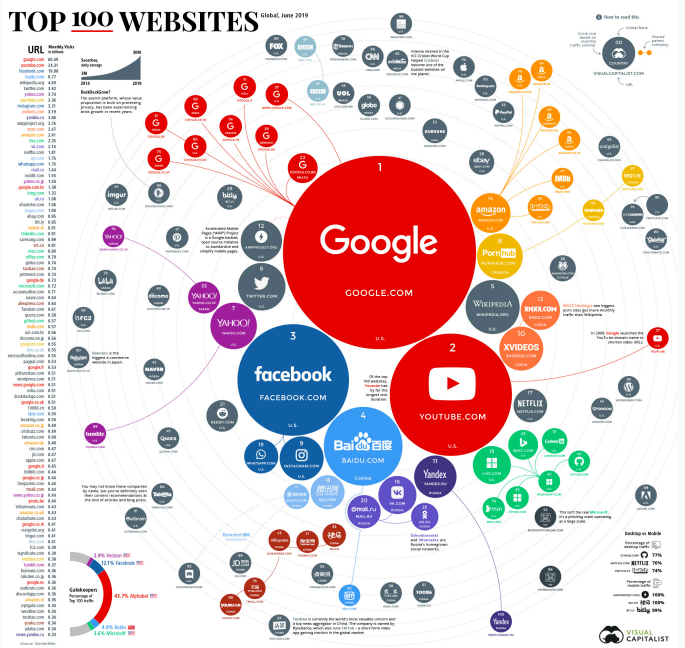
Grundgedanken

1. Alles ist Daten.

2. Daten sind nicht gleich Information.

3. Wir können Daten klassifizieren danach, ...

- wer sie generiert (Mensch vs. Maschine) bzw. woher sie stammen (*z.B. Verwaltung, Geschichte, Medizin usw.*)





Grundgedanken

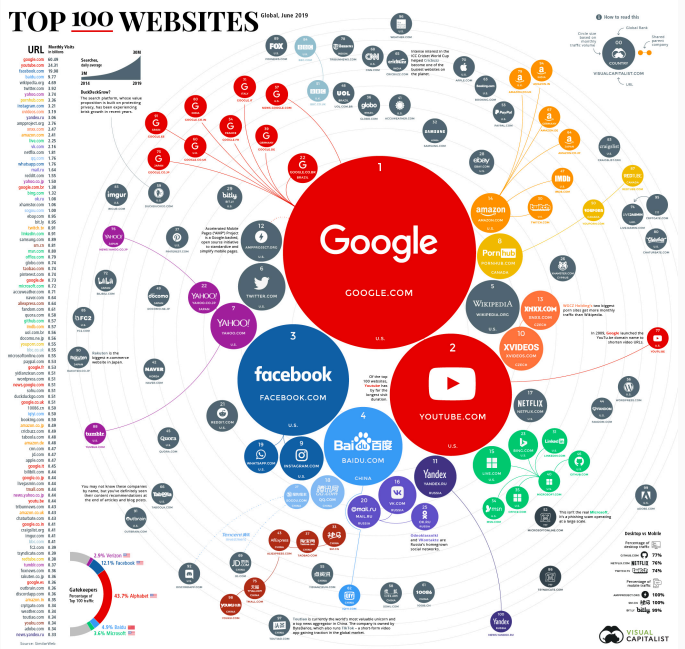
Hertie School

1. Alles ist Daten.

2. Daten sind nicht gleich Information.

3. Wir können Daten klassifizieren danach, ...

- wer sie generiert (Mensch vs. Maschine) bzw. woher sie stammen (*z.B. Verwaltung, Geschichte, Medizin usw.*)
- wie bewusst sie erhoben werden (prozessgeneriert vs. aktiv erhoben)





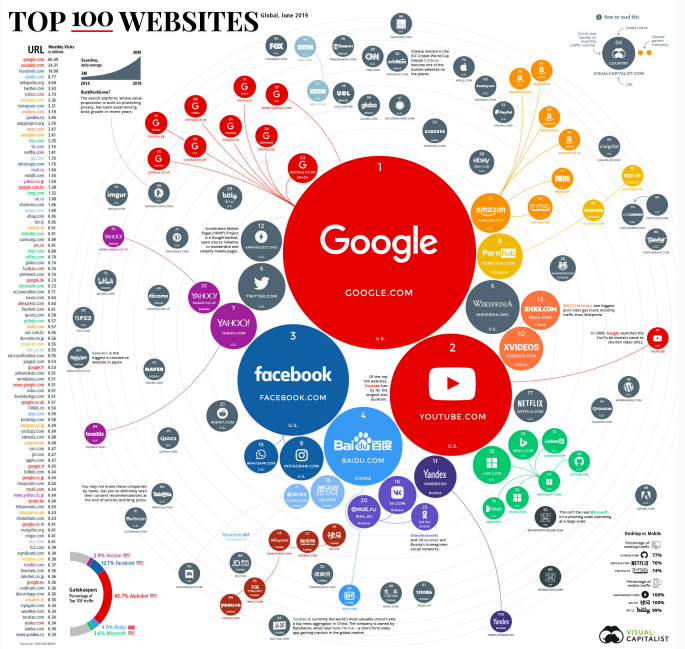
Grundgedanken

1. Alles ist Daten.

2. Daten sind nicht gleich Information.

3. Wir können Daten klassifizieren danach, ...

- wer sie generiert (Mensch vs. Maschine) bzw. woher sie stammen (*z.B. Verwaltung, Geschichte, Medizin usw.*)
- wie bewusst sie erhoben werden (prozessgeneriert vs. aktiv erhoben)
- wie strukturiert sie sind (maschinenlesbar vs. nicht maschinenlesbar)





Grundgedanken

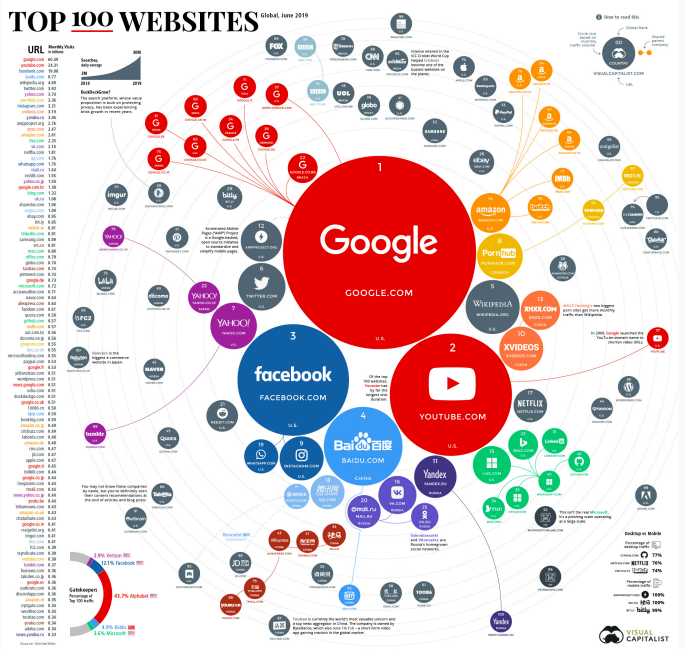
Hertie School

1. Alles ist Daten.

2. Daten sind nicht gleich Information.

3. Wir können Daten klassifizieren danach, ...

- wer sie generiert (Mensch vs. Maschine) bzw. woher sie stammen (*z.B. Verwaltung, Geschichte, Medizin usw.*)
- wie bewusst sie erhoben werden (prozessgeneriert vs. aktiv erhoben)
- wie strukturiert sie sind (maschinenlesbar vs. nicht maschinenlesbar)
- was sie abbilden (welche Art von Information, z.B. Text, Bild, Geodaten, Netzwerkdaten)





Grundgedanken

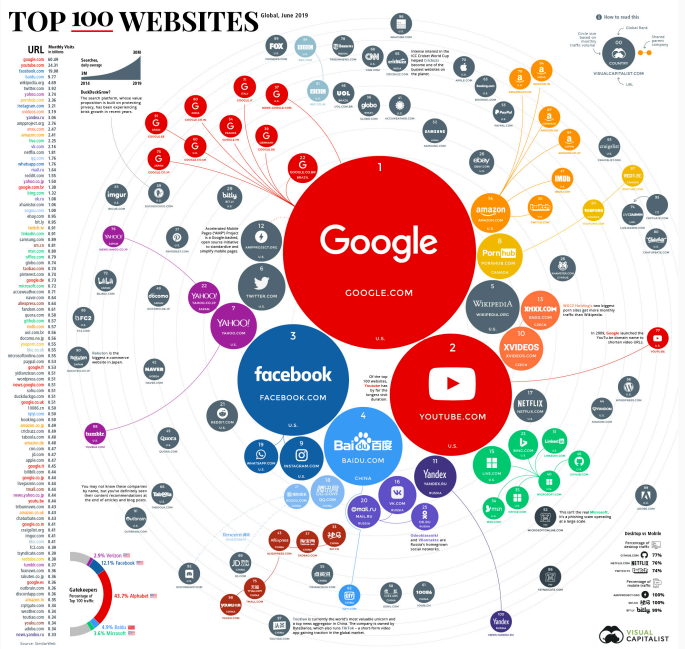
1. Alles ist Daten.

2. Daten sind nicht gleich Information.

3. Wir können Daten klassifizieren danach, ...

- wer sie generiert (Mensch vs. Maschine) bzw. woher sie stammen (*z.B. Verwaltung, Geschichte, Medizin usw.*)
- wie bewusst sie erhoben werden (prozessgeneriert vs. aktiv erhoben)
- wie strukturiert sie sind (maschinenlesbar vs. nicht maschinenlesbar)
- was sie abbilden (welche Art von Information, z.B. Text, Bild, Geodaten, Netzwerkdaten)

Und nach vielem mehr (Beständigkeit, Digitalisierung, etc.). Für uns eher relevant: Welche **Datentypen** sind **im Data-Science- und AI-Kontext** besonders relevant und wie machen wir sie nutzbar?



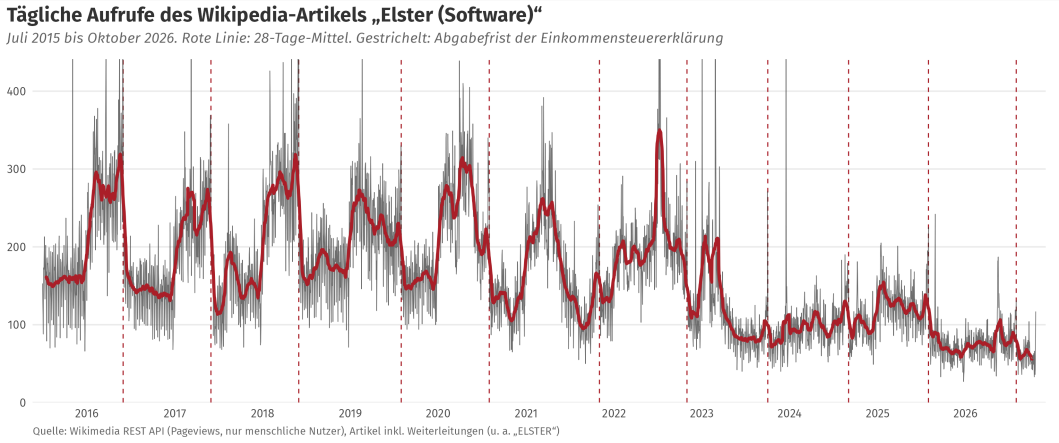


Prozessproduzierte vs. aktiv generierte Daten

Hertie School

Prozessproduzierte Daten

- Daten, die als Nebenprodukt von Prozessen generiert werden
- Beispiele: Transaktionsdaten (z. B. E-Commerce), Log-Daten (z. B. Website-Clicks), Emails, **Verwaltungsakten**
- Ein Großteil der Daten, die in KI-Anwendungen verwendet werden, sind prozessproduzierte Daten



Aktiv generierte Daten

- Daten, zu einem bestimmten Zweck erhoben
- Beispiele: Umfragen, Experimente, Beobachtungen (z. B. manuelle Zählungen), Formulare
- Aktiv generierte Daten sind oft teurer und aufwendiger zu erheben, aber passgenauer für bestimmte Fragestellungen



Strukturierte, semistrukturierte, unstrukturierte Daten

	Strukturierte Daten	Semistrukturierte Daten	Unstrukturierte Daten
Gestalt	Tabellen mit festen Spalten und Datentypen	Verschachtelt, mit Markierungen (Tags, Schlüssel), aber ohne starres Schema	Rohmaterial ohne vorgegebene Struktur
Typische Formate	CSV, Excel, relationale Datenbanken	XML, JSON, XÖV-Nachrichten, E-Mails	Text, PDF, Bilder, Audio, Video
In der Verwaltung	Register, Fachverfahren, Statistik, Haushaltsdaten	Online-Anträge (XFall), elektronische Rechnungen (XRechnung), Schnittstellen zwischen Fachverfahren	Akten, Bescheide, Vermerke, Fotos, Protokolle, Bürgeranfragen
Maschinenlesbar?	direkt	mit einem Parser	oft erst nach Verarbeitung (OCR, Sprachmodelle, Bilderkennung)

✎ Die Grenzen sind fließend: Ein PDF-Bescheid ist unstrukturiert, die Daten darin stammen aus einem strukturierten Fachverfahren. Ein Teil von "KI in der Verwaltung" ist der Versuch, diesen Weg **rückwärts** zu gehen.

✎ Formate (CSV, XML, JSON, XFall) sind Thema von **Session 3**; unstrukturierte Daten nutzbar machen (OCR) ist Thema der **Praxis-Sessions**.

Datentypen - ein Überblick

Datentypen in Aktion

Was KI-Anwendungen antreibt

- Die spektakulären Anwendungen der letzten Jahre laufen fast alle auf **unstrukturierten Daten**: Text, Code, Bilder, Satellitenaufnahmen, Verhaltensspuren.
- Die folgenden Beispiele zeigen jeweils: **Welcher Datentyp**, **woher die Daten kommen**, und **was dabei schiefgehen kann**.

Einige Fragen zum Mitdenken

1. Welche Daten gehen in das System hinein, und wer hat sie erzeugt?
2. Wurde den Datenerzeuger:innen gesagt, wofür ihre Daten genutzt werden?
3. Gibt es Belege dafür, dass das System funktioniert?



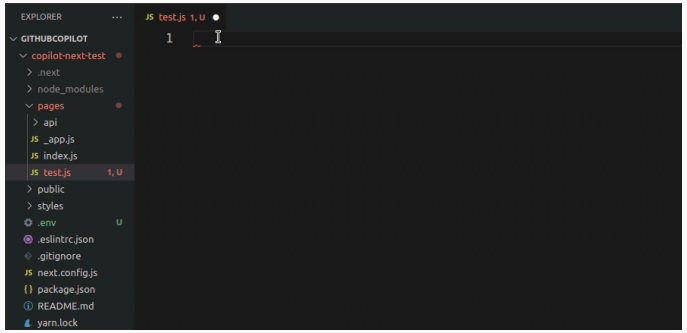
	A	B	C	D	E	F	G
1	OrderDa	Regio	Rep	Item	Unit	Unit Cos	Total
2	1/6/21	East	Jones	Pencil	95	1.99	189.05
3	1/23/21	Central	Kivell	Binder	50	19.99	999.50
4	2/9/21	Central	Jardine	Pencil	36	4.99	179.64
5	2/26/21	Central	Gill	Pen	27	19.99	539.73
6	3/15/21	West	Sorvino	Pencil	56	2.99	167.44
7	4/1/21	East	Jones	Binder	60	4.99	299.40
8	4/18/21	Central	Andrews	Pencil	75	1.99	149.25
9	5/5/21	Central	Jardine	Pencil	90	4.99	449.10
10	5/22/21	West	Thompso	Pencil	32	1.99	63.68
11	6/8/21	East	Jones	Binder	60	8.99	539.40
12	6/25/21	Central	Morgan	Pencil	90	4.99	449.10
13	7/12/21	East	Howard	Binder	29	1.99	57.71
14	7/29/21	East	Parent	Binder	81	19.99	1,619.19
15	8/15/21	East	Jones	Pencil	35	4.99	174.65
16	9/1/21	Central	Smith	Desk	2	125.00	250.00

Textdaten: GitHub Copilot

"Your AI Pair Programmer"

- GitHub Copilot ist ein KI-gestütztes Tool, das Entwickler/innen beim Schreiben von Code unterstützt.
- Wurde von GitHub & OpenAI entwickelt (ursprünglich auf GPT-3-Basis).
- Copilot kann Codevorschläge machen, die auf dem Kontext des Codes basieren, den Ihr gerade schreibt.
- Es kann auch ganze Funktionen schreiben, wenn man eine Beschreibung gibt (💻 Demonstration).
- Copilot ist in der Lage, in vielen verschiedenen Programmiersprachen zu arbeiten.





`Quelle` Scalablepath.com

Datengrundlage

- Massen an Code, vermutlich von Plattformen wie GitHub, StackOverflow, etc.
- Substantieller Impact auf Developer-Community, aber auch Kritik bzgl. Urheberrechten und Datenschutz.

Satellitenbilder zur Messung von räumlichen Phänomenen

Hertie School

Das Potential von Satellitenbildern und Luftaufnahmen

- Mit massiv gestiegener **Auflösung** sowie **räumlicher** und **zeitlicher Abdeckung** werden Satellitenbilder mittlerweile für viele Forschungs- und kommerzielle Zwecke eingesetzt
- Rohdaten alleine sind wenig nützlich: Machine-Learning-Techniken, um Muster zu erkennen bzw. inferieren

Beispiele

- Vorhersage von Armut (Neal Jean et al., Science)
- Vorhersage von ökonomischer Entwicklung (Burke et al.)
- Erkennung von Photovoltaik-Anlagen (de Hoog et al.)
- Monitoring von Agrarwirtschaft und Ernteerträgen (siehe letzte Session)

RESEARCH ARTICLES

ECONOMICS

Combining satellite imagery and machine learning to predict poverty

Neal Jean,[1,2*] Marshall Burke,[3,4,5*†] Michael Xie,[1] W. Matthew Davis,[4] David B. Lobell,[3,4] Stefano Ermon[1]

Reliable data on economic livelihoods remain scarce in the developing world, hampering efforts to study these outcomes and to design policies that improve them. Here we demonstrate an accurate, inexpensive, and scalable method for estimating consumption expenditure and asset wealth from high-resolution satellite imagery. Using survey and satellite data from five African countries—Nigeria, Tanzania, Uganda, Malawi, and Rwanda—we show how a convolutional neural network can be trained to identify image features that can explain up to 75% of the variation in local-level economic outcomes. Our method, which requires only publicly available data, could transform efforts to track and target poverty in developing countries. It also demonstrates how powerful machine learning techniques can be applied in a setting with limited training data, suggesting broad potential application across many scientific domains.

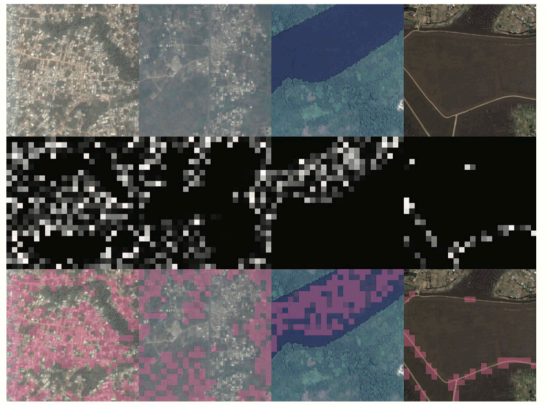


Fig. 2. Visualization of features. By column: Four different convolutional filters (which identify, from left to right, features corresponding to urban areas, nonurban areas, water, and roads) in the convolutional neural network model used for extracting features. Each filter "highlights" the parts of the image that activate it, shown in pink. By row: Original daytime satellite images from Google Static Maps, filter activation maps, and overlay of activation maps onto original images

Luftaufnahmen: Autobahnparkplatzerkennung

Hertie School

Remote Sensing of Car and Truck Parking Lots at German Highway Rest Areas using Semantic Segmentation*

Master Thesis

Benedikt N. Korbach†
b.korbach@students.hertie-school.org

April 29, 2024

Abstract

The widespread adoption of electric vehicles (EVs) necessitates the expansion of public charging infrastructure, particularly along highways to facilitate long-distance, low-carbon transportation. For optimal charging site planning, accurate information on parking lot size and type is crucial. Public parking inventories and community-based databases such as OpenStreetMap (OSM), however, often provide unreliable and inconsistent parking information. This paper addresses these challenges by leveraging aerial imagery to accurately estimate parking lots for cars and trucks at German highway rest areas. As a main contribution, a dataset of 246 high-resolution images of rest areas is created from publicly accessible sources, with manually verified and corrected ground-truth annotations gathered from OSM. Various semantic segmentation algorithms (U-Net, LinkNet, Feature Pyramid Network) trained on this dataset are assessed for their ability to detect specific parking lots. The best-performing model demonstrates robust performance in parking area extraction, achieving a mean Intersection over Union (mIoU) score of 0.70 on full-scale test cases. This method offers a validation technique to enhance the accuracy of parking inventory data along highways, thereby informing the strategic development of charging infrastructure.

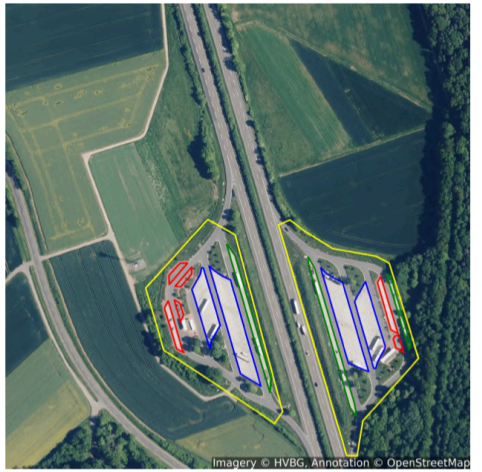


Figure 1: Example of a Correctly Labelled Rest Area. Yellow line polygons are used to indicate service station areas, blue polygons for truck parking areas, red polygons for car parking areas, and green polygons for pull-off zones.

Fotos: Googles Kindesmissbrauch-Prävention

Anwendung und Ziel

- Image Content Moderation mit KI: Google's efforts to combat Child Sexual Abuse Material (CSAM) über Google Photos; Sperren von Accounts mutmaßlicher Täter
- Launch 2018: Google Blogpost; letzter Stand hier



Bildquelle

Evaluation und Probleme

- Keine belastbaren Angaben zu Accuracy des Tools; siehe auch Narayanan/Kapoor, 2024: S. 181, 194
- Google Nutzer/innen kennen Erkennungskriterien nicht oder können Missklassifikation nur schwer anfechten
- NYT Recherche: Familienvater fotografierte geschwollenen Intimbereich seines Babys für den Hausarzt, Missklassifikation als Kindesmissbrauch und Zugang zu allen Google Services, Google SIM Karte und Google beruflicher Account gesperrt; etliche weitere Berichte von gesperrten Eltern

Digitale Spurendaten: COVID-19-App-Nutzung

Hertie School

nature human behaviour

ARTICLES

https://doi.org/10.1038/s41562-020-01044-x

Check for updates

Tracking and promoting the usage of a COVID-19 contact tracing app

Simon Munzert[1]✉, Peter Selb[2], Anita Gohdes[1], Lukas F. Stoetzer[3] and Will Lowe[1]

Digital contact tracing apps have been introduced globally as an instrument to contain the COVID-19 pandemic. Yet, privacy by design impedes both the evaluation of these tools and the deployment of evidence-based interventions to stimulate uptake. We combine an online panel survey with mobile tracking data to measure the actual usage of Germany's official contact tracing app and reveal higher uptake rates among respondents with an increased risk of severe illness, but lower rates among those with a heightened risk of exposure to COVID-19. Using a randomized intervention, we show that informative and motivational video messages have very limited effect on uptake. However, findings from a second intervention suggest that even small monetary incentives can strongly increase uptake and help make digital contact tracing a more effective tool.

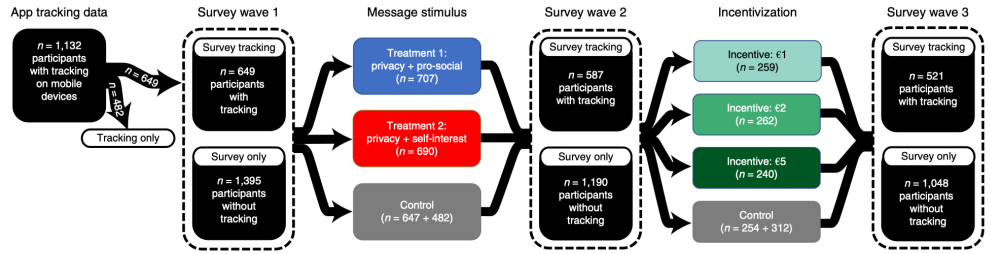


Fig. 1 | Overview of the study design. To collect tracking data (app usage, time stamps, duration and device information) from the app, members of the survey provider's passive tracking panel were incentivized to provide mobile app usage histories via passive metering software (Wakoopa). This was done from 15 June 2020 (1 d before the official app launch) until 21 September 2020 and included only panellists with Android devices. During survey wave 1, participants completed a 20-min survey about sociodemographic, attitudinal and behavioural characteristics. They were then assigned to one of two message interventions (message stimulus) or a control group. For analyses of tracked app usage, the 482 participants with mobile tracking only were used as additional controls. During survey wave 2, an average of 12 d after the initial survey, the participants were surveyed again to reassess their attitudes and behaviours. As part of the follow-up survey, self-reported non-users of the app were randomly assigned to one of three incentivization conditions or to a control group. When analysing tracked app usage, the 312 participants in the tracking-only group who did not have the app installed at the time of the follow-up survey were included as additional controls. Finally, during survey wave 3, an average of 28 d later, the survey wave 2 participants were re-invited to another follow-up survey during which their attitudes and behaviours were re-assessed.

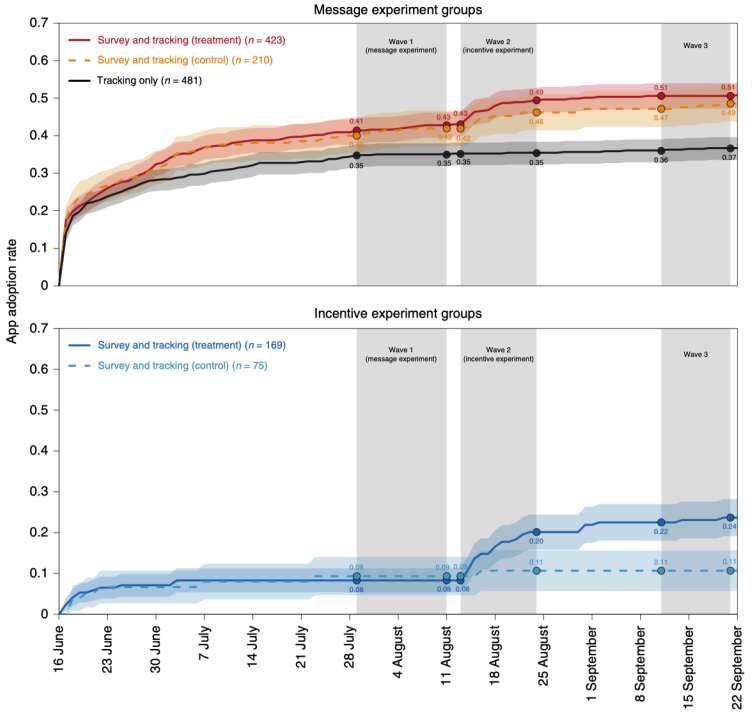


Fig. 4 | App adoption rates over time for message and incentive groups. The top plot shows the estimated rates and 83% CIs (shaded areas) for treated, control and baseline tracking-only respondents. The bottom plot shows the estimated rates and 83% CIs for treated and control respondents in the incentive group. Note that this group was limited to those who never adopted the app or uninstalled it by wave 2. Non-overlapping intervals indicate a significant difference at $P < 0.05$.

Übung

Welche Beispiele für Text-, Bild- und digitale Spurendaten fallen euch ein, die in Eurem Kontext genutzt werden (könnten)?

Wie werden sie erzeugt?

Was sind mögliche Fehlerquellen?

Woher kommen die Daten?

Datenquellen in der Verwaltung

Quelle	Beispiele	Was das für die Qualität heißt
Register	???	???
Fachverfahren und Akten	???	???
Amtliche Statistik	???	???
Sensoren und Infrastruktur	???	???
Externe und offene Daten	???	???
Eigene Erhebungen	???	???

✎ **Was vermutet Ihr?** Welche Daten fallen in Eurem Haus in diese Kategorien, und was bedeutet ihre Herkunft für die Qualität?

Datenquellen in der Verwaltung

Quelle	Beispiele	Was das für die Qualität heißt
Register	Melderegister, Handelsregister, Grundbuch, Fahrzeugregister	Je Eintrag verlässlich, aber in Silos; Verknüpfung rechtlich eng begrenzt
Fachverfahren und Akten	Antrags- und Fallbearbeitung, Bescheide, Vermerke	Nebenprodukt der Sachbearbeitung; selten für Auswertung gedacht; oft nur als PDF
Amtliche Statistik	Zensus, Mikrozensus, Wirtschaftsstatistiken	Methodisch dokumentiert, aber aggregiert und zeitverzögert
Sensoren und Infrastruktur	Verkehrszählung, Luftqualität, Pegel	Groß und kontinuierlich; Messfehler und Lücken bei Ausfall
Externe und offene Daten	Open-Data-Portale, Web, Satelliten	Nachnutzbar, aber Zweck, Qualität und Lizenz prüfen
Eigene Erhebungen	Befragungen, Evaluationen, Zählungen	Passgenau, aber teuer; Antwortverzerrungen

✎ Die meisten Daten in Behörden sind **prozessproduziert**: Sie entstehen, weil ein Verfahren bearbeitet wird, nicht, weil jemand sie auswerten wollte. Das hat Auswirkungen auf ihre Qualität und Nutzungpotentiale.

Womit werden KI-Systeme gefüttert?

Hertie School

KI-Produkt	Funktion	Datenbasis
Sprachmodelle ChatGPT, Claude, Gemini	Text generieren, zusammenfassen, programmieren, recherchieren	**???**
Alexa Amazon	Sprachassistent; seit 2025 als „Alexa+“ auf Basis eines Sprachmodells	**???**
Palantir Gotham in Deutschland: HessenDATA, VeRA (Bayern), DAR (NRW)	Analyseplattform der Polizei: Personen, Orte, Ereignisse über Datenbestände hinweg verknüpfen	**???**
Stable Diffusion Stability AI, Open Source	Bilder aus Textbeschreibungen erzeugen	**???**

✎ **Was vermutet Ihr?** Woher stammen die Daten, mit denen diese Systeme trainiert oder betrieben werden?

Womit werden KI-Systeme gefüttert?

Hertie School

KI-Produkt	Funktion	Datenbasis
Sprachmodelle ChatGPT, Claude, Gemini	Text generieren, zusammenfassen, programmieren, recherchieren	Frei zugängliches Web (Common Crawl), Bücher, Wikipedia, Foren, Code; bei GPT-3 noch offengelegt, seit GPT-4 nicht mehr. Dazu **lizenzierte Inhalte** (Axel Springer, Reddit) und **menschliches Feedback**, u.a. von Annotatoren in Kenia für unter 2 $/Stunde (TIME 2023).
Alexa Amazon	Sprachassistent; seit 2025 als „Alexa+“ auf Basis eines Sprachmodells	Sprachaufnahmen aus Millionen Haushalten, Nutzungs- und Kaufhistorie, Smart-Home-Geräte. Seit 28.03.2025 gehen alle Aufnahmen in die Cloud, die lokale Verarbeitung wurde abgeschafft (Ars Technica). 2023 zahlte Amazon 25 Mio. $, weil Kinderaufnahmen unbegrenzt gespeichert wurden (DOJ/FTC).
Palantir Gotham in Deutschland: HessenDATA, VeRA (Bayern), DAR (NRW)	Analyseplattform der Polizei: Personen, Orte, Ereignisse über Datenbestände hinweg verknüpfen	**Keine eigenen Datenbestände**: Palantir liefert die Software, nicht die Daten („not in the business of collecting, mining, or selling data“, Ulbricht/Egbert 2024). Verknüpft wird, was die Polizei einspeist: Vorgangs- und Fallsysteme, Register, TKÜ, Funkzellenabfragen, ausgelesene Handys, soziale Netzwerke (BT-Drs. 21/5625). Grenzen durch das BVerfG 2023.
Stable Diffusion Stability AI, Open Source	Bilder aus Textbeschreibungen erzeugen	LAION-5B: 5,85 Mrd. Bild-Text-Paare, automatisch aus dem Web gesammelt, ohne Einwilligung der Urheber. Dez. 2023 wegen über 1.000 Missbrauchsdarstellungen zurückgezogen (Stanford), Aug. 2024 bereinigt als Re-LAION-5B. Getty verlor 2025 in London weitgehend (High Court).

Womit werden KI-Systeme gefüttert?

Drei Beobachtungen

1. **Die Daten sind oft nicht für den Zweck erhoben worden.** Webtexte, Sprachaufnahmen, Falldateien: alles Nebenprodukte, nachträglich zum Trainingsmaterial erklärt.
2. **Die Datenbasis ist die eigentliche Blackbox.** Modellarchitekturen sind publiziert, Trainingsdaten nicht. Bei Sprachmodellen weiß niemand außerhalb des Unternehmens, was drin ist.
3. **Bei Verwaltungssoftware bringt der Anbieter nicht zwangsläufig Daten mit.** Die Qualität des Systems ist die Qualität **Eurer** Daten.

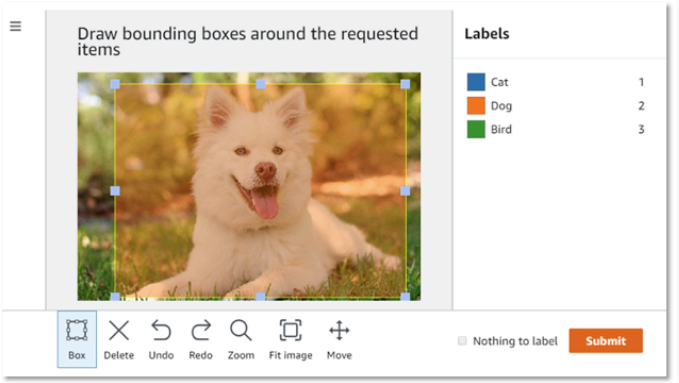
Beispiele

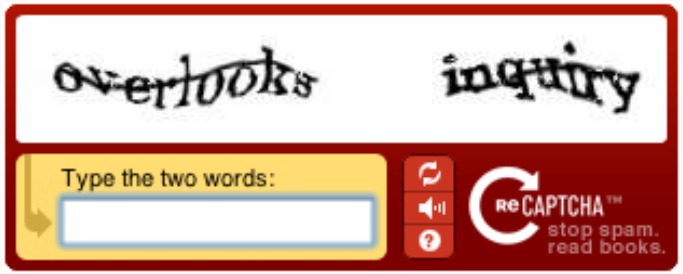
Anwendung	Datenbasis
F13, KI-Assistent der Landesverwaltung BW	Dokumente und Vorlagen der Landesverwaltung, dazu ein kommerzielles Sprachmodell
Risikomanagement der Finanzämter	Steuererklärungen, Vorjahresdaten, Kontrollmitteilungen Dritter
Flächenmonitoring Agrarförderung	Sentinel-Satellitenbilder plus Antragsdaten der Landwirte als Vergleichsmaßstab
Sprachbiometrie BAMF	Sprachproben aus Asylverfahren, Referenzsamples pro Dialekt
Kommunale Chatbots	Dienstleistungstexte des Serviceportals

Human in the loop

Ohne Menschen keine KI

- Fast jedes KI-System braucht **menschliche Arbeit** an den Daten: Beispiele beschriften (Bilder, Texte, Tonaufnahmen), Modellantworten bewerten (das „Feedback“ hinter Sprachmodellen), Grenzfälle entscheiden, Fehler prüfen.
- Diese Arbeit ist unsichtbar, global verteilt und schlecht bezahlt. Sprachmodelle sind so „höflich“, weil Tausende Annotatoren, u.a. in Kenia und auf den Philippinen, Antworten sortiert haben.





Wo diese Arbeit stattfindet

- **Datenannotations-Firmen**: Scale AI, Surge AI, Mercor, Appen, u.a. (Amazon Mechanical Turk, jahrelang die wichtigste Quelle für Annotationen und Umfragen, wurde am **30.9.2026** geschlossen.)
- **Content Moderation**: Meta, TikTok, YouTube beschäftigen Zehntausende, meist über Subunternehmer.
- **Unbezahlt, nebenbei**: Jede CAPTCHA-Lösung trainiert Bilderkennung

Clickworking und Crowdsourcing

Plattformen

- **Mikrojobs**: Texte prüfen, Bilder beschriften, Daten erfassen, Antworten bewerten. Bezahlung pro Aufgabe.
- Clickworker (Deutschland, nach eigenen Angaben über 6 Mio. Registrierte), Prolific (Forschung), Toloka, Appen, dazu die KI-Spezialisten Scale AI, Surge AI und Mercor, die inzwischen Fachkräfte (Ärzt:innen, Jurist:innen, Programmierer:innen) für anspruchsvolle Bewertungen anwerben.

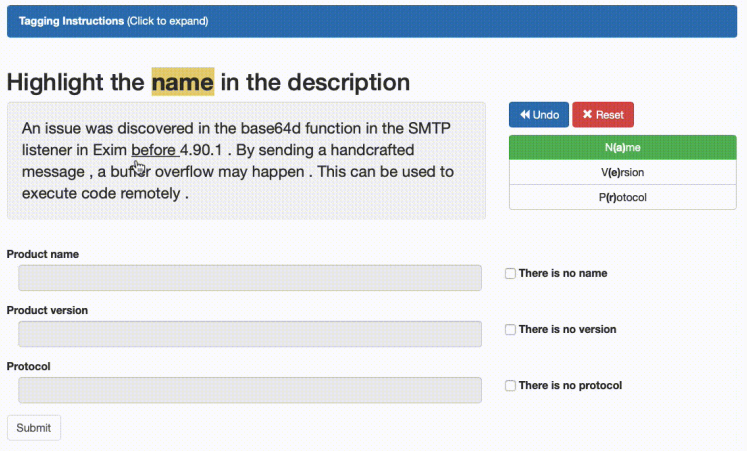
Ethische Fragen

- **Bezahlung und Arbeitsbedingungen**: Oft unter Mindestlohn; keine Absicherung; Belastung durch verstörende Inhalte (Moderation).
- **Globale Arbeitsteilung**: Die Annotation wandert dorthin, wo Arbeit billig ist; die Wertschöpfung bleibt beim Auftraggeber.
- **Datenschutz**: Wer annotiert Eure Akten, wenn Ihr ein Modell trainieren lasst, und wo sitzt diese Person?

amazon mechanical turk beta

2005–2026

Prolific



`Quelle` TechPolicy.Press: Mechanical Turk is Closing (2026)

Und wenn die Daten nicht passen?

Zwei Fragen, die wir morgen vertiefen werden

Wer oder was ist in den Daten drin, wer nicht? (Selektion)

- Ein Fachverfahren kennt nur die, die einen Antrag gestellt haben, nicht die Berechtigten, die es nicht getan haben.
- Ein Chatbot, trainiert auf Bürgeranfragen per Web, kennt die Anliegen derer nicht, die anrufen oder vorbeikommen.

Wird gemessen, was gemeint ist? (Messung)

- Eine Akte dokumentiert die Entscheidung, nicht den Sachverhalt samt Kontext und alle angestellten Erwägungen.

Take-aways für heute

- Der Kontext der Datenerhebung entscheidet, **für wen** und **wofür** ein System funktioniert.
- Fundamentale Qualitätsprobleme lassen sich nicht nachträglich wegtrainieren.
- Zur Beurteilung der Datengüte für KI-Anwendungen benötigt es dieses Kontextwissen - zum Beispiel zusammengetragen in einem Steckbrief.



Eure Daten

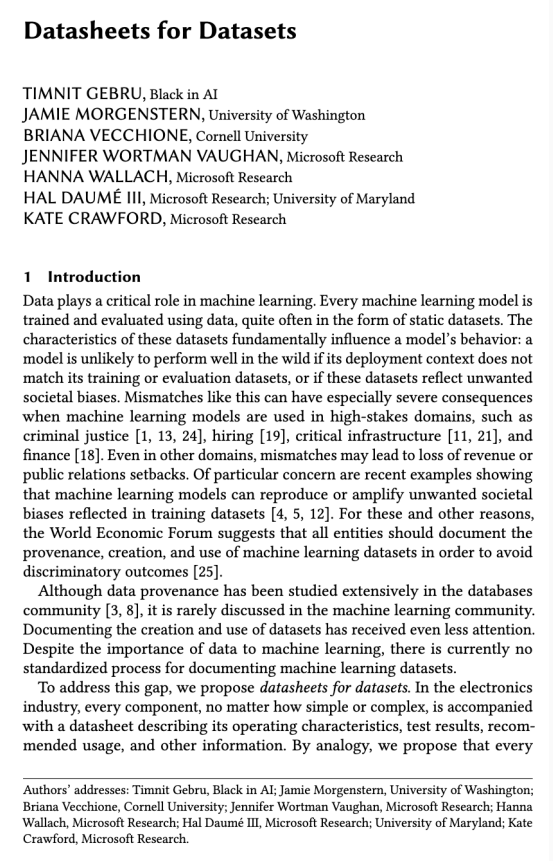
Ein Steckbrief für Datensätze

„Datasheets for Datasets“

- Vorschlag von Gebru et al. (2021): Jeder Datensatz bekommt einen **Beipackzettel**, so wie elektronische Bauteile ein Datenblatt haben.
- Ziel: Wer einen Datensatz nutzt, soll wissen, wofür er entstanden ist und wofür er **nicht** taugt.

Die Leitfragen

1. **Motivation**: Wofür und von wem wurde der Datensatz erstellt?
2. **Zusammensetzung**: Was ist eine Zeile? Gibt es sensible Daten, Lücken?
3. **Erhebung**: Wie, von wem, über welchen Zeitraum wurden Daten gesammelt?
4. **Aufbereitung**: Was wurde bereinigt, gefiltert, verändert? Gibt es die Rohdaten noch?
5. **Nutzung**: Wofür wurde er bisher verwendet? Wofür sollte er nicht verwendet werden?
6. **Pflege**: Wer ist verantwortlich? Wird er aktualisiert? Wie lange wird er aufbewahrt?



Datasheets for Datasets

TIMNIT GEBRU, Black in AI
JAMIE MORGENSTERN, University of Washington
BRIANA VECCHIONE, Cornell University
JENNIFER WORTMAN VAUGHAN, Microsoft Research
HANNA WALLACH, Microsoft Research
HAL DAUMÉ III, Microsoft Research; University of Maryland
KATE CRAWFORD, Microsoft Research

1 Introduction

Data plays a critical role in machine learning. Every machine learning model is trained and evaluated using data, quite often in the form of static datasets. The characteristics of these datasets fundamentally influence a model's behavior: a model is unlikely to perform well in the wild if its deployment context does not match its training or evaluation datasets, or if these datasets reflect unwanted societal biases. Mismatches like this can have especially severe consequences when machine learning models are used in high-stakes domains, such as criminal justice [1, 13, 24], hiring [19], critical infrastructure [11, 21], and finance [18]. Even in other domains, mismatches may lead to loss of revenue or public relations setbacks. Of particular concern are recent examples showing that machine learning models can reproduce or amplify unwanted societal biases reflected in training datasets [4, 5, 12]. For these and other reasons, the World Economic Forum suggests that all entities should document the provenance, creation, and use of machine learning datasets in order to avoid discriminatory outcomes [25].

Although data provenance has been studied extensively in the databases community [3, 8], it is rarely discussed in the machine learning community. Documenting the creation and use of datasets has received even less attention. Despite the importance of data to machine learning, there is currently no standardized process for documenting machine learning datasets.

To address this gap, we propose *datasheets for datasets*. In the electronics industry, every component, no matter how simple or complex, is accompanied with a datasheet describing its operating characteristics, test results, recommended usage, and other information. By analogy, we propose that every

Authors' addresses: Timnit Gebru, Black in AI; Jamie Morgenstern, University of Washington; Briana Vecchione, Cornell University; Jennifer Wortman Vaughan, Microsoft Research; Hanna Wallach, Microsoft Research; Hal Daumé III, Microsoft Research; University of Maryland; Kate Crawford, Microsoft Research.

`Quelle` Gebru et al. (2021), Communications of the ACM

Übung

Daten-Poster-Karrussell

1. 5 Gruppen à 5 Personen
2. Jede Gruppe hat einen festen Poster-Standort.
3. Jeweils eine Person bleibt beim eigenen Poster stehen und erklärt es.
4. Die 4 anderen hören zu, stellen Fragen.
5. Nach 3–4 Minuten wird gewechselt: Die nächste Person ist dran, bis alle 5 vorgestellt haben.