Der Daten-Lifecycle

Session 4: Praxis-Session - Web Scraping und APIs

Simon Munzert
Hertie School

Überblick

1. Wozu Webdaten?
2. Web scraping
3. Web APIs

Wozu Webdaten?

Was sind Webdaten?

Definition

- Webdaten sind **Daten, die im, für oder über das Web generiert oder über Webtechnologien zur Verfügung gestellt werden**.

Beispiele für Webdaten

- Online-Nachrichtenartikel
- Netzwerkstrukturen in sozialen Medien
- Crowdsourced-Datenbanken (z. B. Wikidata)
- Serverprotokolle (z. B. Statistiken über die Zuschauerzahlen)
- Online-Verhalten
- Jede beliebige Website

Keine genuinen Webdaten

- Offline generierte Datensätze, die über das Web disseminiert werden (z.B. nicht web-basierte Umfragen; offizielle Statistiken)



`Quelle` eDiscoveryToday, LTMG

Die Bedeutung von Webdaten für AI-Technologien

Hertie School

Datenquelle für KI-Modelle

- **Web als Datenlieferant:** Das Web ist eine riesige Quelle von Daten, die für das Training von KI-Modellen unerlässlich sind. Durch öffentlich zugängliche Webseiten, soziale Medien, Blogs, Nachrichtenportale und andere Online-Plattformen wird eine Vielzahl von Informationen erzeugt, die in Form von Text, Bildern, Videos und Audiodaten vorliegen.

- **KI-Training durch das Web:** Plattformen wie Amazon Mechanical Turk nutzen das Web, um KI-Systeme mit menschlichen Beiträgen zu trainieren. Crowdsourcing ermöglicht es, menschliche Intelligenz zu nutzen, um Daten zu labeln oder komplexe Aufgaben zu lösen, die für KI-Algorithmen schwierig sind.

Plattform für KI-Dienste

- **Cloud-basierte KI-Services:** Viele KI-Dienste werden über das Web in der Cloud angeboten. Diese Dienste ermöglichen es Entwicklern, leistungsstarke KI-Anwendungen ohne den Bedarf an eigenen Infrastrukturen zu nutzen. Beispiele sind Amazon Web Services (AWS), Microsoft Azure oder Google Cloud, die KI-Modelle bereitstellen, die über APIs aufgerufen werden können.

- **KI in Web-Anwendungen:** KI wird zunehmend in Web-Anwendungen integriert. Beispiele sind intelligente Suchmaschinen, personalisierte Inhalte in sozialen Netzwerken und Empfehlungssysteme in Online-Shops, die auf dem Web basieren.

Die Bedeutung von Webdaten für AI-Technologien (2)

Kollaboration und Wissensaustausch

- **Open-Source-Communities:** KI-Entwicklung profitiert von der offenen Zusammenarbeit, die das Web ermöglicht. Plattformen wie GitHub, Stack Overflow oder spezielle KI-Foren bieten Möglichkeiten für Entwickler, Code zu teilen, zu lernen und innovative KI-Projekte gemeinsam voranzutreiben.
- **KI-Forschung:** Viele bahnbrechende KI-Forschungsarbeiten und Datensätze werden im Web veröffentlicht und zugänglich gemacht. Dies erleichtert die Verbreitung von Wissen und die schnelle Entwicklung neuer KI-Ansätze.
- **Verfügbarkeit von KI-Tools:** Über das Web stehen KI-Entwicklungstools, Bibliotheken und Frameworks wie TensorFlow, PyTorch und OpenAI zur Verfügung, die es Entwicklern ermöglichen, eigene KI-Anwendungen zu erstellen und zu trainieren.







Die Bedeutung von Webdaten in der Verwaltung

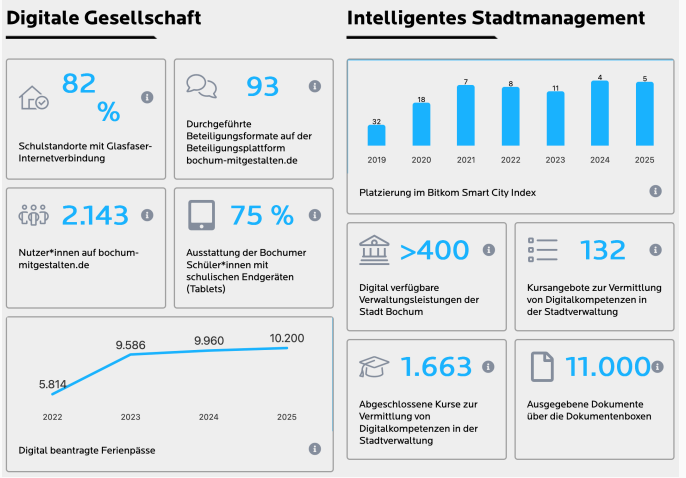
Hertie School

Verwaltung als Webdaten-Provider

- **Open Government Data**: Bereitstellung offener Datensätze durch Regierung und Verwaltung
- **E-Government**

Verwaltung als Webdaten-Nutzer

- **Erhebung von Verwaltungsdaten,** z.B. Unternehmensregister, Immobilienpreise, Arbeitsmarktdaten
- **Echtzeit-Monitoring,** z. B. Analyse von Verkehrsdaten, Wetterinformationen oder Gesundheitsdaten
- **Bürgerbeteiligung,** z.B. Auswertungen von Foren, sozialen Medien (eher fragwürdig)

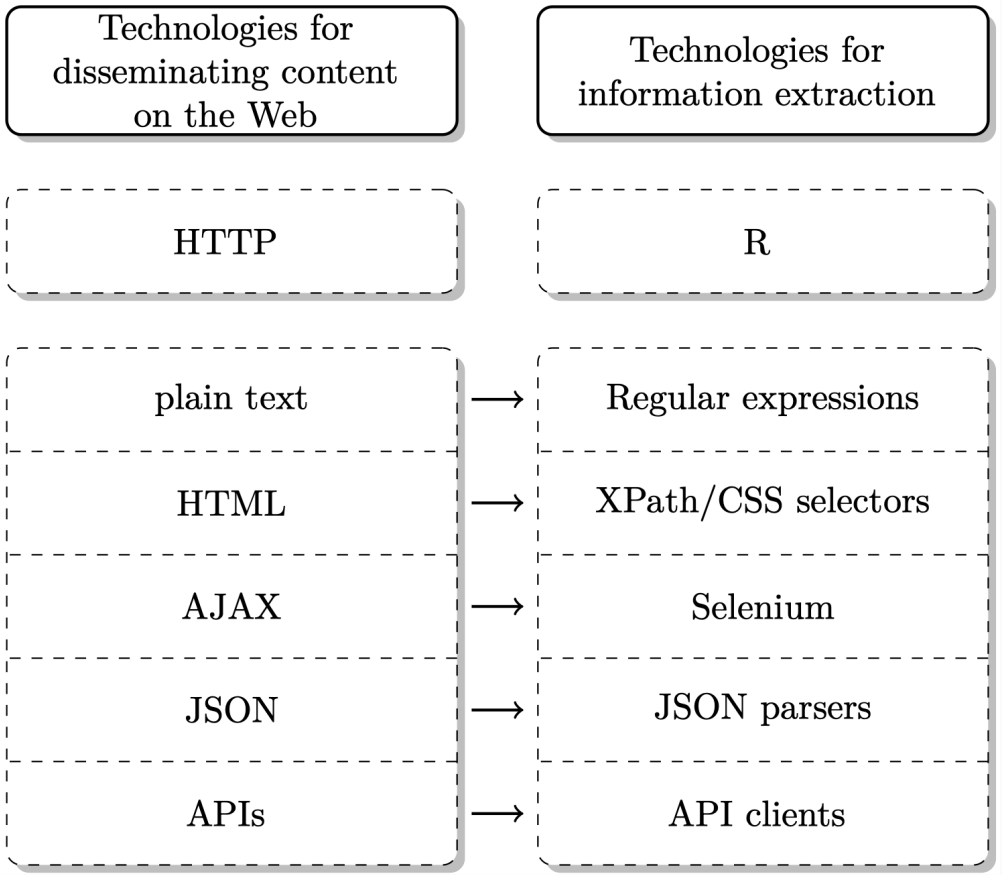




Web scraping

Webtechnologien

- Um Webdaten für Data-Science-Anwendungen verfügbar zu machen, greifen wir auf bestimmte Webtechnologien zurück.
- Konkret sind folgende Fragen relevant:
  - Wie unser Rechner/Browser/R mit Webservern kommuniziert (→ **HTTP/S**)
  - Wie Webseiten aufgebaut sind (→ **HTML**, **CSS**, Grundlagen von **JavaScript**)
  - Wie Inhalte in Webseiten effektiv gefunden werden können (→ **XPath**, **CSS-Selektoren**)
  - Wie dynamische Webanwendungen ausgeführt und abgegriffen werden (→ **AJAX**, **Selenium**)
  - Wie Daten von Webdiensten verteilt und verarbeitet werden (→ **APIs**, **JSON**, **XML**)



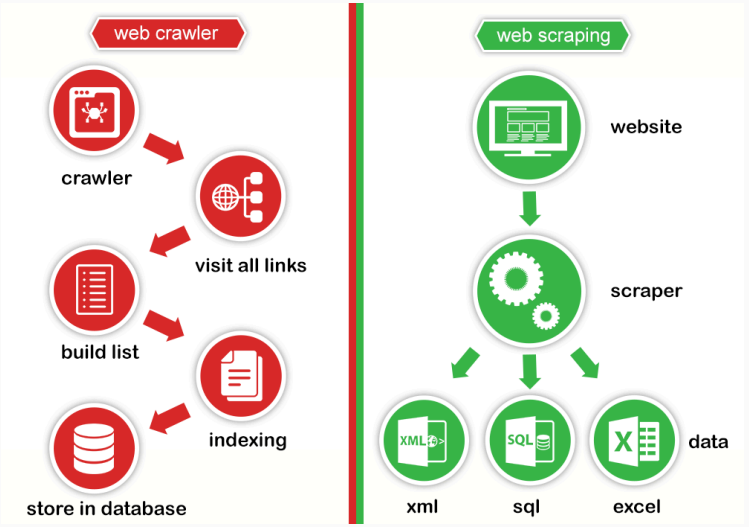
`Quelle` ADCR

Was ist Web Scraping?

1. Auslesen von (unstrukturierten) Daten aus Websites (HTMLs)
2. Aufbereitung der Daten, Überführung in saubere Datenstruktur (analysefähiges Format)

Skriptbasiertes Vorgehen

- Kein händisches Copy-and-Paste-Verfahren
- Skripting (Programmierung) des gesamten Prozesses
- Automatisiert wird:
  - Das Herunterladen von Dateien und Webseiten
  - Das Parsing von Webinhalten
  - Das gezielte Auslesen von Informationen
  - Anzapfen von APIs
  - Datenbereinigung, Textdatenverarbeitung
- Scraping-Programme skalieren und können wiederholt große Datenmengen sammeln

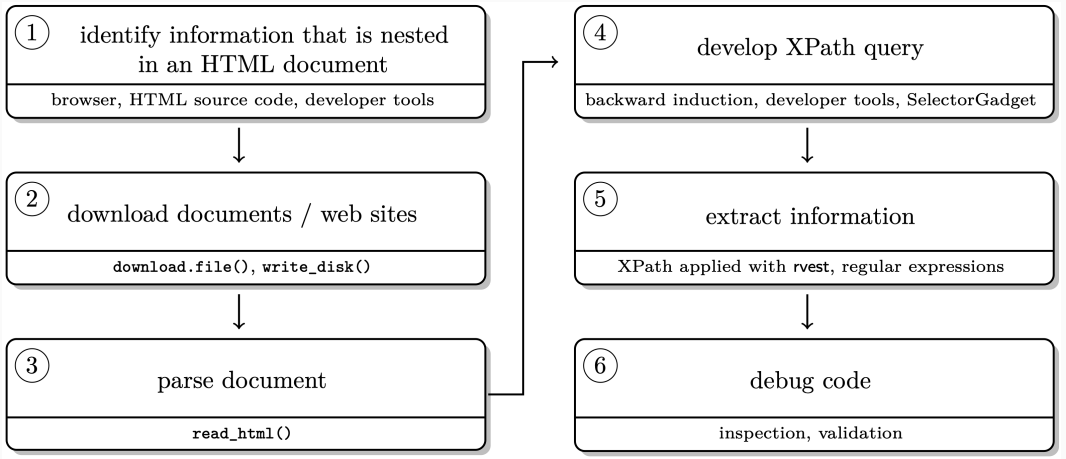


`Credit` prowebscraping.com

Der Scraping-Workflow

Die wichtigsten Werkzeuge für das Scraping statischer Webseiten

1. Untersuchen von HTML-Seiten mit den Webentwickler-Tools im Browser
2. Parsing von HTML mit dedizierten Programmen/Computercode (z.B. Python, R)
3. Auslesen bestimmter Information mit XPath oder CSS-Selektoren (Mini-Sprachen)
4. Weiterverarbeitung der Daten in skriptbasierten Programmen (z.B. mit `dplyr` oder `pandas` in R/Python)
5. Speichern der Daten in einem geeigneten Format (z.B. CSV, JSON, Datenbank)



Mehr zu Web Scraping

Weitere Möglichkeiten

Scraping ist nicht auf Inhalte von statischen Webseiten beschränkt. Die Mächtigkeit von Scraping-Tools entfaltet sich in Szenarien, in denen:

- **Daten von mehreren Seiten** gesammelt werden sollen
- Automatisiert mit Webinhalten **interagiert** werden soll (z.B. über Formulare), um konditionale Inhalte abzugreifen
- **Authentifizierung** erforderlich ist
- **Dynamische Inhalte** (mit JavaScript angereichert) abgegriffen werden sollen



Weiterführende Materialien

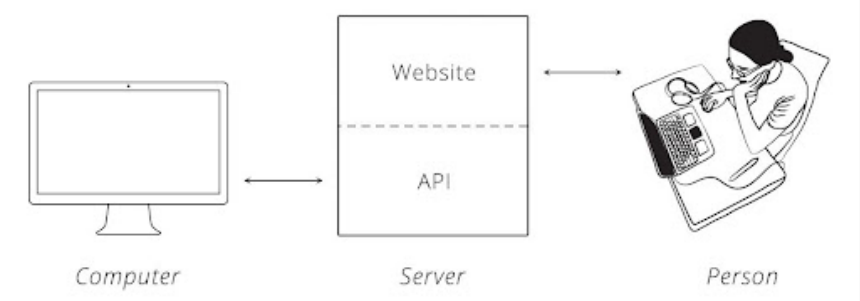
Weitere Beispiele, Scraping-Tutorials und Lernmaterialien finden sich hier und hier.

Web APIs: Grundlagen

Was sind Web APIs?

Definition

- Ein **A**pplication **P**rogramming **I**nterface erlaubt den programmatischen Zugriff auf Daten, die auf einem Server vorgehalten werden.
- Web-APIs als „Datensuchmaschinen“: Man stellt eine Anfrage für spezifische Daten, die API antwortet.
- Viele beliebte Webdienste bieten APIs an (Google, Twitter, Wikipedia, ...).
- Oft stellen APIs Daten in den Formaten JSON oder XML bereit (kann aber jedes beliebige Format sein).



`Credit` Brian Cooksey

Konzepte

- **Server:** Ein Computer, auf dem eine API läuft und mit dem gesprochen werden kann.
- **Client:** Ein Programm, das über eine API Daten mit einem Server austauscht.
- **Protocol:** Das Regelwerk, das der Kommunikation zwischen Computern zugrunde liegt (z. B. HTTP).
- **Method:** Die „Verben“, die Clients verwenden, um mit einem Server zu kommunizieren (in der HTTP-Sprache: `GET`, `POST` und andere).
- **Enpoint:** URLs, die auf eine bestimmte Weise angegeben werden können, um die API abzufragen.
- **Request:** Die Anfrage des Clients an den Server (siehe Methoden oben).
- **Response:** Die Antwort des Servers. Enthält *Statuscode* (z. B. „200“, „404“), *Header* (Meta-Info) und *Body* (der eigentliche Inhalt).

Was macht APIs attraktiv?

Wichtige Vorteile

- APIs bieten unmittelbaren Zugang zu "sauberen" Daten.
- Machen manuelle konstruierte Scraper potentielle überflüssig.
- Sie erleichtern einem Computer die Interaktion mit Daten auf dem Server.
- Die Verwendung von APIs setzt ein gegenseitiges Einverständnis mit der Datenerfassung voraus.



Restaurant-Analogie[1]

Restaurant	Web API
Ihr als Kunde	Euer Programm/Computer
Das Restaurant	API-Anbieter
Der Kellner	API-Frontend
Die Speisekarte	API-Dokumentation
Eure Bestellung	API-Enpoint (Request)
Die Küche	API-Datenbank
Das Essen	API-Response
Die Rechnung	API-Pricing

[1] Restaurant-Beispiel inspiriert von Jason Johl

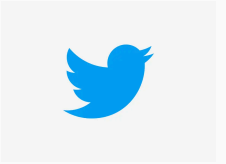
Warum stellen Organisationen APIs bereit?

Skalierbarkeit und Regulierung des Zugangs

- APIs erlauben einen skalierbaren Zugriff auf Daten und Dienste.
- Mit APIs können Organisationen ihren Kunden eine geregelte und strukturierte Möglichkeit bieten, gezielt Datenmengen abzurufen ohne ihre Server zu überlasten, zum Absturz zu bringen oder ihre Nutzungsbedingungen zu verletzen.
- APIs können auch dazu beitragen, die Sicherheit zu erhöhen, indem sie den Zugriff auf sensible Daten kontrollieren und überwachen.

Weitere Gründe

- **Monetarisierung:** Daten können in ein verkaufbares Produkt umgewandelt werden.
- **Innovation:** Kunden haben Zugang zu Daten und können ihre eigenen Produkte und Lösungen entwickeln.
- **Expansion:** APIs können Unternehmen helfen, in andere Märkte vorzudringen oder Partnerschaften mit anderen Unternehmen einzugehen.











Weiterführende Informationen zu Web APIs

APIs als Goldstandard der Web-Datenabfrage

Das Sammeln von Daten aus dem Web unter Verwendung von APIs, die vom Dateneigentümer zur Verfügung gestellt werden, stellt den **Goldstandard der Web-Datenabfrage** dar. Sie ermöglicht eine saubere Datenerfassung, einen standardisierten Datenzugriff, eine faktische Übereinkunft zur Datenerfassung sowie die Robustheit und Skalierbarkeit der Datenerfassung.

Auf der anderen Seite ist die Verbreitung von Web-APIs zulasten eines offenen Web nicht unproblematisch. Sie schafft Abhängigkeiten von API-Anbietern. APIs haben zwar das Potenzial, den Datenzugriff zu demokratisieren, können aber auch dazu beitragen, Informationen zu isolieren.

Mehr Informationen finden sich in dieser Einführung in APIs oder diesem Einführungsvideo zu APIs in R.

API-Ressourcen

Es gibt viele Ressourcen, die einen Überblick über bestehende öffentliche APIs geben, einschließlich dieser Liste öffentlicher APIs auf GitHub. Eine weitere nützliche Ressource ist APIs for social scientists - a collaborative review.

APIs in der deutschen Verwaltung: Daten nach außen

Offene Daten per API: inzwischen Pflicht, nicht Kür

- Die EU-Durchführungsverordnung zu hochwertigen Datensätzen (2023/138, anwendbar seit Juni 2024) verlangt für sechs Kategorien (Georaum, Umwelt, Meteorologie, Statistik, Unternehmen, Mobilität): **maschinenlesbar, kostenfrei, offene Lizenz, über eine API** mit Dokumentation und Kontaktstelle. In Deutschland umgesetzt über § 9 Datennutzungsgesetz. Neue Erhebungspflichten entstehen nicht: Es geht um Daten, die schon da sind.
- GovData als Metadatenkatalog: rund 170.000 Datensätze, davon rund 19.000 als hochwertig gekennzeichnet. Die Verteilung ist schief: einzelne Länder liefern Tausende, andere fast nichts.

Beispiele, die Ihr mglw. schon kennt oder wir diskutieren werden

- **Pegelonline** (Wasserstraßen- und Schifffahrtsverwaltung), **GENESIS** (Destatis), **DWD Open Data**, **XRepository** (KoSIT), **Mobilithek** (BMV), **Ladesäulenregister** (Bundesnetzagentur), **DIP** (Bundestag).

Das Symptom: bund.dev

- Das „Entwicklungsportal des Bundes“ dokumentiert rund 50 Schnittstellen von Bundesbehörden im OpenAPI-Format, von der Autobahn-API bis zur Zoll-API. Es wird aber **nicht vom Bund betrieben**, sondern ehrenamtlich von der Gruppe bundesAPI um Lilith Wittmann (heise 2021). Der IT-Planungsrat stellte 2025 fest: Außer dem FITKO-Entwicklungsportal gibt es kein zentrales Verzeichnis der Verwaltungs-APIs.

Take-aways für Euch als Nutzer und Anbieter von APIs

Als Nutzer fremder APIs

1. **Verlässlichkeit**: Wer betreibt die API, gibt es Nutzungsbedingungen, Versionierung und eine Ankündigungsfrist für Änderungen?
2. **Rechte**: Lizenz der Daten (Datenlizenz Deutschland, CC BY), Zweckbindung bei personenbezogenen Daten, Protokollierung der Abrufe.
3. **Betrieb**: Wer im Haus pflegt den Abruf, wenn die Person wechselt, die das Skript geschrieben hat?

Als Anbieter eigener APIs

4. **Pflichten kennen**: Welche unserer Daten fallen unter die HVD-Verordnung oder das Datennutzungsgesetz? Welche Anträge müssen wir per FIT-Connect oder NOOTS annehmen können?
5. **Schnittstellen einkaufen**: Beim Kauf oder der Ausschreibung eines Fachverfahrens dokumentierte, offene APIs (OpenAPI, XÖV, FIT-Connect, Deutschland-Stack) verlangen. Nachträglich kann das teuer werden.
6. **Scraping als Warnsignal**: Wenn Unternehmen oder andere Behörden Eure Website scrapen, fehlt eine API. Das kostet beide Seiten und bricht bei jedem Relaunch.

✎ Eine API ist ein **Versprechen**: Dieser Datenzugang bleibt stabil, dokumentiert und zuständig. Das ist eine Organisationsentscheidung, für die Ihr einstehen könnt.