Der Daten-Lifecycle

Session 6: Informierter Konsum von Daten und Statistiken

Simon Munzert
Hertie School

Inhaltsverzeichnis

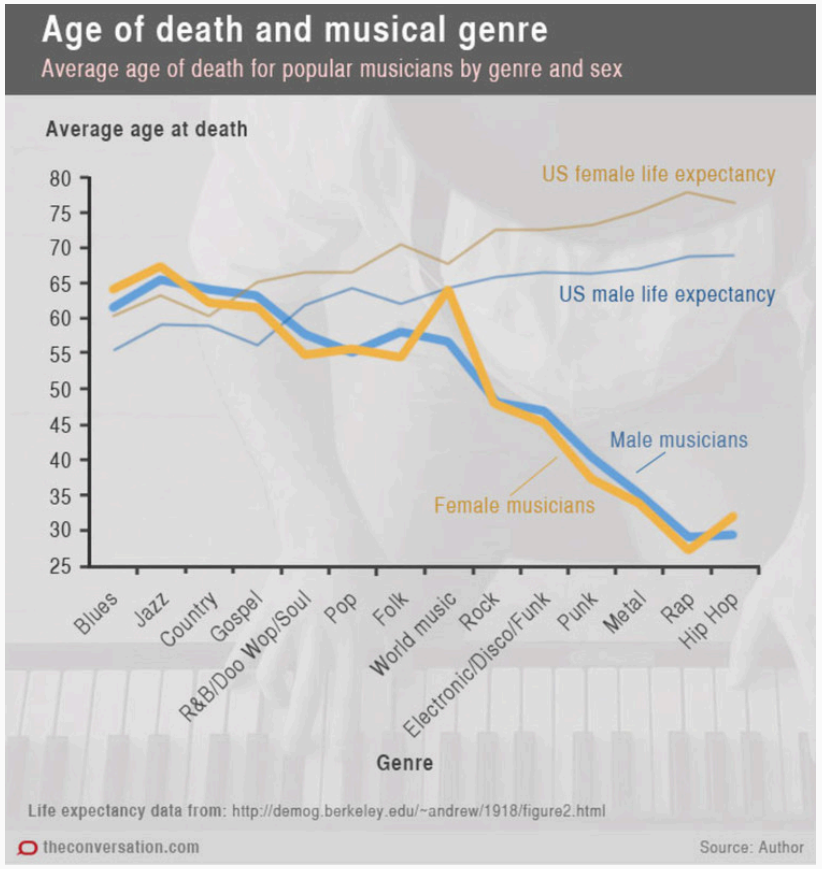
1. Warum statistische Kompetenz?

2. Wahrscheinlichkeit verstehen

3. Klassifikationsmetriken verstehen

Warum statistische Kompetenz?

Sind bestimmte Musikgenres tödlicher als andere?



`Quelle` The Conversation

`Hintergrund` Calling Bullshit

> [Study author Dianna Kenny] found that musicians from older genres – including blues, jazz, country and gospel – have similar lifespans to American people their own age. The life expectancy for R&B musicians is slightly lower, while the life expectancy for newer genres like rock, techno, punk, metal, rap and hip hop is significantly shorter."
>
> Ana Swanson, Washington Post

> "It's a cautionary tale to some degree," Kenny told the Washington Post. "People who go into rap music or hip hop or punk, they're in a much more occupational hazard profession compared to war. We don't lose half our army in a battle."
>
> Dianna Kenny, quoted by Washington Post

Weitere Evidenz

Cause of death by genre

Various causes of death for musicians of different genres

	Accidental	Suicide	Homicide	Heart-related	Cancer
% deaths per cause	19.5%	6.8%	6.0%	17.4%	23.4%
Blues	9.2%	2.0%	3.5%	28.0%	24.2%
Jazz	10.6%	2.7%	1.9%	20.7%	30.6%
Country	15.8%	4.7%	1.6%	23.5%	25.1%
Gospel	13.3%	0.9%	3.6%	18.5%	23.0%
R&B	11.5%	1.6%	5.0%	23.2%	26.8%
Pop	19.0%	6.4%	2.9%	16.4%	26.7%
Folk	15.9%	5.5%	4.4%	15.3%	32.3%
World music	12.7%	3.4%	9.6%	17.8%	19.9%
Rock	24.4%	7.2%	3.6%	15.4%	24.7%
Electronic	16.7%	5.0%	10.0%	15.0%	25.0%
Punk	30.0%	11.0%	8.2%	12.6%	18.3%
Metal	36.2%	19.3%	5.9%	11.0%	14.1%
Rap	15.9%	6.2%	51.0%	6.9%	7.6%
Hip Hop	18.3%	7.4%	51.5%	6.1%	6.1%

Red: significantly above the overall average rate for cause of death
Blue: above the overall average rate for cause of death
Green: significantly below the overall average rate for cause of death

Note: not all causes shown

theconversation.com Source: Author

Einige Probleme mit der Evidenz

1. **Sanity check:** Sind manche Genres wirklich so tödlich? Sterben z. B. Rap-Musiker wirklich mit einem Durchschnittsalter von ~30 Jahren?
2. **Datenzensierung:** Einige Genres sind jünger als andere, und die Auswertung setzt voraus, dass die Musiker bereits gestorben sind. Die meisten Rap- und Hip-Hop-Stars sind heute noch am Leben - Lebensdauer unbekannt!
3. **Bedingte Wahrscheinlichkeiten:** Die Wahrscheinlichkeiten der einzelnen Todesursachen hängen davon ab, dass der Tod zum Zeitpunkt der Untersuchung bereits eingetreten ist. 4) (Kleineres Problem) Liniendiagramm für kategoriale Daten? Keine gute Idee.

Lösung des Falles

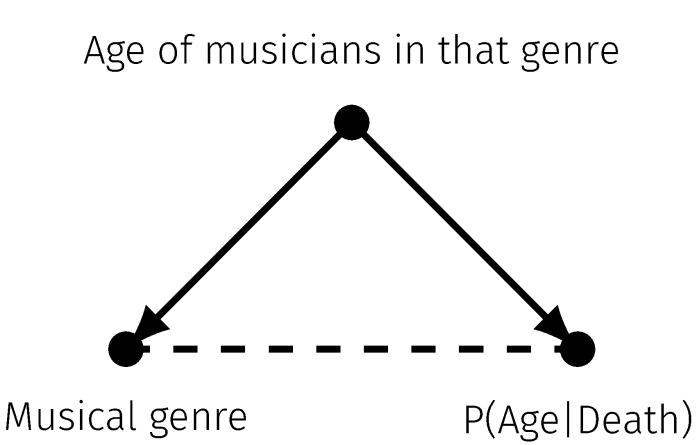
	Evidenz und Schlüsse
Der Tatort	Musikgenre korreliert mit Todesalter
Die Verdächtigen	Lifestyle (z.B. Drogenkonsum), Alter des Genres, unvollständige Datenerhebung
Die Tatwaffe	Konfundierung durch Daten-Zensur

> "In other words, it's not that rap stars will likely die young; it's that the rap stars who have died certainly died young because rap hasn't been around long enough for it to be otherwise."
>
> Carl Bergstrom and Jevin West, Calling Bullshit[1]

Inspector Lestrade:



Sherlock:



[1]Die Autorin Dianna Kenny hat mit einer plausiblen Antwort reagiert und auf eine besser designte Studie verwiesen, deren Evidenz konsistent mit den ursprünglichen Mustern zu sein scheint.

Wie gut ist ein Mammographie-Screening?

Szenario

Eine Frau ohne Symptome nimmt am Mammographie-Screening teil. Bekannt ist:

- Etwa **1%** der Frauen in dieser Altersgruppe haben Brustkrebs (Prävalenz).
- Hat eine Frau Brustkrebs, fällt der Test mit **90%** Wahrscheinlichkeit positiv aus (Sensitivität).
- Hat eine Frau keinen Brustkrebs, fällt der Test trotzdem mit **9%** Wahrscheinlichkeit positiv aus (Falsch-positiv-Rate).



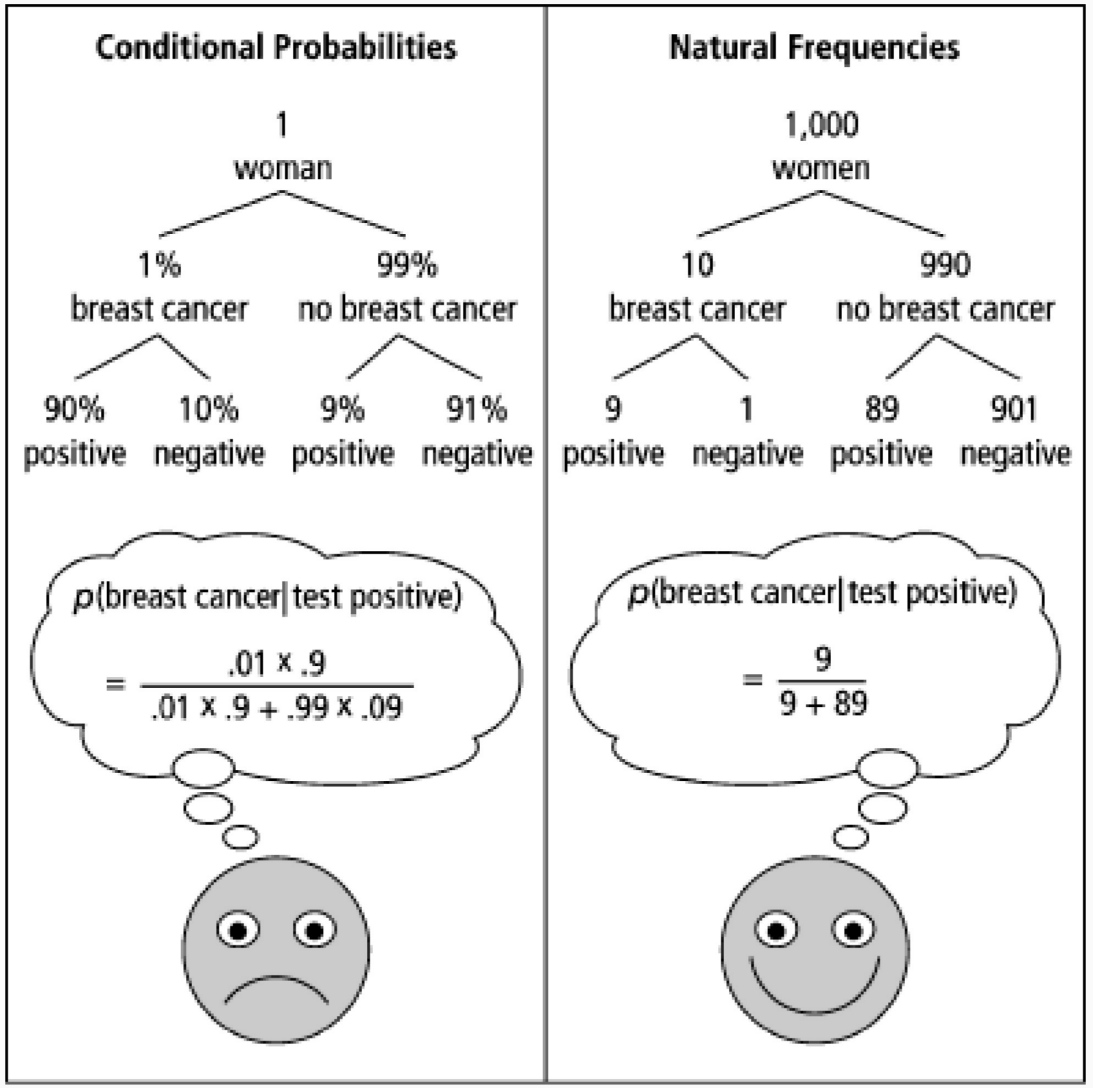
Mobile Mammographie-Einheit am Krankenhaus Lysekil, Schweden. `Quelle` W.carter, Wikimedia Commons, CC BY 4.0

Aufgabe

Der Befund ist positiv. Wie wahrscheinlich ist es, dass die Frau tatsächlich Brustkrebs hat?

✎ Schätzt zuerst intuitiv, dann rechnet.

Wie gut ist ein Mammographie-Screening?



Warum statistische Kompetenz?

Auch Profis scheitern daran

- Gigerenzer und Kollegen legten 160 Gynäkologinnen und Gynäkologen die Kennzahlen des Mammographie-Screenings vor (Prävalenz 1%, Sensitivität 90%, Falsch-positiv-Rate 9%) und fragten: Wie wahrscheinlich ist Brustkrebs bei positivem Befund?
- Richtig wären etwa **9%**. Die Mehrheit antwortete **81 bis 90%**; nur ein Fünftel lag richtig. Es ging um ihr eigenes Fachgebiet.
- Dieselbe Rechnung steckt in jedem KI-Alarm, jedem Betrugsscore, jedem Screening-Programm. Wer sie beherrscht, bewertet Systeme; wer nicht, glaubt Prospekten.

`Quelle` Gigerenzer et al. (2007), Psychological Science in the Public Interest

Zahlen sind das Medium Eurer Entscheidungen

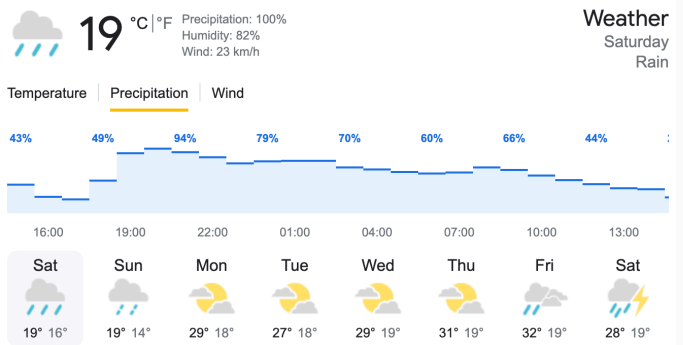
- Vorlagen, Evaluationen, Kennzahlen, Dashboards: Fast jede Entscheidung, die über Euren Tisch geht, stützt sich auf Zahlen, die jemand anderes erzeugt hat.
- Jedes KI-Angebot kommt mit einer Zahl: „95% Genauigkeit“, „Trefferquote 0,9“, etc. Ob das gut oder gefährlich ist, hängt von Fragen ab, die der Anbieter mglw. nicht beantwortet.

Wahrscheinlichkeit verstehen

Wahrscheinlichkeiten

Was sind Wahrscheinlichkeiten?[1]

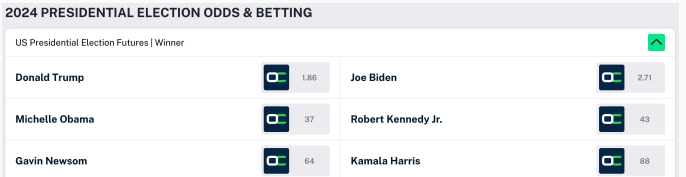
- Wahrscheinlichkeiten quantifizieren die Möglichkeit eines Ereignisses
- Wahrscheinlichkeiten liegen zwischen 0 und 1 (oder 0 und 100%)
- Wahrscheinlichkeiten können verbal oder numerisch kommuniziert werden

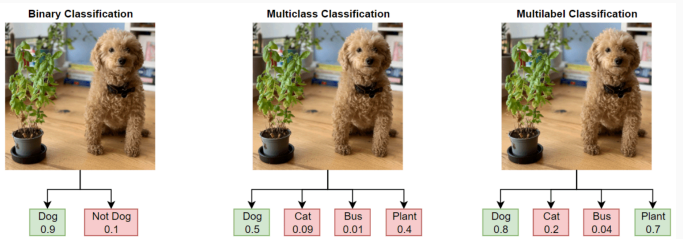


Relevanz von Wahrscheinlichkeiten für politische Entscheidungen

Wahrscheinlichkeiten sind ...

- ... das Kernstück der Risikobewertung und Entscheidungsfindung
- ... werden zur Quantifizierung von Unsicherheit verwendet
- ... zur Bewertung der Wirksamkeit von Maßnahmen
- ... eine Kernmetrik für AI-basierte Entscheidungssysteme





[1] Hier eine gute Einführung in die Wahrscheinlichkeitsrechnung und Simulation.

Marginale, bedingte und gemeinsame Wahrscheinlichkeiten

Randwahrscheinlichkeit

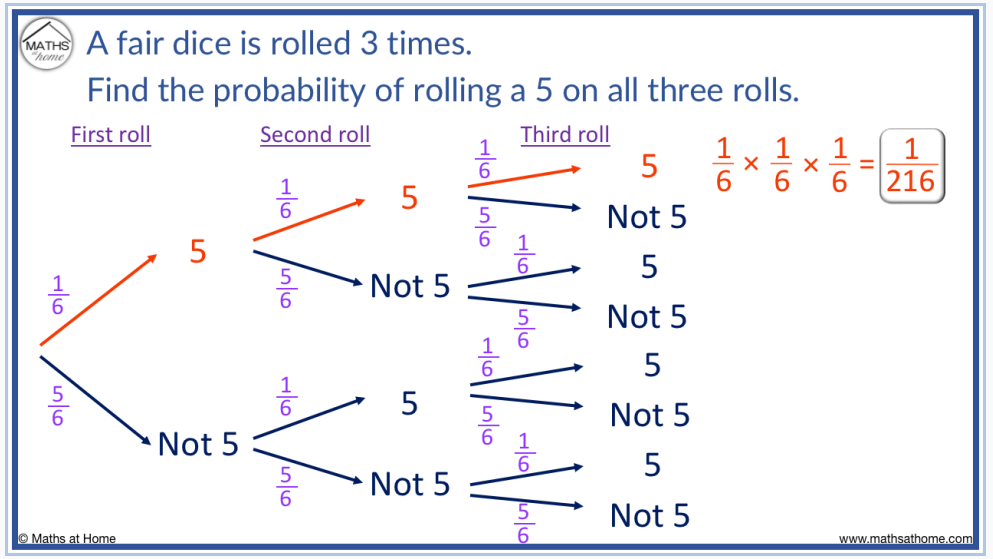
- Die Wahrscheinlichkeit des Eintretens eines Ereignisses: $p(A)$
- Unbedingte Wahrscheinlichkeit ist nicht von einem anderen Ereignis abhängig
- 🎲 Beispiel: $p(\text{Würfeln einer } 5) = 1/6$

Bedingte Wahrscheinlichkeit

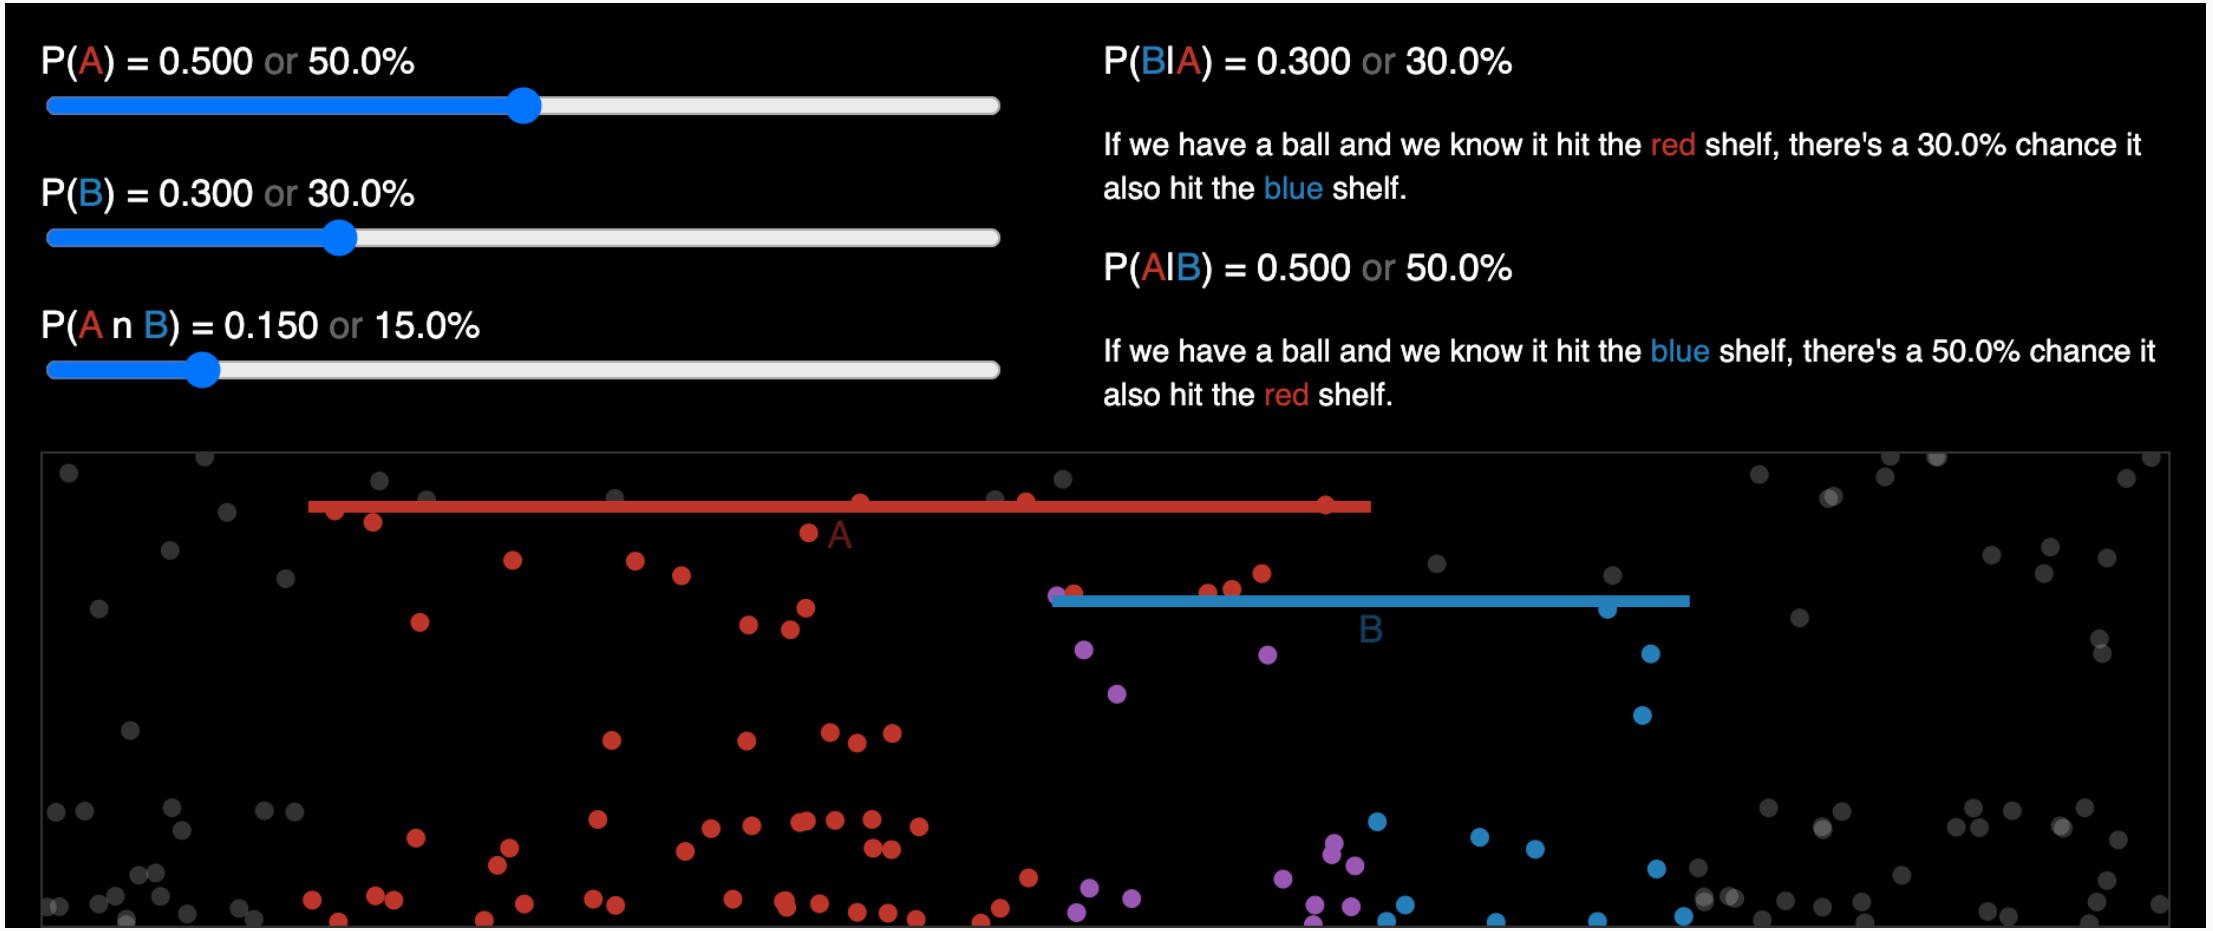
- Die Wahrscheinlichkeit, dass das Ereignis A eintritt, wenn das Ereignis B eintritt: $p(A|B)$
- Wichtig: Die Randwahrscheinlichkeit von B spielt hier keine Rolle!
- 🎲 Beispiel:
  $p(\text{Würfeln einer } 5 | \text{Würfeln ungerader Zahl}) = 1/3$

Gemeinsame Wahrscheinlichkeit

- Die Wahrscheinlichkeit, dass Ereignis A und Ereignis B eintreten: $p(\text{A und B}) = p(A \cap B)$
- 🎲 Beispiel:
  $p(\text{Würfeln einer } 5 \text{ und einer geraden Zahl}) = 0$



Bedingte Wahrscheinlichkeiten



`Quelle` Victor Powell, setosa.io (Siehe zur interaktiven Simulation)

Puzzle

Wie können alle der folgenden Punkte wahr sein?

1. Ein Impfstoff ist hochwirksam beim Schutz gegen eine Krankheit.
2. Die meisten Menschen, die die Krankheit bekommen, sind geimpft worden.



`Quelle` Hakan Nural, Unsplash

Puzzle

Wie können alle der folgenden Punkte wahr sein?

1. Ein Impfstoff ist hochwirksam beim Schutz gegen eine Krankheit.
2. Die meisten Menschen, die die Krankheit bekommen, sind geimpft worden.

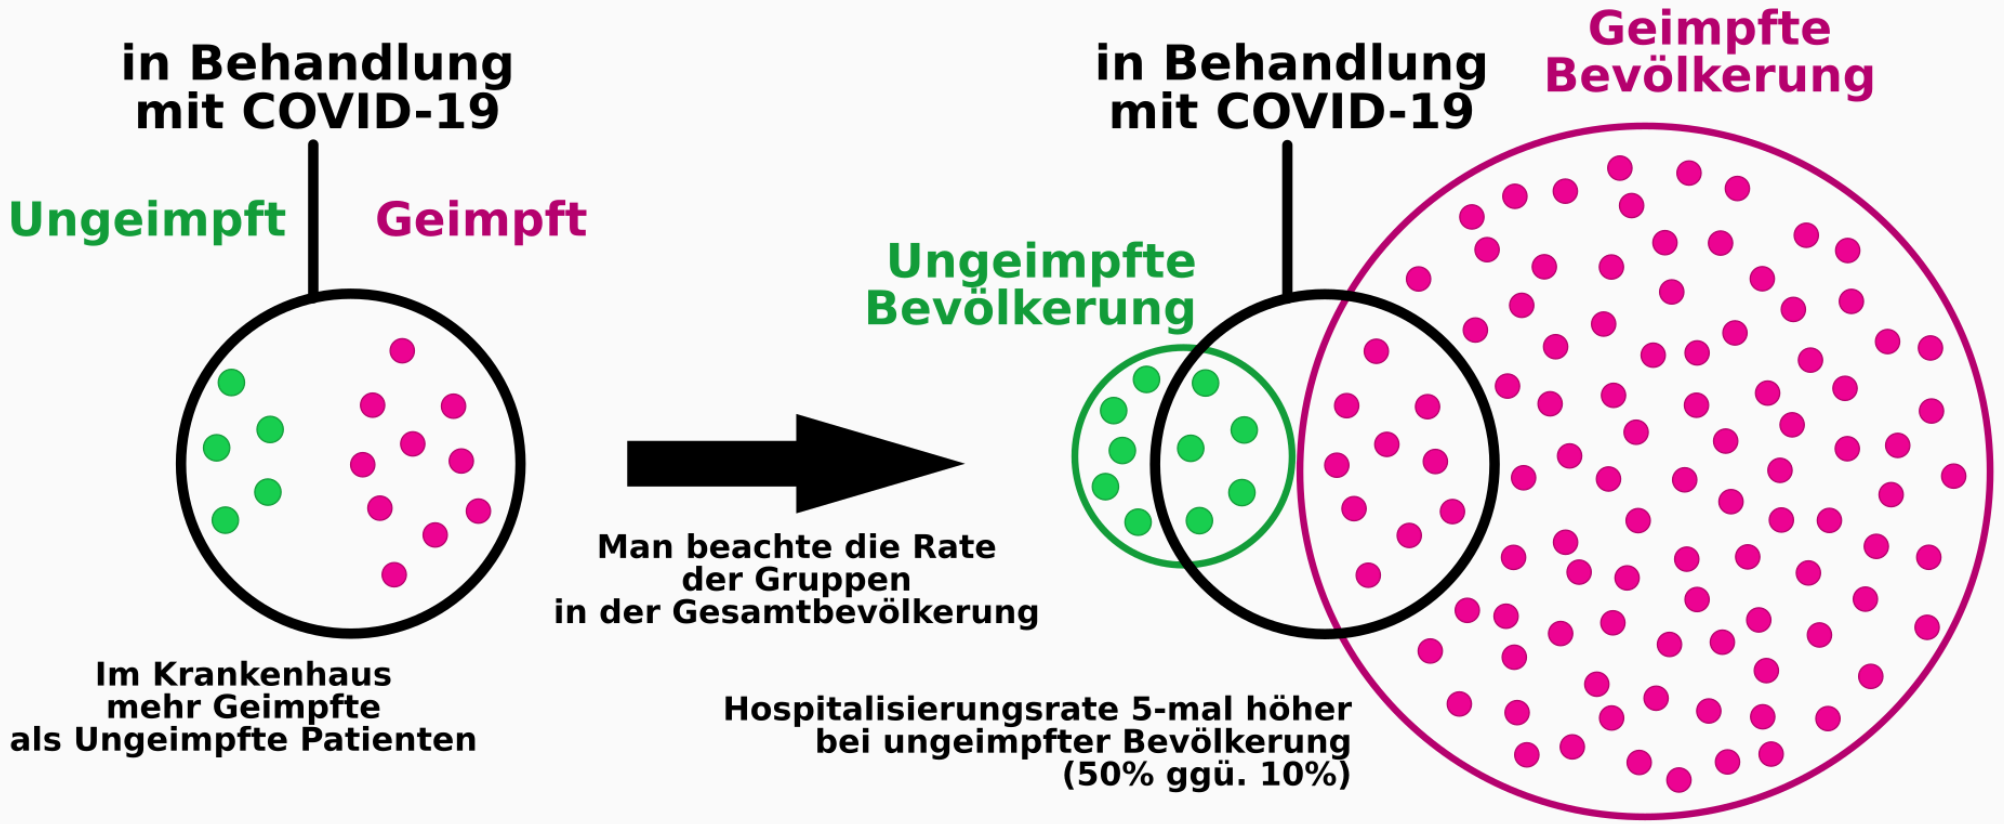
Base Rate Fallacy ("Prävalenzfehler")

- Dies ist ein klassischer Fall des „Base Rate Fallacy“ oder „Prosecutor's Fallacy“.
- Wenn die Impfrate $P(geimpft)$ in der Bevölkerung hoch ist, besteht eine möglicherweise höhere Chance, dass eine zufällig ausgewählte kranke Person (z.B. im Krankenhaus) geimpft als ungeimpft ist.



`Quelle` Hakan Nural, Unsplash

"Base rate fallacy", illustriert



`Quelle` Marc Rumilly

Relevanz für AI-basierte Entscheidungssysteme

Hertie School

Politik für seltene Ereignisse

- Diverse Politikmaßnahmen sind darauf ausgerichtet, seltene und gleichzeitig extrem kostspielige Ereignisse zu verhindern.
- Beispiele: Terroranschläge, Krieg, Naturkatastrophen
- Die Vorhersage solcher Ereignisse ist von Natur aus schwierig.
- KI-gestützte Erkennungssysteme versprechen hohe Erkennungsraten. Aber selbst bei einer sehr hohen Genauigkeit kann die Anzahl der falsch-positiven Meldungen inakzeptabel hoch sein.

Leitfaden

- Berücksichtigt bei der Evaluation von solchen Tools immer die **Basiswahrscheinlichkeit**.
- Wählt geeignete Performanzmetriken (FPR, FNR, etc. - mehr dazu später).

Beispiel: Terrorismuserkennung

- In einer Stadt mit 1 Mio. Einwohnern gibt es 100 Terroristen und 999.900 Nicht-Terroristen:
  $p(\text{Terrorist}) = 0,0001$
- Überwachung mit Gesichtserkennungssoftware mit zwei Fehlerquoten von 1%:
  1. Falsch-negativ-Rate (FNR):
     $p(\text{kein Alarm}|\text{Terrorist}) = 0,01$
  2. Falsch-positiv-Rate (FPR):
     $p(\text{Alarm}|\text{kein Terrorist}) = 0.01$

Was bedeutet das, wenn wir einen Alarm erhalten?[1]

$$p(\text{Terrorist}|\text{Alarm}) = \frac{p(\text{Alarm}|\text{Terrorist})p(\text{Terrorist})}{p(\text{Alarm})}$$
$$= \frac{0.99*0.0001}{0.01} = 0.01$$

[1] $p(\text{Alarm}) = p(\text{Alarm}|\text{Terrorist})*p(\text{Terrorist})$ `
$+p(\text{Alarm}|\text{Nicht-Terrorist}) * p(\text{Nicht-Terrorist}) = p(\text{Terrorist}|\text{Alarm})$
$= 0.99 * 0.0001 + 0.01 * 0.9999 = 0.01$`

Kommunikation von Wahrscheinlichkeiten mit verbalen Ausdrücken

JCOM

Variability in the interpretation of probability phrases used in Dutch news articles — a risk for miscommunication

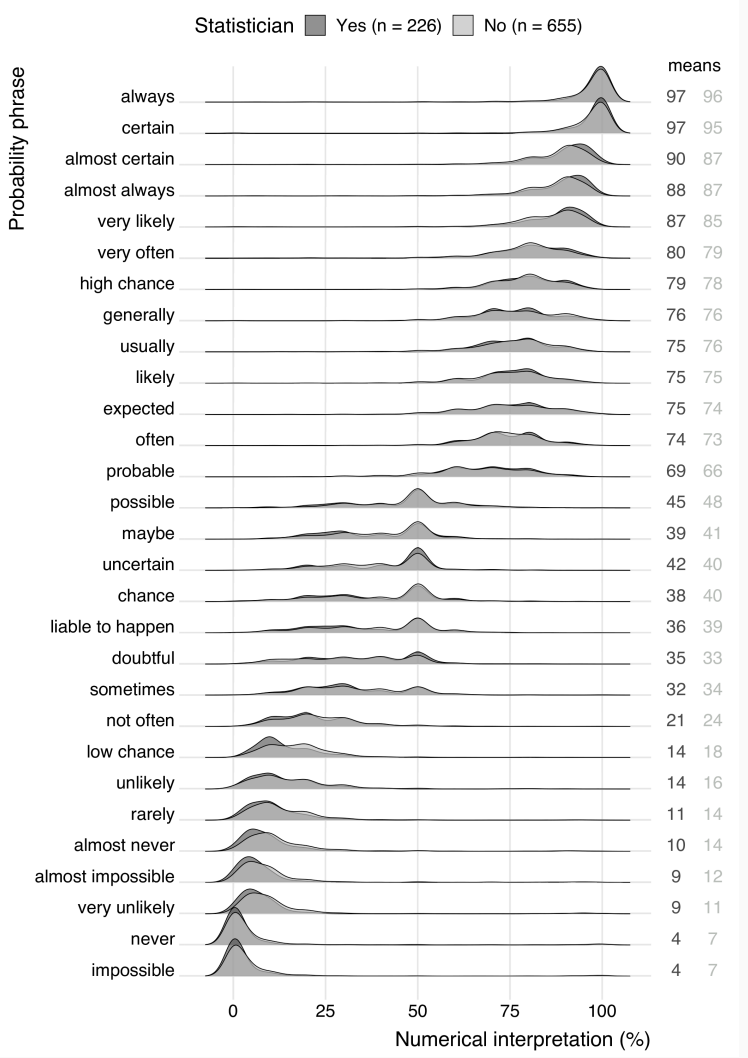
Sanne Willems, Casper Albers and Ionica Smeets

Abstract

Verbal probability phrases are often used in science communication to express estimated risks in words instead of numbers. In this study we look at how laypeople and statisticians interpret Dutch probability phrases that are regularly used in news articles. We found that there is a large variability in interpretations, even if the phrases are given in a neutral context. Also, statisticians do not agree on the interpretation of the phrases. We conclude that science communicators should be careful in using verbal probability expressions.

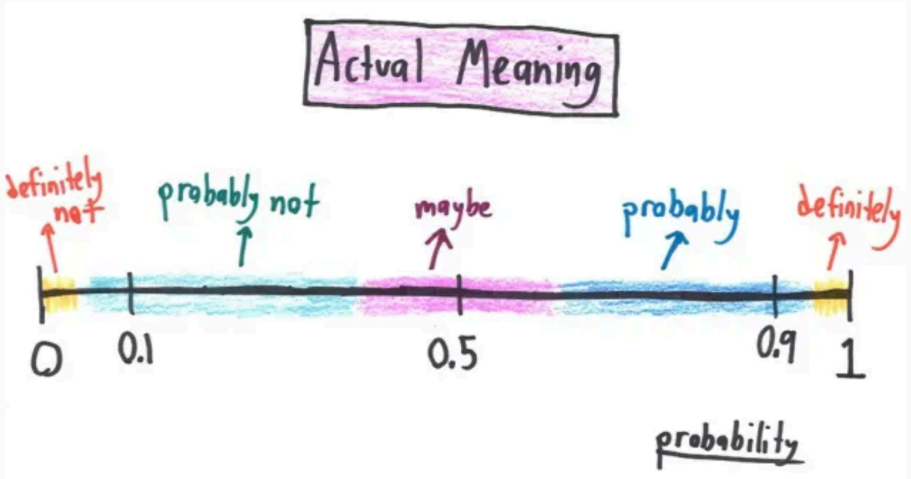
Keywords Risk communication; Science and media; Science writing

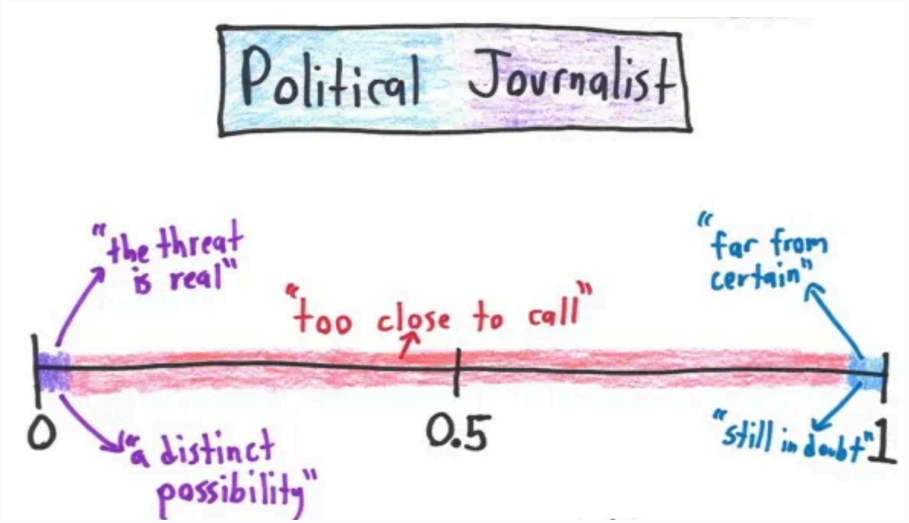
`Quelle` Willems et al. 2020



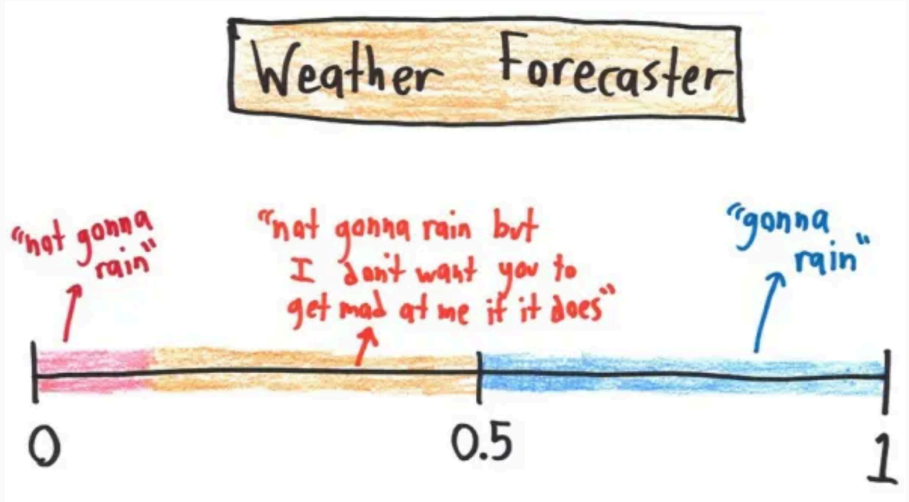
Was bedeutet die Wahrscheinlichkeit für verschiedene Berufe?

Hertie School









Quelle Ben Orlin

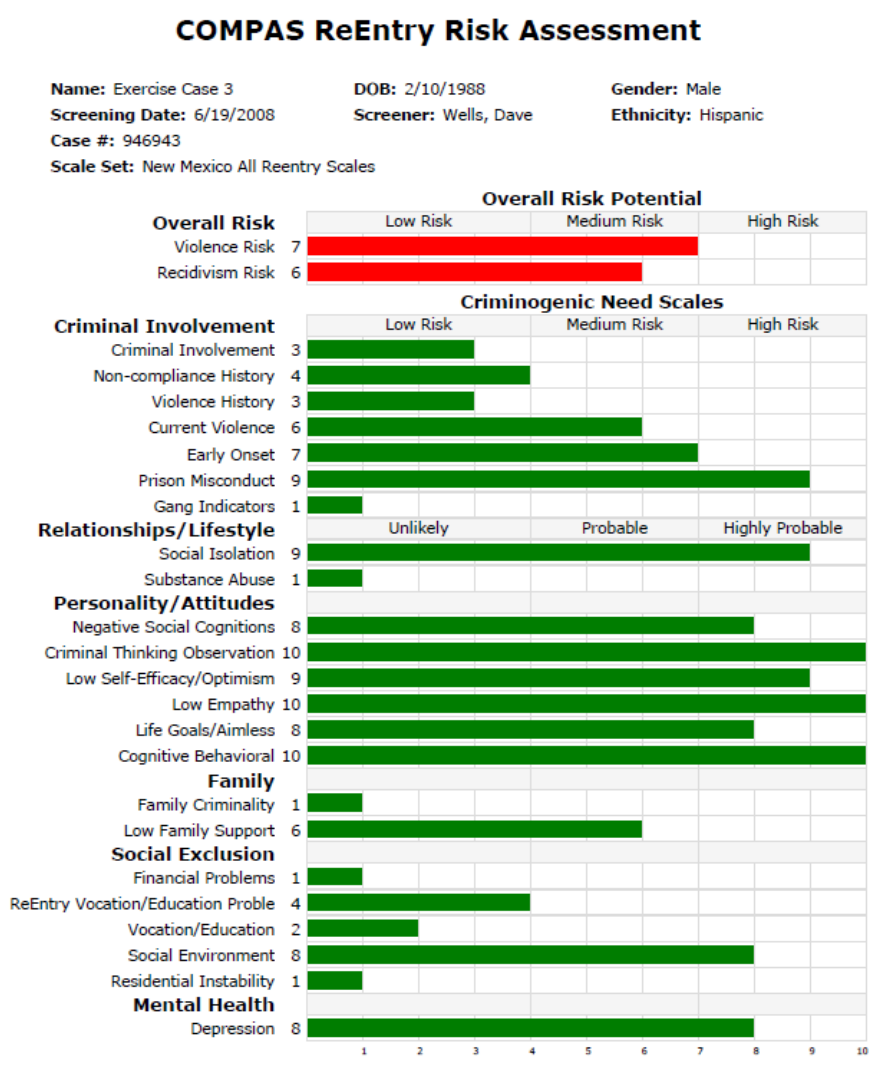
Klassifikationsmetriken verstehen

Vorhersage der Rückfälligkeit von Straftätern

Hertie School

Hintergrund

- Correctional Offender Management Profiling for Alternative Sanctions (COMPAS) ist ein von Northpointe (jetzt Equivant) entwickeltes Entscheidungshilfeinstrument, das von US-Gerichten zur **Bewertung der Rückfallwahrscheinlichkeit** eingesetzt wird.
- Erstellt mehrere Skalen (Risiko der vorzeitigen Entlassung, allgemeine Rückfälligkeit, gewalttätige Rückfälligkeit) auf der Grundlage von Faktoren wie Alter, Vorstrafen und Drogenmissbrauch
- Der Algorithmus ist urheberrechtlich geschützt und seine inneren Abläufe sind nicht öffentlich.

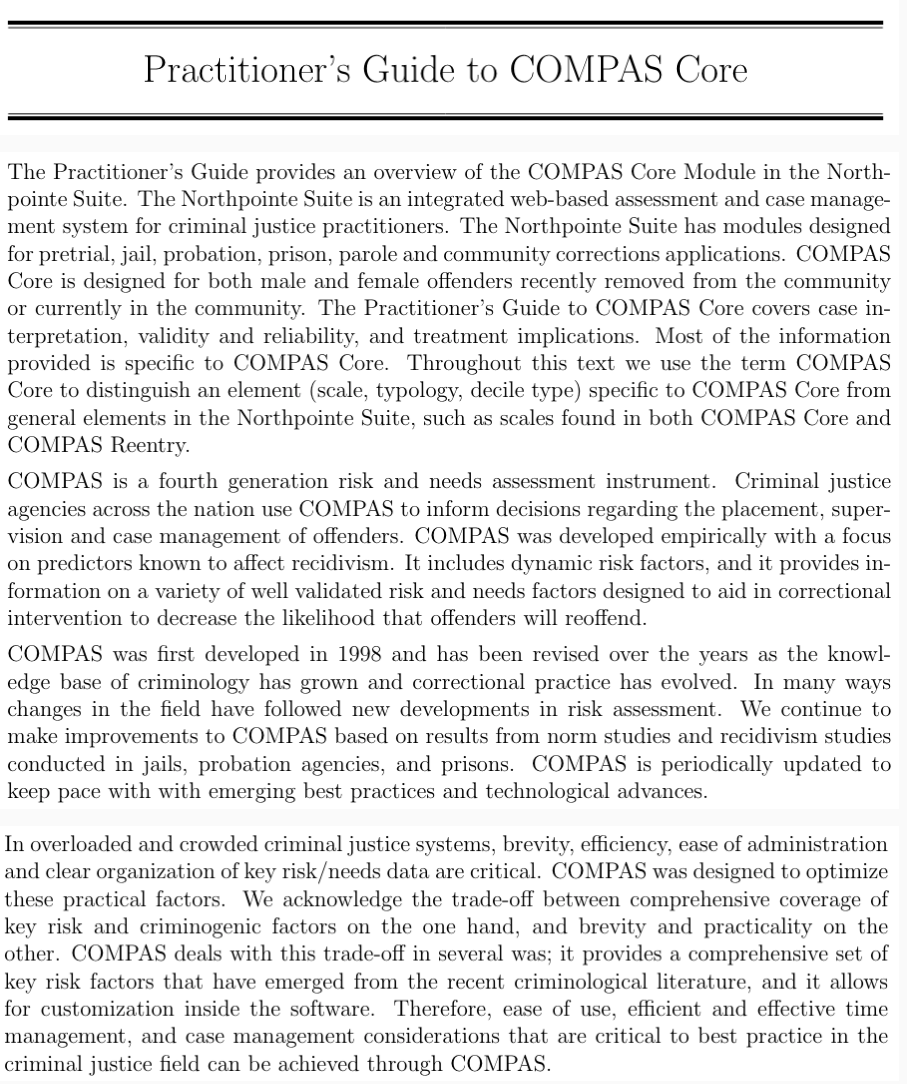


`Quelle` Leitfaden für Praktiker zum COMPAS Core

Vorhersage der Rückfälligkeit von Straftätern

Hintergrund

- Correctional Offender Management Profiling for Alternative Sanctions (COMPAS) ist ein von Northpointe (jetzt Equivant) entwickeltes Entscheidungshilfeinstrument, das von US-Gerichten zur **Bewertung der Rückfallwahrscheinlichkeit** eingesetzt wird.
- Erstellt mehrere Skalen (Risiko der vorzeitigen Entlassung, allgemeine Rückfälligkeit, gewalttätige Rückfälligkeit) auf der Grundlage von Faktoren wie Alter, Vorstrafen und Drogenmissbrauch
- Der Algorithmus ist urheberrechtlich geschützt und seine inneren Abläufe sind nicht öffentlich.



Practitioner's Guide to COMPAS Core

The Practitioner's Guide provides an overview of the COMPAS Core Module in the Northpointe Suite. The Northpointe Suite is an integrated web-based assessment and case management system for criminal justice practitioners. The Northpointe Suite has modules designed for pretrial, jail, probation, prison, parole and community corrections applications. COMPAS Core is designed for both male and female offenders recently removed from the community or currently in the community. The Practitioner's Guide to COMPAS Core covers case interpretation, validity and reliability, and treatment implications. Most of the information provided is specific to COMPAS Core. Throughout this text we use the term COMPAS Core to distinguish an element (scale, typology, decile type) specific to COMPAS Core from general elements in the Northpointe Suite, such as scales found in both COMPAS Core and COMPAS Reentry.

COMPAS is a fourth generation risk and needs assessment instrument. Criminal justice agencies across the nation use COMPAS to inform decisions regarding the placement, supervision and case management of offenders. COMPAS was developed empirically with a focus on predictors known to affect recidivism. It includes dynamic risk factors, and it provides information on a variety of well validated risk and needs factors designed to aid in correctional intervention to decrease the likelihood that offenders will reoffend.

COMPAS was first developed in 1998 and has been revised over the years as the knowledge base of criminology has grown and correctional practice has evolved. In many ways changes in the field have followed new developments in risk assessment. We continue to make improvements to COMPAS based on results from norm studies and recidivism studies conducted in jails, probation agencies, and prisons. COMPAS is periodically updated to keep pace with with emerging best practices and technological advances.

In overloaded and crowded criminal justice systems, brevity, efficiency, ease of administration and clear organization of key risk/needs data are critical. COMPAS was designed to optimize these practical factors. We acknowledge the trade-off between comprehensive coverage of key risk and criminogenic factors on the one hand, and brevity and practicality on the other. COMPAS deals with this trade-off in several was; it provides a comprehensive set of key risk factors that have emerged from the recent criminological literature, and it allows for customization inside the software. Therefore, ease of use, efficient and effective time management, and case management considerations that are critical to best practice in the criminal justice field can be achieved through COMPAS.

`Quelle` Leitfaden für Praktiker zum COMPAS Core

Die ProPublica und andere Untersuchungen

- Im Jahr 2016 veröffentlichte ProPublica eine Untersuchung, die zeigte, dass COMPAS **voreingenommen gegenüber Afroamerikanern** war
- **Bias:** Der Algorithmus sagte bei Afroamerikanern mit höherer Wahrscheinlichkeit falsch voraus, dass Angeklagte wieder straffällig werden würden.
- **Mangelnde Präzision:** Nur 20 % der Personen, denen Gewaltverbrechen vorhergesagt wurden, wurden tatsächlich straffällig (in einer späteren Studie wurde der Wert auf 65 % geschätzt - schlechter als eine Gruppe von Nicht-Experten)

`Quelle` ProPublica 2016



Machine Bias*

Julia Angwin, Jeff Larson, Surya Mattu, and Lauren Kirchner

There's software used across the country to predict future criminals. And it's biased against blacks.

ON A SPRING AFTERNOON IN 2014, Brisha Borden was running late to pick up her god-sister from school when she spotted an unlocked kid's blue Huffy bicycle and a silver Razor scooter. Borden and a friend grabbed the bike and scooter and tried to ride them down the street in the Fort Lauderdale suburb of Coral Springs.

Just as the 18-year-old girls were realizing they were too big for the tiny conveyances—which belonged to a 6-year-old boy—a woman came running after them saying, "That's my kid's stuff." Borden and her friend immediately dropped the bike and scooter and walked away.

But it was too late—a neighbor who witnessed the heist had already called the police. Borden and her friend were arrested and charged with burglary and petty theft for the items, which were valued at a total of $80.

Compare their crime with a similar one: The previous summer, 41-year-old Vernon Prater was picked up for shoplifting $86.35 worth of tools from a nearby Home Depot store (Figure 6.1.1).

Prater was the more seasoned criminal. He had already been convicted of armed robbery and attempted armed robbery, for which he served five years in prison, in addition to another armed robbery charge. Borden had a record, too, but it was for misdemeanors committed when she was a juvenile.

Yet something odd happened when Borden and Prater were booked into jail: A computer program spat out a score predicting the likelihood of each committing a future crime. Borden—who is black—was rated a high risk. Prater—who is white—was rated a low risk.

Two years later, we know the computer algorithm got it exactly backward. Borden has not been charged with any new crimes. Prater is serving an eight-year prison term for subsequently breaking into a warehouse and stealing thousands of dollars' worth of electronics.

Scores like this—known as risk assessments—are increasingly common in courtrooms across the nation. They are used to inform decisions about who can be set free at every stage of the criminal justice system, from assigning bond amounts—as is the case in Fort Lauderdale—to

* Julia Angwin, Jeff Larson, Surya Mattu, Lauren Kirchner, "Machine Bias," *ProPublica* (May 23, 2016). Reprinted with permission.

254 DOI: 10.1201/9781003278290-37

Vorhersage der Rückfälligkeit von Straftätern

Die ProPublica und andere Untersuchungen

- Im Jahr 2016 veröffentlichte ProPublica eine Untersuchung, die zeigte, dass COMPAS **voreingenommen gegenüber Afroamerikanern** war
- **Bias:** Der Algorithmus sagte bei Afroamerikanern mit höherer Wahrscheinlichkeit falsch voraus, dass Angeklagte wieder straffällig werden würden.
- **Mangelnde Präzision:** Nur 20 % der Personen, denen Gewaltverbrechen vorhergesagt wurden, wurden tatsächlich straffällig (in einer späteren Studie wurde der Wert auf 65 % geschätzt - schlechter als eine Gruppe von Nicht-Experten)

`Quelle` Dressel and Fair, 2018, Science Advances

SCIENCE ADVANCES | RESEARCH ARTICLE

RESEARCH METHODS

The accuracy, fairness, and limits of predicting recidivism

Julia Dressel and Hany Farid*

Algorithms for predicting recidivism are commonly used to assess a criminal defendant's likelihood of committing a crime. These predictions are used in pretrial, parole, and sentencing decisions. Proponents of these systems argue that big data and advanced machine learning make these analyses more accurate and less biased than humans. We show, however, that the widely used commercial risk assessment software COMPAS is no more accurate or fair than predictions made by people with little or no criminal justice expertise. In addition, despite COMPAS's collection of 137 features, the same accuracy can be achieved with a simple linear predictor with only two features.

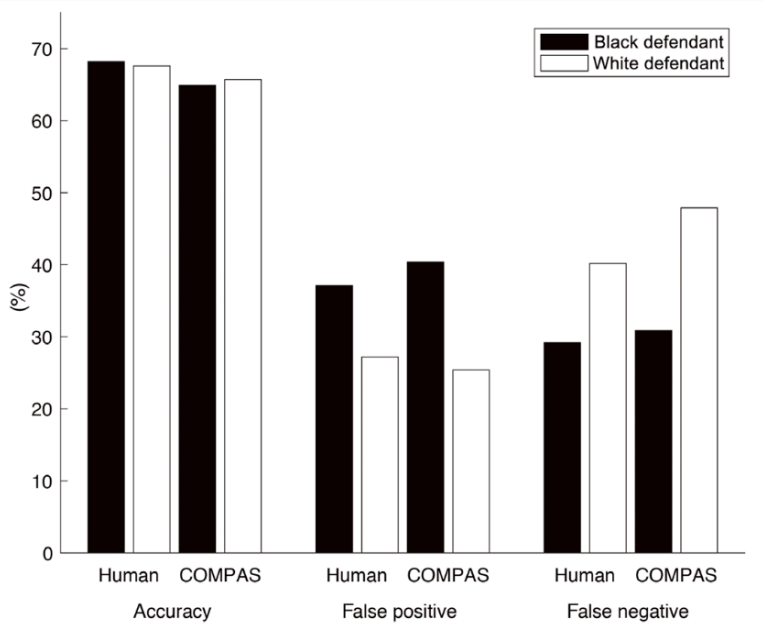


Fig. 1. Human (no-race condition) versus COMPAS algorithmic predictions (see also Table 1).

Klassifizierungsprobleme in freier Wildbahn

Klassifizierungsprobleme sind weit verbreitet (wahrscheinlich häufiger als Regressionsprobleme). **Beispiele:**

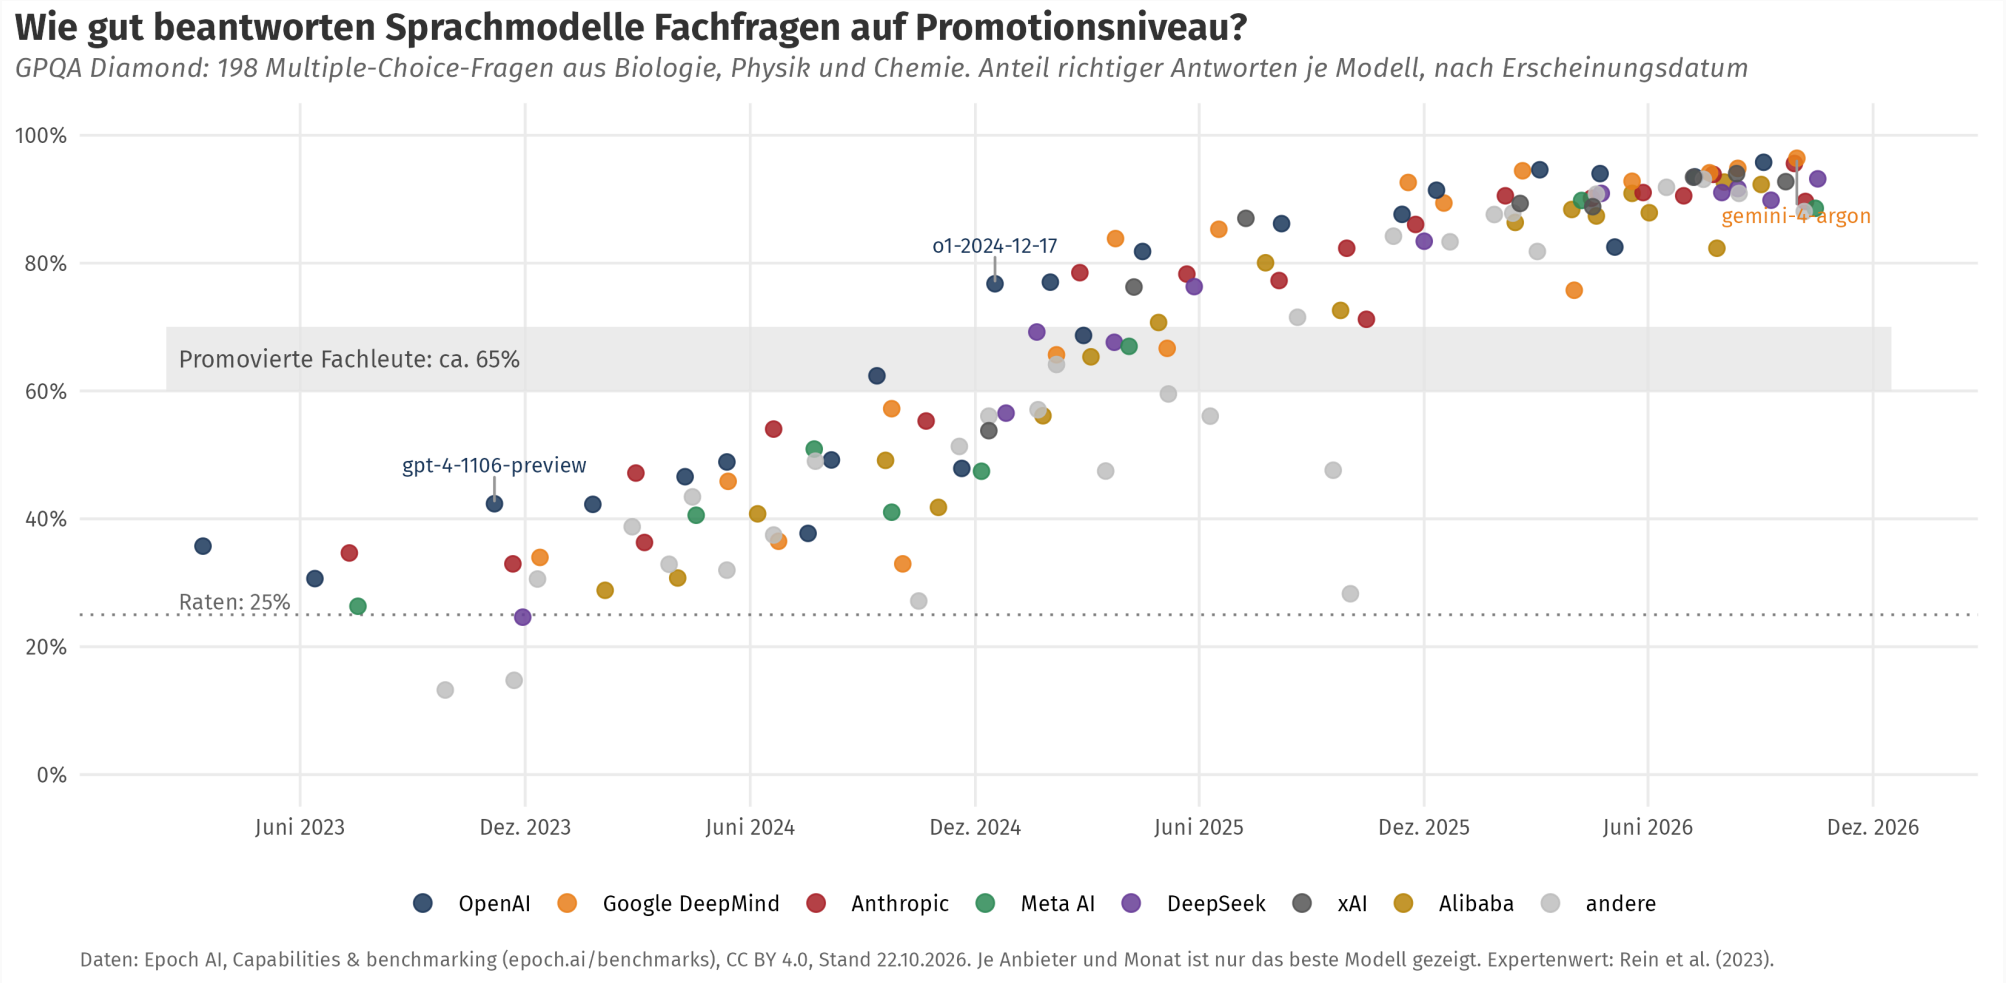
1. Eine Frau kommt mit einer Reihe von Symptomen in die Notaufnahme. Welche Krankheit hat sie?
2. Ein Online-Banking-Dienst muss in der Lage sein, anhand der IP-Adresse des Benutzers, seiner bisherigen Transaktionen usw. festzustellen, ob eine Transaktion betrügerisch ist oder nicht.
3. Eine Biologin möchte anhand der DNA-Sequenzdaten einer Reihe von Patienten mit und ohne eine bestimmte Krankheit herausfinden, welche DNA-Mutationen schädlich (krankheitsverursachend) sind und welche nicht.
4. Ein Moderator einer Social-Media-Plattform muss entscheiden, ob ein von einem Nutzer erstellter Beitrag als unangemessen gekennzeichnet werden soll oder nicht.

Automatisierte Entscheidungsfindung

Entscheidungsfindungsprobleme sind oft Klassifizierungsprobleme!

Wenn automatisierte Systeme zur Entscheidungsfindung eingesetzt werden, beruhen sie häufig auf Klassifizierungsmodellen. Ob sie als rechtmäßig angesehen werden oder nicht, hängt oft entscheidend von der Leistung dieser Modelle ab.

ML-Performanz-Benchmarking: Beispiel



`Quelle` Eigene Darstellung nach Epoch AI, Capabilities & benchmarking (CC BY 4.0), Stand 22.10.2026. GPQA Diamond: Rein et al. (2023).

ML-Performanz-Benchmarking: Beispiel

Dataset	Characteristics	Moderation Service	ACC	AUC	F1	FPR	FNR
ToxiGen [40]	Implicit / Synthetic: 7,800 samples	Amazon	70.4%	79.2%	68.9%	7.2%	51.9%
		Google	62.7%	65.0%	62.7%	39.1%	35.5%
		OpenAI	70.3%	87.2%	68.1%	5.6%	33.2%
		Microsoft	59.8%	67.0%	57.4%	16.4%	63.9%
		Perspective	61.6%	82.9%	55.5%	1.2%	75.4%
Civil Comments [11]	Explicit / Long: 50,000 samples	Amazon	92.2%	97.4%	92.2%	7.5%	8.1%
		Google	69.9%	67.4%	67.2%	58.4%	1.8%
		OpenAI	78.6%	86.9%	78.6%	17.1%	25.6%
		Microsoft	75.8%	81.7%	75.7%	20.4%	28.1%
		Perspective	87.8%	97.2%	87.7%	3.3%	20.9%
HateXplain [59]	Explicit / Short 14,000 samples	Amazon	70.2%	75.1%	69.9%	44.2%	20%
		Google	66.4%	52.2%	58.9%	76.8%	4%
		OpenAI	78%	87.3%	77.2%	41.1%	8.86%
		Microsoft	69%	66.5%	66.6%	61.2%	10.3%
		Perspective	70.6%	70.2%	75.1%	42.3 %	20.6%
SBIC [90]	Implicit / Real: 33,000 samples	Amazon	80.1%	72.7%	80.6%	12.9%	25.1 %
		Google	64.4%	66.2%	63.4%	50.34%	22.39%
		OpenAI	67.4%	81.1%	65.9%	9%	53.4%
		Microsoft	62.7%	68.1%	62.7%	32%	42%
		Perspective	60.1%	73.9%	60%	21.8%	55%

Table 2: Performance metrics by moderation service and dataset. Blue shading signals the best performance, while red shading indicates the worst performance. All datasets are balanced on toxic and non-toxic phrases.

`Quelle` Hartmann, Oueslati, Staufer, Pohlmann, Munzert und Heuer (2025): Lost in Moderation. Proceedings of the 2025 CHI Conference, Tabelle 2.

Bestimmung der Performanz eines binären Klassifizierers

Hertie School

Accuracy ("Korrektklassifizierungsrate")

- Accuracy = $\frac{\text{Anzahl der richtigen Vorhersagen}}{\text{Gesamtzahl der Vorhersagen}} = \frac{TP+TN}{TP+TN+FP+FN}$
- Falschklassifikationsrate: $1 - \text{Accuracy}$

Nützlichkeit

- Die Accuracy ist eine einfache und intuitive Metrik.
- Sie kann jedoch irreführend sein, insbesondere in unausgewogenen Datensätzen, in denen die Klassen nicht gleichmäßig vertreten sind.
- Beispiel: In einem Datensatz mit 90% der Klasse A und 10% der Klasse B hat ein Modell, das alle Fälle als Klasse A vorhersagt, eine Genauigkeit von 90%, ist aber für die Vorhersage von Fälle der Klasse B nicht nützlich.

Beispiel

Outcome recidivism: 1 = recidivate, 0 = not recidivate			
	Predicted values		
	0	1	Total
True/actual values			
0	540	224	764
1	255	424	679
Total	795	648	1443

Wie hoch ist die **Accuracy** unseres Rückfall-Klassifizierers?

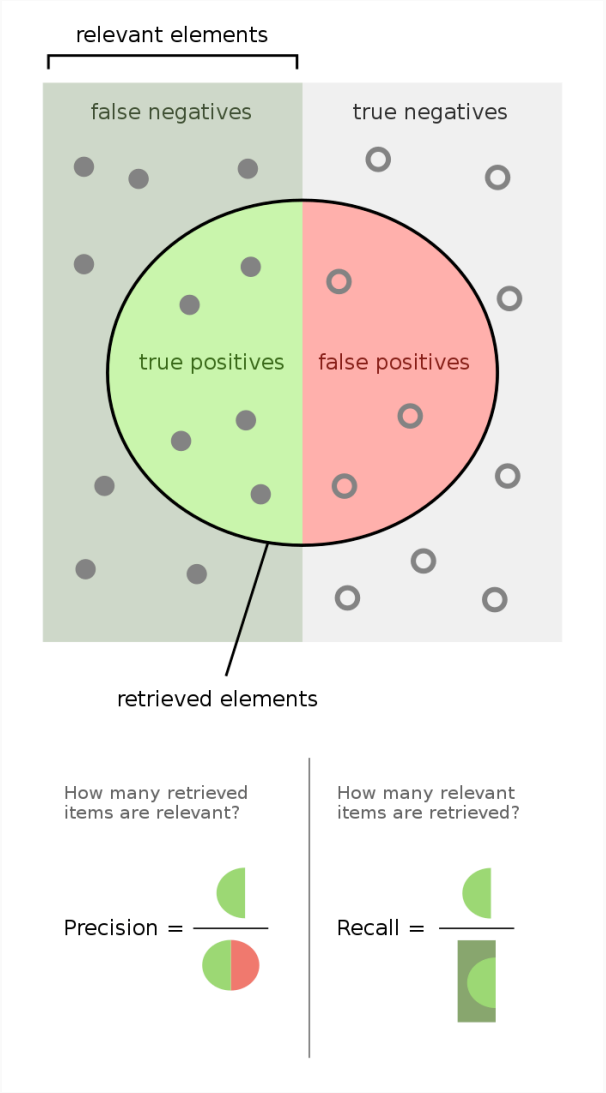
Bestimmung der Performanz eines binären Klassifizierers

Präzision

- Präzision = $\frac{\text{Anzahl der echten positiven Vorhersagen}}{\text{Anzahl der positiven Vorhersagen}} = \frac{TP}{TP+FP}$

Nützlichkeit

- Die Präzision konzentriert sich auf die Genauigkeit der positiven Vorhersagen und ist nützlich, wenn die Kosten für falsch positive Vorhersagen hoch sind.



Bestimmung der Performanz eines binären Klassifizierers

Präzision

- Präzision = $\frac{\text{Anzahl der echten positiven Vorhersagen}}{\text{Anzahl der positiven Vorhersagen}} = \frac{TP}{TP+FP}$

Nützlichkeit

- Die Präzision konzentriert sich auf die Genauigkeit der positiven Vorhersagen und ist nützlich, wenn die Kosten für falsch positive Vorhersagen hoch sind.

Example

Outcome recidivism: 1 = recidivate, 0 = not recidivate			
	Predicted values		
	0	1	Total
True/actual values			
0	540	224	764
1	255	424	679
Total	795	648	1443

Wie hoch ist die **Präzision** unseres Rückfall-Klassifizierers?

Bestimmung der Performanz eines binären Klassifizierers

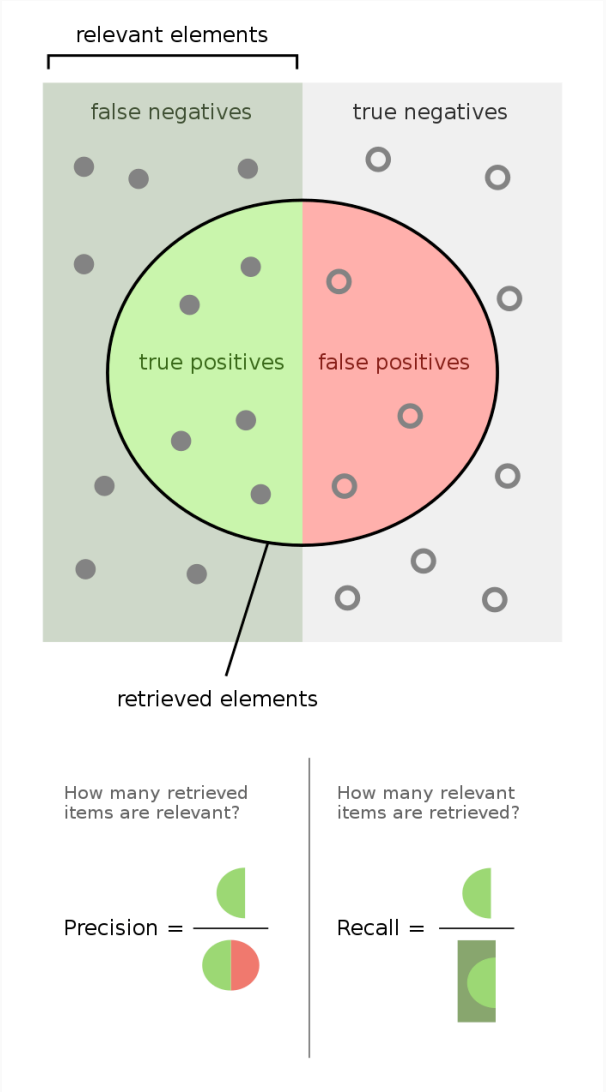
Hertie School

Recall (Sensitivität)

- Recall = $\frac{\text{Anzahl der wahren positiven Vorhersagen}}{\text{Anzahl der wahren positiven Werte}} = \frac{TP}{TP+FN}$
- „True-Positive-Rate“

Nützlichkeit

- Der Recall konzentriert sich auf die Erfassung aller positiven Werte und ist wichtig, wenn die Kosten für Falsch-negativ-Vorhersagen hoch sind.
- **Beispiel:** Bei einer medizinischen Diagnose ist der Recall wichtig, um sicherzustellen, dass alle Patienten mit einer Krankheit korrekt identifiziert werden.
- Das ergänzende Maß ist die Spezifität (Rate der echten Negativbefunde; z. B. wie viele gesunde Personen als nicht erkrankt identifiziert werden).



Bestimmung der Performanz eines binären Klassifizierers

Recall (Sensitivität)

- Recall = $\frac{\text{Anzahl der wahren positiven Vorhersagen}}{\text{Anzahl der wahren positiven Werte}} = \frac{TP}{TP+FN}$
- „True-Positive-Rate“

Nützlichkeit

- Der Recall konzentriert sich auf die Erfassung aller positiven Werte und ist wichtig, wenn die Kosten für Falsch-negativ-Vorhersagen hoch sind.
- **Beispiel:** Bei einer medizinischen Diagnose ist der Recall wichtig, um sicherzustellen, dass alle Patienten mit einer Krankheit korrekt identifiziert werden.
- Das ergänzende Maß ist die Spezifität (Rate der echten Negativbefunde; z. B. wie viele gesunde Personen als nicht erkrankt identifiziert werden).

Beispiel

Outcome recidivism: 1 = recidivate, 0 = not recidivate			
	Predicted values		
	0	1	Total
True/actual values			
0	540	224	764
1	255	424	679
Total	795	648	1443

Wie hoch ist der **Recall** unseres Rückfall-Klassifizierers?

Bestimmung der Performanz eines binären Klassifizierers

F1-Score

- F1 score = $2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2TP}{2TP + FP + FN}$
- Der F1-Score ist das harmonische Mittel aus Präzision und Recall.

Nützlichkeit

- Der F1-Score berichtet eine Balance zwischen Präzision und Recall, was insbesondere dann hilfreich ist, wenn ein Ungleichgewicht zwischen den Klassen besteht.
- Der F1-Score reicht von 0 bis 1, wobei 1 für perfekte Präzision und Recall und 0 für eine schlechte Leistung steht.

Illustration

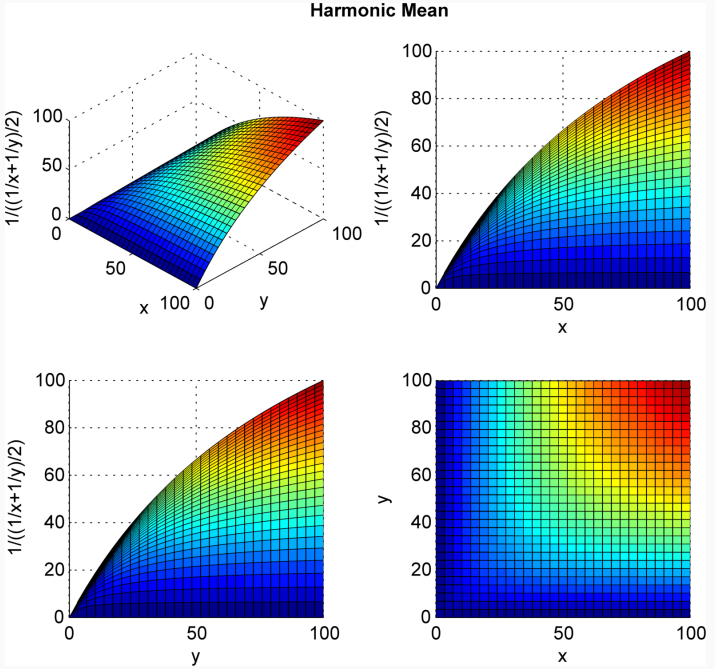


Abbildung des normalisierten harmonischen Mittels, wobei x die Präzision, y den Recall und die vertikale Achse den F1-Score in %-Punkten darstellt.

`Quelle` Andong87

Bestimmung der Performanz eines binären Klassifizierers

Hertie School

F1-Score

- F1 score = $2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2TP}{2TP + FP + FN}$
- Der F1-Score ist das harmonische Mittel aus Präzision und Recall.

Nützlichkeit

- Der F1-Score berichtet eine Balance zwischen Präzision und Recall, was insbesondere dann hilfreich ist, wenn ein Ungleichgewicht zwischen den Klassen besteht.
- Der F1-Score reicht von 0 bis 1, wobei 1 für perfekte Präzision und Recall und 0 für eine schlechte Leistung steht.

Beispiel

Outcome recidivism: 1 = recidivate, 0 = not recidivate			
	Predicted values		
	0	1	Total
True/actual values			
0	540	224	764
1	255	424	679
Total	795	648	1443

Wie hoch ist der **F1-Score** unseres Rückfall-Klassifizierers?

Weshalb die Wahl der Metrik den Unterschied machen kann

Szenario

- **Outcome:** Rückfälligkeit, wenn die Person rückfällig wird (1) oder nicht (0)
- **Falsch positiv (FP):** Das Modell sagt voraus, dass eine Person rückfällig wird, wenn sie es tatsächlich nicht wird.
- **Falsch Negativ (FN):** Das Modell sagt voraus, dass eine Person nicht rückfällig wird, obwohl sie es tatsächlich wird.

Kosten

- Was sind die nachgelagerten Kosten von FP und FN?
- FP könnte dazu führen, dass einer Person Maßnahmen auferlegt werden, die nicht notwendig wären
- FN könnte dazu führen, dass gefährdete Personen ohne angemessene Intervention entlassen werden, was möglicherweise zu erneuten Straftaten führt.
- Auf welcher Ebene fallen die Kosten an - individuell, gesellschaftlich, ...?

Ethische und wirtschaftliche Überlegungen

- Wie sollten wir die Kosten von FP und FN abwägen?
- Was sollte in unserem Modell Vorrang haben - die Verringerung von FP, FN oder ein Kompromiss zwischen beiden?

Statistiken verwenden: lessons learned

Hertie School

Lies, damned lies and statistics

- Politische Debatten drehen sich fast zwangsläufig auch um Statistiken
- Strategischer Anreiz, Beweise zu seinen Gunsten zu beeinflussen
- Statistische Fallstricke: Nicht alles, was logisch klingt, ist statistisch fundiert
- Ein grundlegendes Verständnis der grundlegenden Konzepte der Statistik ist der Schlüssel zu kritischem Konsum von Daten und Statistiken
- Einige populäre Irrtümer und Fehler treten immer wieder auf - man kann trainieren, sie zu erkennen!



Übung: OptiClassify

"OptiClassify: Effiziente Aktenkategorisierung – Präzision, die Sie brauchen!"

Mit OptiClassify bieten wir eine KI-basierte Lösung, die **Verwaltungsakten automatisch in 5 spezifische Kategorien** einteilt. Unsere Technologie erreicht eine **statistisch signifikante Trefferquote (Accuracy) von 95%**, unterstützt durch modernste Machine-Learning-Algorithmen.

Die **Falsch-Negative-Rate liegt bei 5%**, was bedeutet, dass nur wenige Dokumente in die falsche Kategorie eingeordnet werden. Dank der **hohen Signifikanz von $p < 0.01$** können Sie sich auf die Zuverlässigkeit unserer Lösung verlassen, insbesondere bei großen Datenmengen.

In **Tests mit über 100.000 realen Verwaltungsakten** haben wir bewiesen, dass OptiClassify selbst in komplexen Szenarien konsistent arbeitet und den manuell erzeugten **Kategorisierungsaufwand um 75% reduziert**.

Entdecken Sie die Zukunft der Verwaltung mit OptiClassify – sparen Sie Zeit, Kosten und Ressourcen, indem Sie unsere praxiserprobte Lösung einsetzen!



Übung: OptiClassify

Mögliche Fragen

1. Auf Basis welcher Daten wurde das Tool trainiert?

   ✎ Die Qualität und Passung der Trainingsdaten ist entscheidend für die Leistung des Tools im konkreten Kontext.

2. Wie wird die Accuracy von 95% berechnet, und wie verteilt sich diese auf die einzelnen Kategorien?

   ✎ Die Accuracy könnte in einigen Kategorien viel niedriger sein.

3. Wie wirkt sich die False-Negative-Rate von 5% auf kritische Akten aus?

   ✎ Es ist wichtig zu wissen, ob Dokumente, die zwingend in eine bestimmte Kategorie gehören, zuverlässig erkannt werden.

   ✎ Bei einer großen Anzahl von Dokumenten könnten niedrige Fehlerraten zu vielen manuellen Nacharbeiten führen.

4. Was soll „Signifikanz von $p < 0.01$“ hier bedeuten?

   ✎ Signifikanz beantwortet eine andere Frage (ob ein Unterschied zufällig sein könnte), nicht, ob das Tool in Eurem Haus brauchbar ist. Hier ist es ein Marketingwort.

Data Detective: AnkER-Zentren

