Der Daten-Lifecycle

Session 5: Möglichkeiten und Probleme mit Big Data

Simon Munzert
Hertie School

Inhaltsverzeichnis

1. Was ist Big Data?

2. Das Big-Data-Paradoxon

3. Datenfails I: Selektion und mangelnde Repräsentativität

4. Datenfails II: Schlechte Messung

5. Datenqualität sichern

6. Übung: Data Detective

Was ist Big Data?

The five V's of big data

VOLUME

The scale of data.

VARIETY

Data comes in different forms. Structured data are easily searchable like spreadsheets. Unstructured data include disorganized information like tweets and video.

VELOCITY

The speed of data processing. These days a great deal of data are available in real time, such as social media posts.

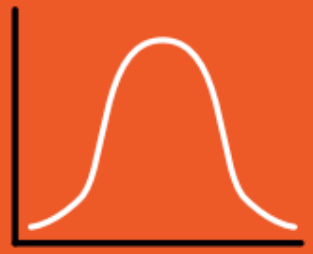

VARIABILITY

How spread out the data are.

VERACITY

The accuracy of data provides confidence during research.

Das Zeitalter von Big Data - Große Trends

1. Massive Erzeugung von **vom Menschen erzeugten Daten** insbesondere im digitalen Bereich
2. Verwendung von **neuen Datentypen**: Text, Video, digitale Spuren
3. **Rechen- und Speicherkosten** sind drastisch gesunken
4. Mainstreaming von **maschinellem Lernen** und **KI**-Technologien
5. (Begrenzte) **Demokratisierung des Zugangs** zu großen Datenbeständen
6. **Verlagerung der Forschungsavantgarde** von der akademischen Welt zur Industrie

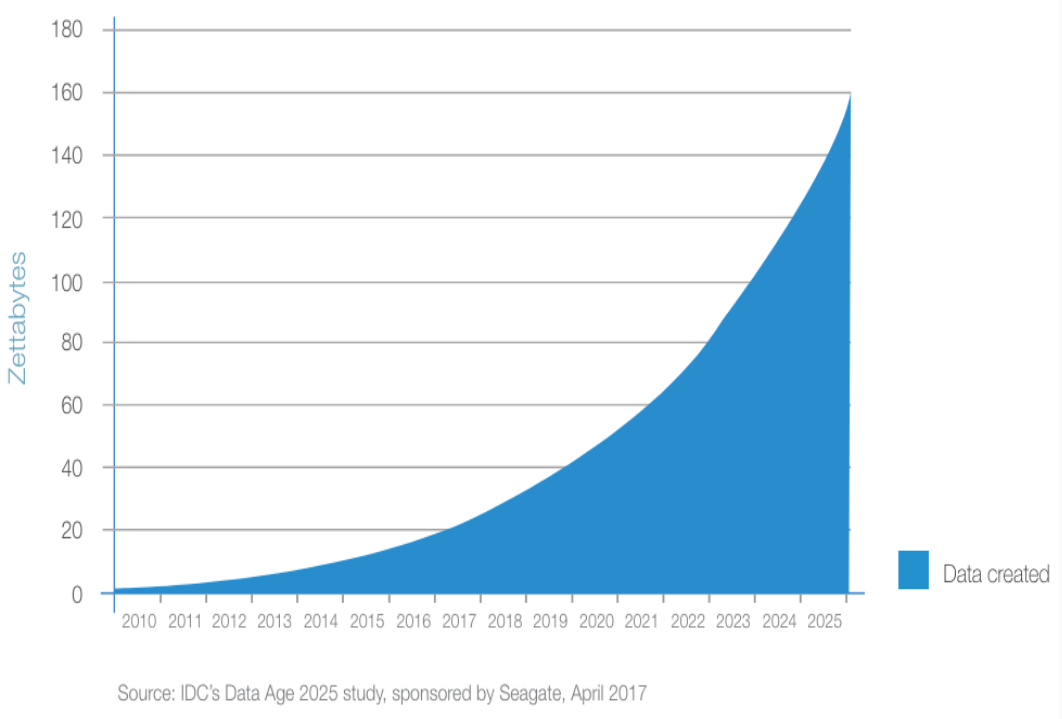

`Quelle` Reinsel et al., 2017, "Data Age 2025"

[1]Die Zahlen sind mit Vorsicht zu genießen. SIe sind fundamental schwer zu messen; deshalb weichen veröffentlichte Daten teilweise um ein Vielfaches voneinander ab.

Das Big-Data-Paradoxon

Wahlumfrage 1936 der Zeitschrift Literary Digest

Hintergrund

- Die Wochenzeitschrift *Literary Digest* hatte die Präsidentschaftswahlen 1920 bis 1932 anhand ihrer Umfragen korrekt vorhergesagt.
- 1936 verschickte sie **10 Millionen Musterstimmzettel**, 2,4 Millionen kamen zurück. Ergebnis: deutlicher Sieg des Republikaners Alf Landon.

Nachwehen

- Landon verlor erdrutschartig gegen Franklin D. Roosevelt, der 46 von 48 Bundesstaaten und 60,8% der Stimmen gewann.
- George Gallup sagte das Ergebnis mit einer Stichprobe von **50.000** Personen richtig voraus.
- Die Zeitschrift ging 1938 in Konkurs.

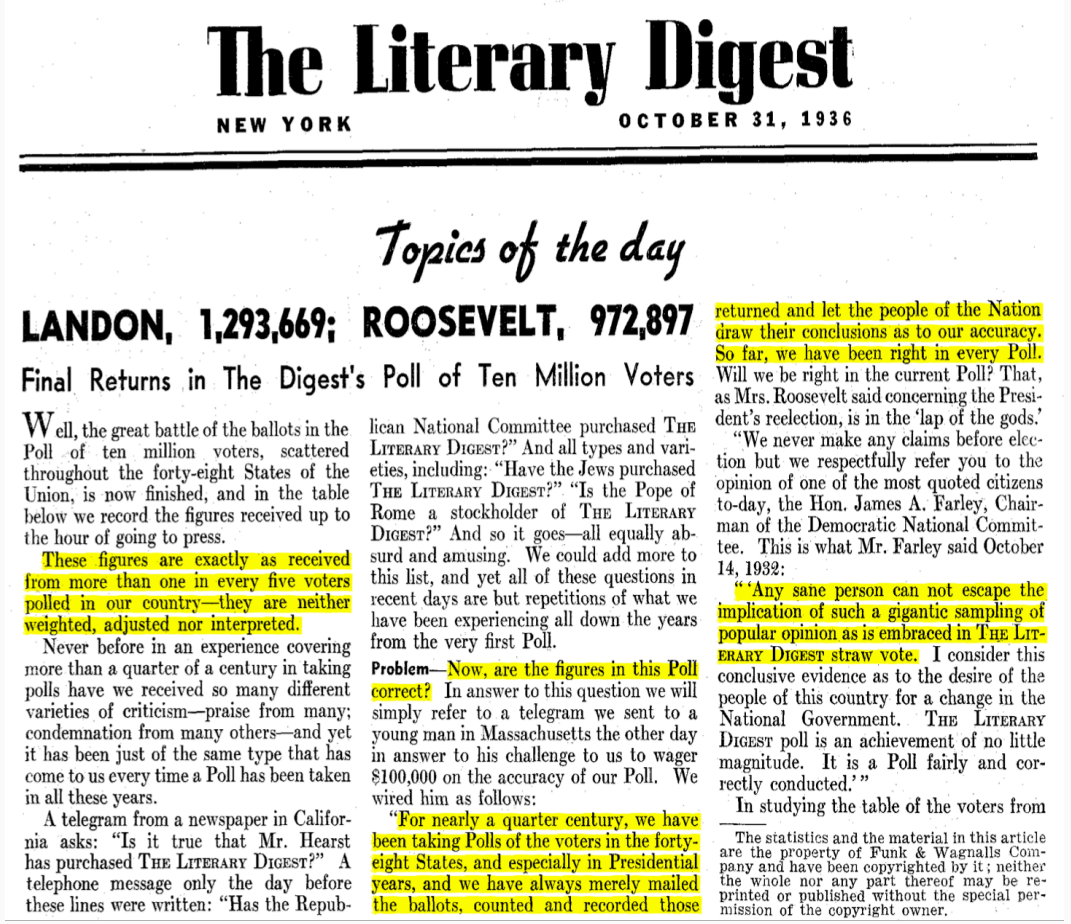

The Literary Digest

NEW YORK — OCTOBER 31, 1936

Topics of the day

LANDON, 1,293,669; ROOSEVELT, 972,897

Final Returns in The Digest's Poll of Ten Million Voters

Well, the great battle of the ballots in the Poll of ten million voters, scattered throughout the forty-eight States of the Union, is now finished, and in the table below we record the figures received up to the hour of going to press.

These figures are exactly as received from more than one in every five voters polled in our country—they are neither weighted, adjusted nor interpreted.

Never before in an experience covering more than a quarter of a century in taking polls have we received so many different varieties of criticism—praise from many; condemnation from many others—and yet it has been just of the same type that has come to us every time a Poll has been taken in all these years.

A telegram from a newspaper in California asks: "Is it true that Mr. Hearst has purchased THE LITERARY DIGEST?" A telephone message only the day before these lines were written: "Has the Republican National Committee purchased THE LITERARY DIGEST?" And all types and varieties, including: "Have the Jews purchased THE LITERARY DIGEST?" "Is the Pope of Rome a stockholder of THE LITERARY DIGEST?" And so it goes—all equally absurd and amusing. We could add more to this list, and yet all of these questions in recent days are but repetitions of what we have been experiencing all down the years from the very first Poll.

Problem—Now, are the figures in this Poll correct? In answer to this question we will simply refer to a telegram we sent to a young man in Massachusetts the other day in answer to his challenge to us to wager $100,000 on the accuracy of our Poll. We wired him as follows:

"For nearly a quarter century, we have been taking Polls of the voters in the forty-eight States, and especially in Presidential years, and we have always merely mailed the ballots, counted and recorded those returned and let the people of the Nation draw their conclusions as to our accuracy. So far, we have been right in every Poll. Will we be right in the current Poll? That, as Mrs. Roosevelt said concerning the President's reelection, is in the 'lap of the gods.'

"We never make any claims before election but we respectfully refer you to the opinion of one of the most quoted citizens to-day, the Hon. James A. Farley, Chairman of the Democratic National Committee. This is what Mr. Farley said October 14, 1932:

"'Any sane person can not escape the implication of such a gigantic sampling of popular opinion as is embraced in THE LITERARY DIGEST straw vote. I consider this conclusive evidence as to the desire of the people of this country for a change in the National Government. THE LITERARY DIGEST poll is an achievement of no little magnitude. It is a Poll fairly and correctly conducted.'"

In studying the table of the voters from

The statistics and the material in this article are the property of Funk & Wagnalls Company and have been copyrighted by it; neither the whole nor any part thereof may be reprinted or published without the special permission of the copyright owner.

Wahlumfrage 1936 der Zeitschrift Literary Digest

Anatomie eines Debakels

1. **Stichprobenrahmen**: (1) eigene Leser, (2) registrierte Autobesitzer, (3) registrierte Telefonnutzer
2. **Datenerhebung**: Jeder bekam einen Musterstimmzettel zugeschickt und wurde gebeten, den markierten Stimmzettel zurückzugeben
3. **Rücklaufquote**: 2,4 Mio. von 10 Mio.

Stichprobenverzerrung als Folge von **coverage error** und **non-reponse**: Überrepräsentation von wohlhabenderen Personen mit einer Präferenz für Landon

`Quelle` Peverill Squire, 1988, Public Opinion Quarterly

Table 1. 1936 Presidential Vote by Car and Telephone Ownership (in Percent)

Presidential Vote	Car & Phone	Car, No Phone	Phone, No Car	Neither
Roosevelt	55	68	69	79
Landon	45	30	30	19
Other	1	2	0	2
Total *N*	946	447	236	657

SOURCE: American Institute of Public Opinion, 28 May 1937.

Table 2. Presidential Vote by Receiving *Literary Digest* Straw Vote Ballot or Not (in Percent)

Presidential Vote	Received Poll	Not Receive Poll	Do Not Know
Roosevelt	55	71	73
Landon	44	27	25
Other	1	1	3
Total *N*	780	1339	149

SOURCE: American Institute of Public Opinion, 28 May 1937.

Table 3. Presidential Vote by Returning or Not Returning Straw Vote Ballot (in Percent)

Presidential Vote	Did Return	Did Not Return	Do Not Know
Roosevelt	48	69	56
Landon	51	30	40
Other	1	1	4
Total *N*	493	288	48

SOURCE: American Institute of Public Opinion, 28 May 1937.

Ein modernes Big-Data-Umfrage-Desaster

Hertie School

Unrepresentative big surveys significantly overestimated US vaccine uptake

https://doi.org/10.1038/s41586-021-04198-4

Received: 18 June 2021

Accepted: 29 October 2021

Published online: 8 December 2021

Check for updates

Valerie C. Bradley[1,6], Shiro Kuriwaki[2,6], Michael Isakov[3], Dino Sejdinovic[1], Xiao-Li Meng[4] & Seth Flaxman[5]✉

Surveys are a crucial tool for understanding public opinion and behaviour, and their accuracy depends on maintaining statistical representativeness of their target populations by minimizing biases from all sources. Increasing data size shrinks confidence intervals but magnifies the effect of survey bias: an instance of the Big Data Paradox[1]. Here we demonstrate this paradox in estimates of first-dose COVID-19 vaccine uptake in US adults from 9 January to 19 May 2021 from two large surveys: Delphi–Facebook[2,3] (about 250,000 responses per week) and Census Household Pulse[4] (about 75,000 every two weeks). In May 2021, Delphi–Facebook overestimated uptake by 17 percentage points (14–20 percentage points with 5% benchmark imprecision) and Census Household Pulse by 14 (11–17 percentage points with 5% benchmark imprecision), compared to a retroactively updated benchmark the Centers for Disease Control and Prevention published on 26 May 2021. Moreover, their large sample sizes led to miniscule margins of error on the incorrect estimates. By contrast, an Axios–Ipsos online panel[5] with about 1,000 responses per week following survey research best practices[6] provided reliable estimates and uncertainty quantification. We decompose observed error using a recent analytic framework[1] to explain the inaccuracy in the three surveys. We then analyse the implications for vaccine hesitancy and willingness. We show how a survey of 250,000 respondents can produce an estimate of the population mean that is no more accurate than an estimate from a simple random sample of size 10. Our central message is that data quality matters more than data quantity, and that compensating the former with the latter is a mathematically provable losing proposition.

Table 1 | Comparison of survey designs

	Axios-Ipsos	Census Household Pulse	Delphi-Facebook
Recruitment mode	Address-based mail sample to Ipsos KnowledgePanel	SMS and email	Facebook Newsfeed
Interview mode	Online	Online	Online
Average size	1,000/wave	75,000/wave	250,000/week
Sampling frame	Ipsos KnowledgePanel; internet/tablets provided to ~5% of panelists who lack home internet	Census Bureau's Master Address File (individuals for whom email / phone contact information is available)	Facebook active users
Vaccine uptake question	"Do you personally know anyone who has already received the COVID-19 vaccine?"	"Have you received a COVID-19 vaccine?"	"Have you had a COVID-19 vaccination?"
Vaccine uptake definition	"Yes, I have received the vaccine"	"Yes"	"Yes"
Other vaccine uptake response options	"Yes, a member of my immediate family", "Yes, someone else", "No"	"No"	"No", "I don't know"
Weighting variables	Gender by age, race, education, Census region, metropolitan status, household income, partisanship.	Education by age by sex by state, race/ethnicity by age by sex by state, household size	Stage 1: age, gender "other attributes which we have found in the past to correlate with survey outcomes" to FAUB; Stage 2: state by age by gender

Comparison of key design choices across the Axios–Ipsos, Census Household Pulse and Delphi–Facebook studies. All surveys target the US adult population. See Extended Data Table 1 for additional comparisons and Methods for additional implementation details.

Ein modernes Big-Data-Umfrage-Desaster

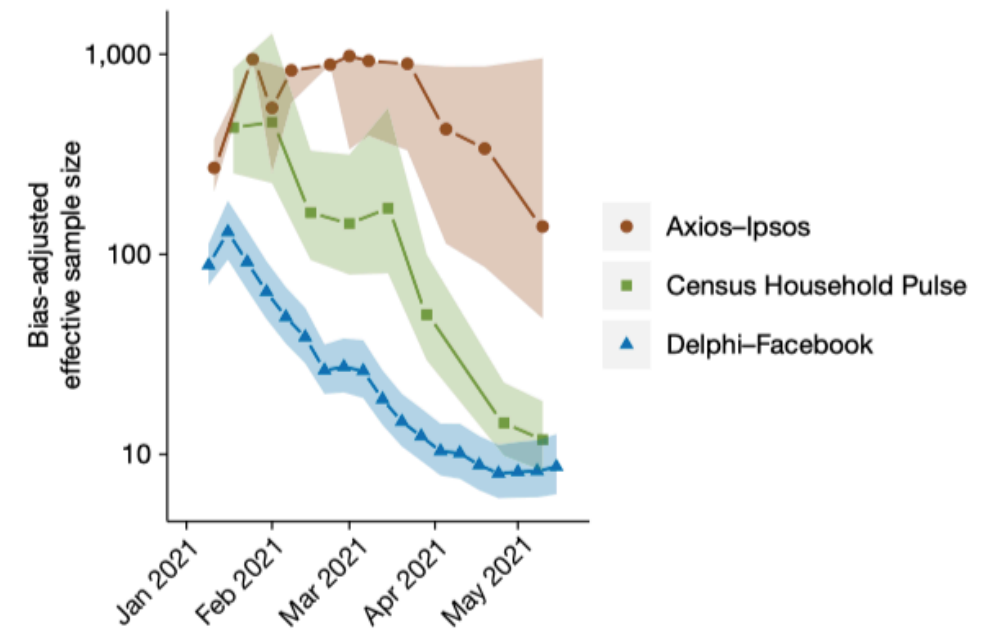

Fig 2 | Bias-adjusted effective sample size. An estimate's bias-adjusted effective sample size (different from the classic Kish effective sample size) is the size of a simple random sample that would have the same MSE as the observed estimate. Effective sample sizes are shown here on the $\log_{10}$ scale. The original sample size was $n = 4{,}525{,}633$ across 19 waves for Delphi–Facebook, $n = 606{,}615$ across 8 waves for Census Household Pulse and $n = 11{,}421$ across 11 waves for Axios–Ipsos. Shaded bands represent scenarios of ±5% benchmark imprecision in the CDC benchmark.

Das Big-Data-Paradoxon

> „Wenn verzerrte Stichproben groß sind, sind sie doppelt irreführend: Sie erzeugen Konfidenzintervalle mit falschen Mitteln und erheblich unterschätzter Unsicherheit. Dies ist das **Big-Data-Paradoxon**: Je umfangreicher die Daten sind, desto sicherer täuschen wir uns selbst, wenn wir die Verzerrungen bei der Datenerhebung nicht berücksichtigen."

Bradley et al. (2021), *Nature*

> „Die 'Größe' solcher Big Data (für Rückschlüsse auf die Population) sollte an der relativen Größe f = n/N der Stichprobe zur Population gemessen werden, nicht an der absoluten Größe n der Stichprobe.

Xiao-Li Meng (2018), *The Annals of Applied Statistics*

Zensus 2022: Wer sind wir und wenn ja, wie viele?

Drei Zahlen, drei Verfahren

Wo leben wie viele Menschen in Deutschland? An der Zahl hängen Länderfinanzausgleich, Wahlkreise, Schlüsselzuweisungen, Stimmen im Bundesrat.

- **Melderegister**: Jede Kommune führt ihr eigenes. Alle Register zusammen enthalten mehr Personen, als im Land leben: Wer ins Ausland zieht, meldet sich selten ab („Karteileichen"); wer zuzieht, nicht immer sofort („Fehlbestände").
- **Fortschreibung**: Zensus 2011 plus Geburten, Sterbefälle, Zu- und Wegzüge aus den Meldungen. Zum Stichtag 2022: rund **84,1 Mio.**
- **Zensus 2022**: Registerabzug plus **Haushaltsstichprobe** (etwa jede zehnte Anschrift wird befragt). Aus der Stichprobe wird geschätzt, wie viele Registereinträge nicht stimmen, und das Register wird hochgerechnet korrigiert. Ergebnis: **82,7 Mio.**

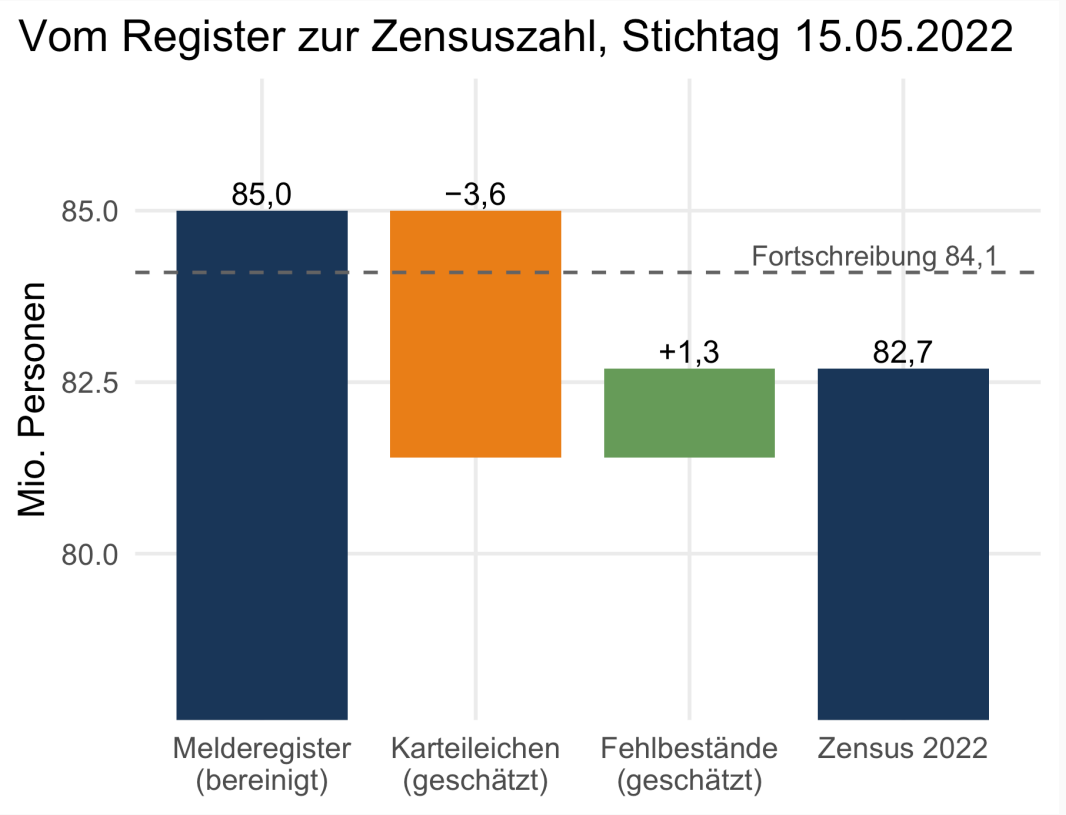

Quellen Zensus 2022; Schnell, Lenz & Schmidt (2026), Gutachten für 287 Gemeinden, Kap. 6 und 9.

Zensus 2022: Wer hat sich geirrt?

Die Vollerhebung

- Das Register ist groß, aber **systematisch** verzerrt: Abmeldungen fehlen vor allem bei Wegzügen ins Ausland, also bei Ausländern und in Großstädten. Köln: 7% unter dem eigenen Register.
- Der Fehler mittelt sich bei 85 Millionen Einträgen nicht weg. Das ist das Big-Data-Paradoxon: Größe täuscht Genauigkeit vor.

Die Stichprobe

- Die Zensus-Schätzung korrigiert das Register, hat aber **eigene** Fehler: Hochrechnung in kleinen Gemeinden, Record Linkage bei der Dublettenprüfung, Interviewer-Effekte, Ausfälle. Ihre Fehlermargen hat Destatis nach Ansicht der Gutachter unterschätzt.

Fazit

- **Man weiß es nicht genau.** Es gibt keinen dritten, unabhängigen Maßstab. Deshalb haben 287 Gemeinden ein Gutachten beauftragt, und mehrere Hundert Widerspruch eingelegt.
- Sicher ist nur: Die Vollerhebung allein irrt systematisch, die Stichprobe allein kann nicht alles sehen.
- Für jede Analyse mit Registerdaten stellt sich die Frage: **Wer ist drin, wer ist noch drin, wer war nie drin?**

`Quelle` Schnell, Lenz & Schmidt (2026): Eine methodische Kritik des Zensus 2022, Kap. 3.1, 8, 9.5, 10

Datenfails I: Selektion und mangelnde Repräsentativität

Zweifelhafte „Repräsentativität“

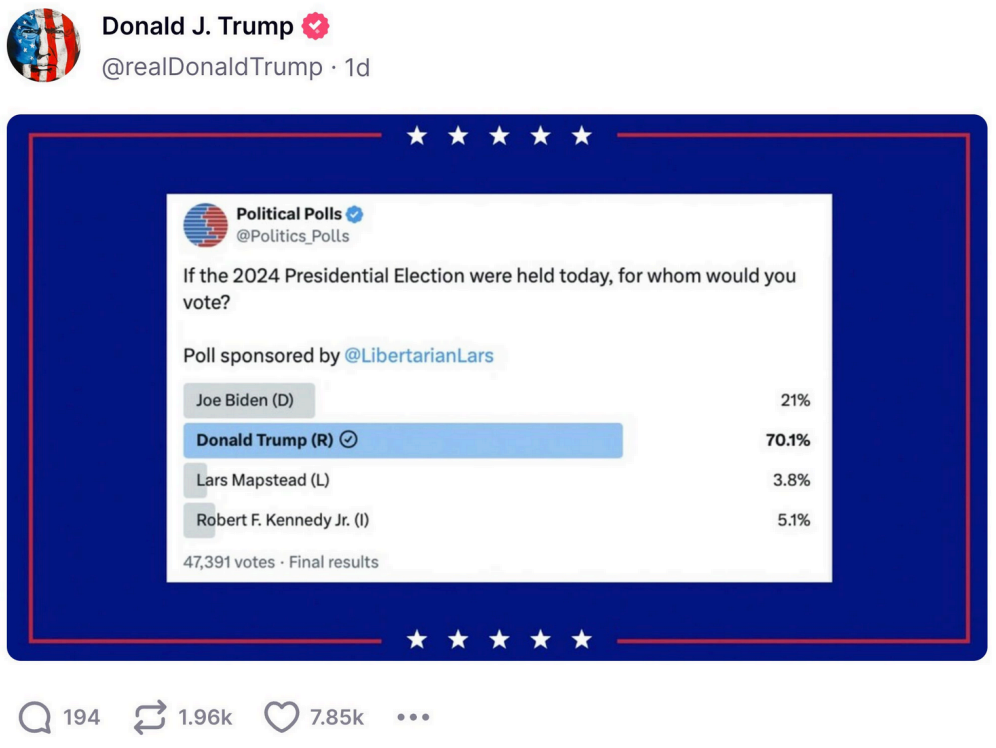

`Quelle` citechdaily.com

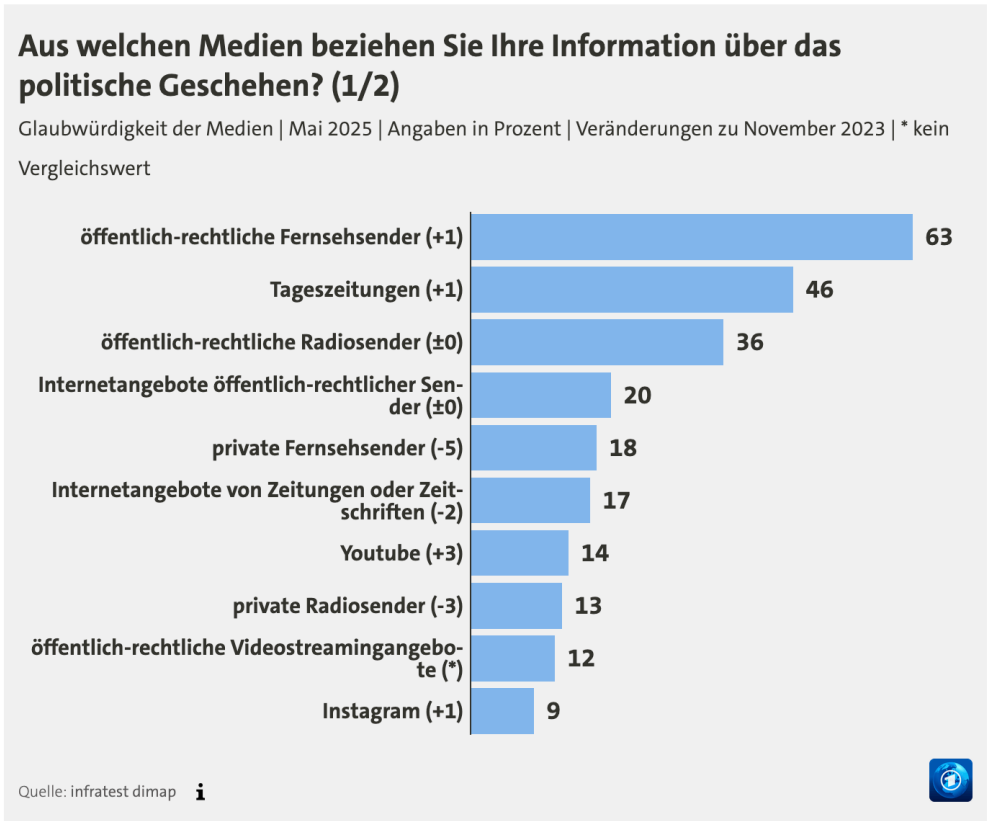

`Quelle` tagesschau.de/infratest dimap

Eine Heuristik für alle Datenfehler: Total Survey Error

Zwei grundsätzliche Fehlerquellen bei jeder Datensammlung

- **Messfehler**: was man misst, ist nicht das, was man messen will
- Fehler der **Repräsentation**: Die Gruppe, die Ihr beobachtet, ist nicht verallgemeinerbar auf die interessierende Population

Nicht nur für Umfragen

- Entwickelt für Befragungen, aber die Logik gilt für **jede** Datenquelle: Register, Fachverfahren, Sensoren, Logdaten, Trainingsdaten.
- Linke Seite: **Messung** (Konzept, Erfassung, Verarbeitung). Rechte Seite: **Repräsentation** (Zielgruppe, Datenrahmen, Ausfälle).

Total survey error framework

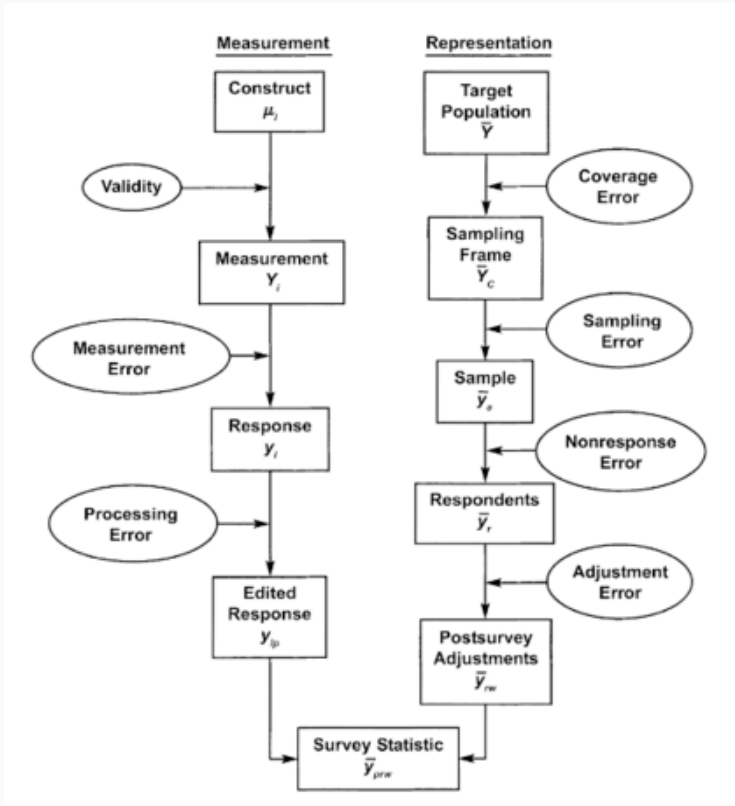

`Quelle` Groves et al. 2009, Survey Methodology

Stichproben und Repräsentativität

Hertie School

Eine substantielle Definition von Repräsentativität

Eine Stichprobe (oder Daten im Allgemeinen) ist „repräsentativ“, wenn **die aus der Stichprobe gezogenen Schlüsse verallgemeinert werden können** auf die Grundgesamtheit von Interesse.

Eine formalere Definition

Eine Stichprobe ist repräsentativ, wenn sie so gezogen wird, dass sie **statistisch nicht von der interessierenden Grundgesamtheit** unterscheidbar ist.

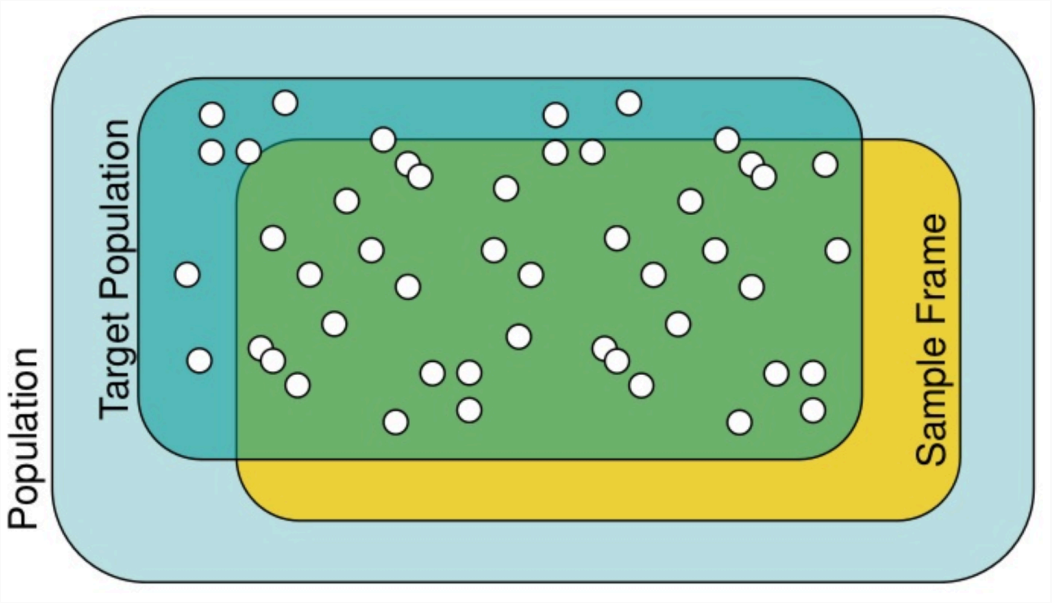

Das Problem mit der „Repräsentativität“

Warum „Repräsentativität“ ein problematischer Begriff ist

1. Ob eine Stichprobe repräsentativ ist, hängt von Eurem Interesse ab.
2. Man kann eine Stichprobe nicht a priori als „repräsentativ“ bezeichnen.
3. Die Beurteilung der Repräsentativität einer Stichprobe erfordert starke Annahmen über Euer Wissen über die Grundgesamtheit und Eure Messungen der Merkmale, die „repräsentativ“ sein sollten.

Ein Beispiel

- Ihr führt eine Umfrage zur Wahlabsicht durch.
- Wen möchtet Ihr repräsentieren? Die Wahlbevölkerung oder die Gesamtbevölkerung?
- Wie erreicht Ihr eine repräsentative Stichprobe? Zufallsauswahl? Gewichtung?

Selektion in Verwaltungsdaten I: Wer stellt keinen Antrag?

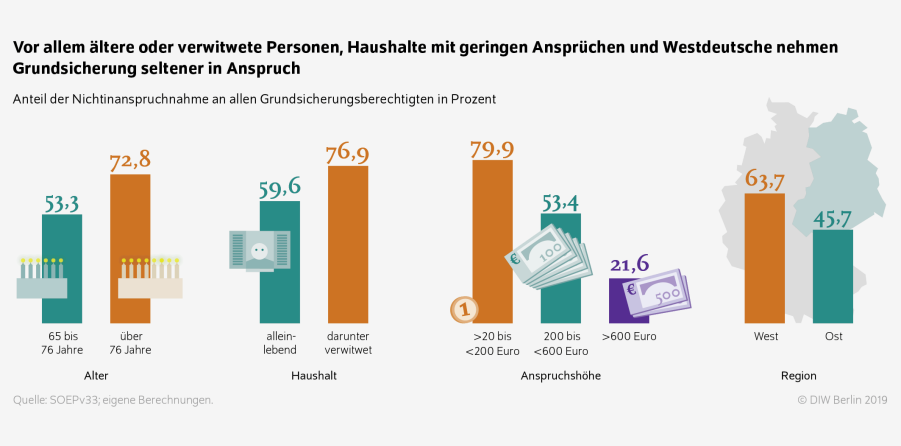

Der Fall

- **Grundsicherung im Alter** steht allen zu, deren Rente unter dem Existenzminimum liegt.
- Die Statistik kennt nur, wer sie **beantragt** hat.
- Das DIW schätzt mit dem SOEP: rund **60% der Berechtigten** stellen keinen Antrag.
- Gründe: Unkenntnis, Aufwand, Scham. Alles hängt mit Alter, Bildung und Gesundheit zusammen, die Lücke ist also **nicht zufällig**.

Folgen

- Die ausgewiesene Quote liegt bei 2,8%; bei voller Inanspruchnahme wären es **7,4%**.
- Bedarfsplanung und Armutsberichte auf Basis der Leistungsdaten **unterschätzen** das Problem.
- Ein KI-System, trainiert auf Antragsdaten, lernt die Antragsteller kennen, nicht die Berechtigten.

Ähnliche Muster

- Wohngeld, Kinderzuschlag, Bildungs- und Teilhabepaket, Beratungsangebote: **Nichtinanspruchnahme ist unsichtbar**, solange man nur die eigenen Daten anschaut.

`Quelle` Buslei et al. (2019), DIW Wochenbericht 49, Daten 2010 bis 2015

Selektion in Verwaltungsdaten II: Hellfeld und Dunkelfeld

Der Fall

- Die **Polizeiliche Kriminalstatistik (PKS)** zählt, was angezeigt oder von der Polizei festgestellt wurde: das **Hellfeld**.
- Die Dunkelfeldstudie **SKiD** des BKA (46.000 Befragte, 2020) zeigt, wie selektiv das ist und wie das Anzeigeverhalten von Delikt zu Delikt variiert.

Das Selektionsproblem

- Ein Anstieg in der PKS kann bedeuten: mehr Kriminalität, mehr Anzeigen, mehr Kontrollen oder eine neue Erfassungsregel.
- **Predictive Policing** wird auf dem Hellfeld trainiert: Wo bisher viel kontrolliert und angezeigt wurde, sagt das Modell mehr voraus, dorthin geht mehr Polizei, dort wird mehr festgestellt. Die Selektion **verstärkt sich selbst**.

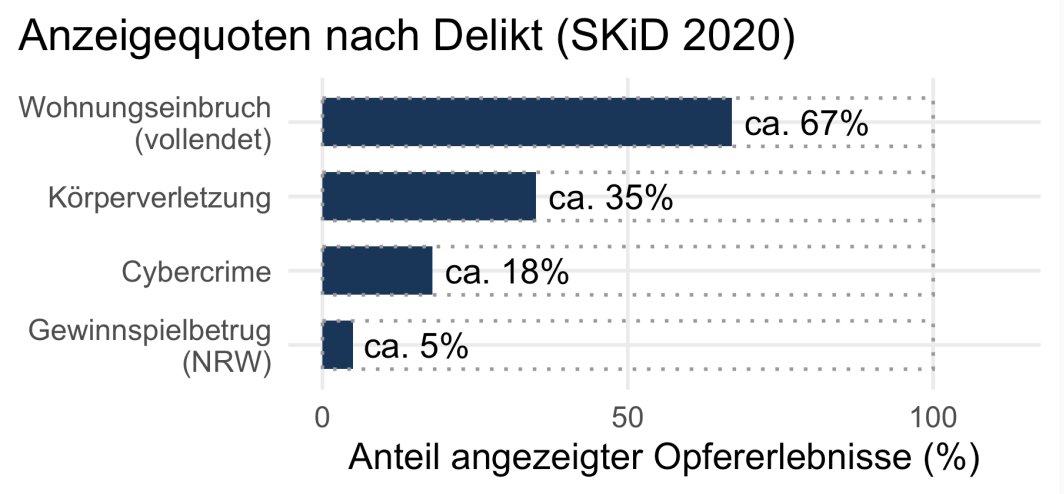

`Quellen` BKA, Pressemitteilung zu SKiD 2020; SKiD-Dashboard; SKiD NRW. Werte gerundet.

Ähnliche Muster

- Beschwerdestatistiken, Meldungen an Ordnungsämter, Verkehrsunfälle (nur polizeilich erfasste).
- Dunkelfeldstudien können helfen.

Schlechte Stichproben: lessons learned

Was bedeutet das für Euch?

- Nehmt die angegebene „Repräsentativität“ nicht für bare Münze.
- Der Stichprobenumfang allein garantiert keine Repräsentativität (siehe Big Data!). Lasst Euch also nicht von „großen Datenmengen“ täuschen (nicht per se repräsentativ).
- Schlechte Stichproben sind nicht auf Erhebungen beschränkt: Melderegister (wer sich nicht abmeldet), Leistungsdaten (wer nicht beantragt), Kriminalstatistik (wer nicht anzeigt), Social-Media-Daten (wer dort schreibt), Sensoren (wo sie stehen).

Achtet stattdessen auf:

1. **Transparenz** über das Auswahlverfahren.
2. **Validierung** der Stichprobe anhand externer Benchmarks.
3. **Euren gesunden Menschenverstand**: Ist die Datengrundlage systematisch verzerrt, d.h. auf relevanten Kriterien unterschiedlich von der Grundgesamtheit?

Übung: Repräsentatitivität

Diskussion in 2er-Gruppen, jeweils 2-3 Minuten

Findet Euch als Paar zusammen und erklärt in 1-2 Minuten jeweils eine der Fragen.

Partner 1: Was bedeutet "repräsentative Daten" oder "repräsentative Stichprobe"?

Partner 2: Warum ist "repräsentative Stichprobe" meistens Quatsch?

Datenfails II: Schlechte Messung

Messung und AI-Anwendungen

Messung ist ein zentraler Bestandteil von AI-Anwendungen

- AI-Modelle lernen von Daten, die gemessen werden.
- Gleichzeitig können AI-Modelle auch messen (z. B. Gesichtserkennung, Spracherkennung).

✎ Messung ist gleichzeitig Grundlage (Input) für als auch Output von AI-Anwendungen.

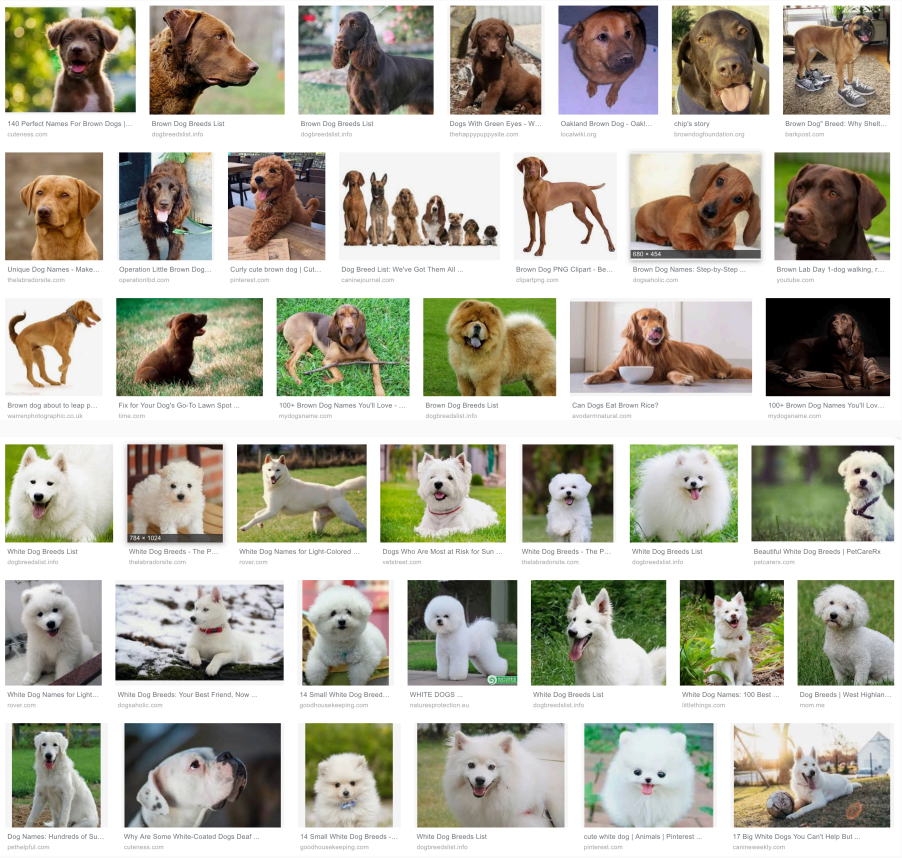

Messfehler in AI-Anwendungen

- Messfehler können systematisch sein (z. B. durch soziale Erwünschtheit).
- Messfehler können zufällig sein (z. B. durch technische Probleme).
- Messfehler können auch durch die AI-Anwendung selbst entstehen (z. B. durch schlechte Datenqualität).

Messung in Verwaltungsdaten: Sprachbiometrie beim BAMF

Der Fall

- Seit 2017 setzt das Bundesamt für Migration und Flüchtlinge eine Software ein, die aus einer **zweiminütigen Sprachprobe** die wahrscheinliche Herkunftsregion von Asylsuchenden ohne Papiere schätzt.
- Gemessen werden **Aussprache und Dialektmerkmale**; ausgegeben werden Wahrscheinlichkeiten für Dialekte. Das BAMF nennt das ein „Indiz", keinen Beweis.
- Fehlerquote nach BAMF-Angaben **15 bis 20%**; eine unabhängige Evaluation, 2018 angekündigt, liegt bis heute nicht vor.

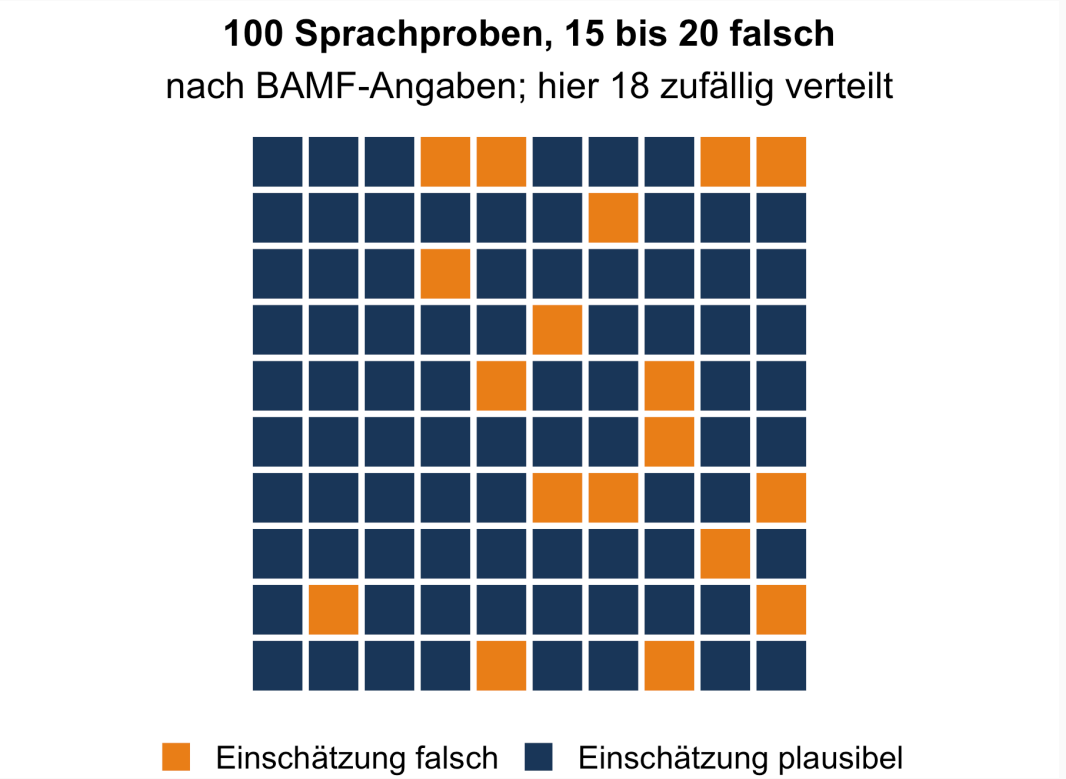

`Quellen` BT-Drs. 20/3238; netzpolitik.org (2020)

Gut funktionierende Messung: Gesichtserkennung

Hertie School

Messung von Gesichtsmerkmalen

- Gesichtsmerkmale sind oft gut messbar.
- Gesichtsmerkmale sind oft stabil über die Zeit.
- Massive Trainingsdaten für Gesichtserkennung verfügbar (Social Media, Fotoportale, etc.)

Beispiel: Paravision AI

> "In this Visa / Border test, Paravision ranks #1 globally for accuracy with an error rate that is 18% lower than the second-ranked vendor, delivering a False Negative Identification Rate of 0.22% at a False Positive Identification Rate of 0.3% across a dataset of 1,600,000 images." Paravision AI

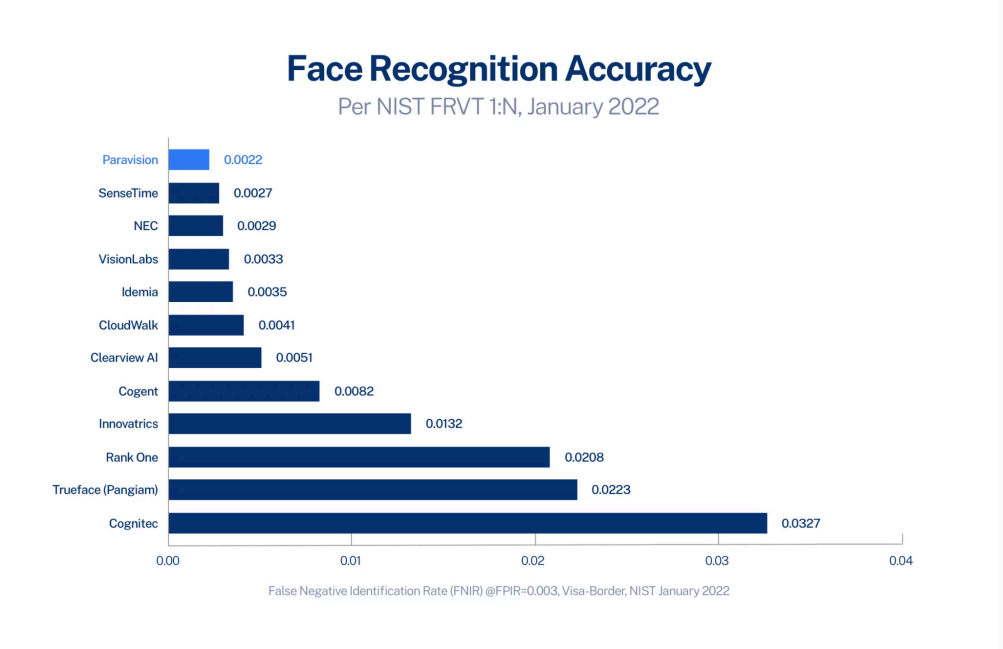

Clearview AI

Worum geht es?

- Tool für Gesichtserkennung beliebiger Personen anhand von Trainingsdaten aus Social Media, Zeitungen, Online-Plattformen, PayPal Transaktionen, etc.
- **Behauptung:** 99,85% Accuracy bei Stichprobe von 12 Millionen Fahndungsfotos (s. Homepage)
- **Belege:** Gutes Testergebnis beim US Nationalen Institut für Standards und Technologie
- **Anfechtbarkeit:** Tool ist weder offen zugänglich, noch können Nutzer/innen ihre Fotos entfernen.
- **Training der Modelle:** Web Scraping von Online-Plattformen, Webseiten und Medien ohne Einverständnis der Nutzer/innen
- **Hintergrund:** NYT-Recherche: Staatliche Behörden benutzen Clearview.ai auch während Gerichtsverfahren weiter (Hill, 2020)

`Quelle` Kashmir Hill, 2024

Clearview.ai

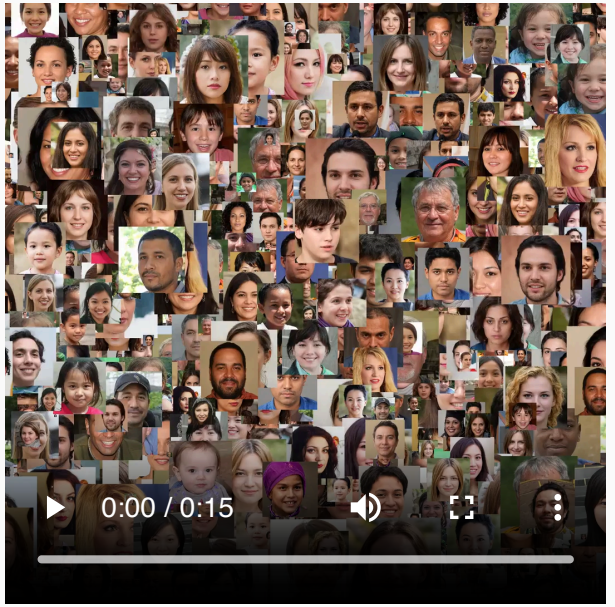

`Quelle` New York Times

Nicht so gut funktionierende Messung: Hate Speech

Hertie School

Das Problem

- **Hate Speech** kann sich in verschiedenen Formen äußern.
- **Hate Speech** ist schwer zu messen, weil es oft subtil und kontextabhhängig ist.
- Es herrscht fundamentale Uneinigkeit darüber, was genau **Hate Speech** ist und wie es gemessen werden sollte.

Beispiel: Facebook

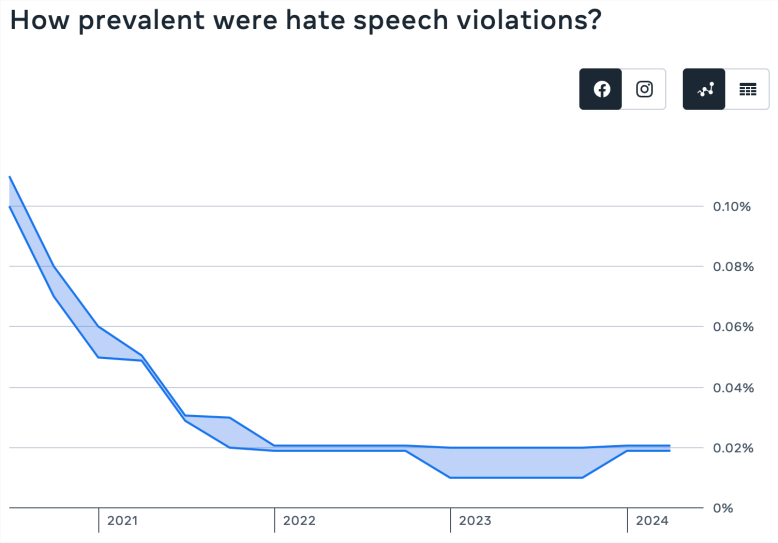

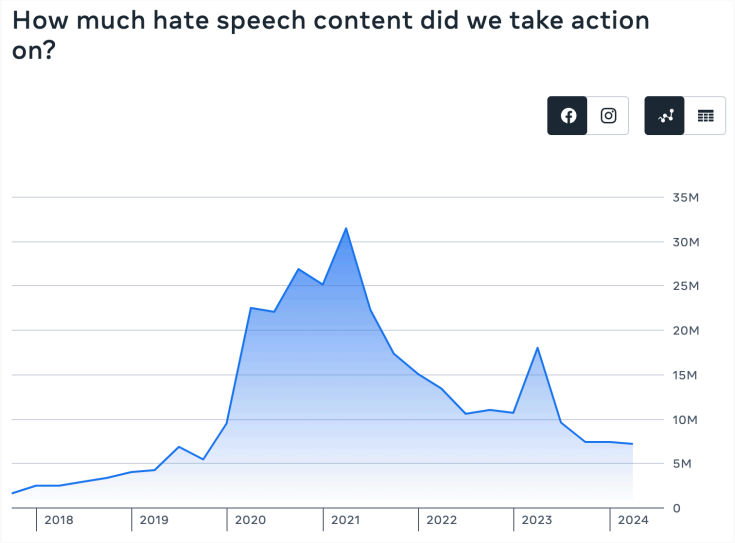

`Quelle` Facebook

Automatisiertes Recruitment

HireVue Personalgewinnung

- Tool für die Personalgewinnung: Video-Persönlichkeitstests zur Vorhersage beruflichen Erfolgs (und "präventivem Einsatz" im Recruitment)

Hintergrund

- Audit 2020 ohne veröffentlichte Ergebnisse
- Training der Modelle auf Basis von Bewertungen bereits eingestellter Mitarbeiter/innen, potenzielle Reproduktion bestehender Biases
- BR Recherche: Bücherregale, seltene Vokabeln, und das Tragen einer Brille führen zu besseren Scores (Harlan/Schnuck, BR, 2021)

`Source` Harwell, 2019; Wang et al., 2023: S. 28

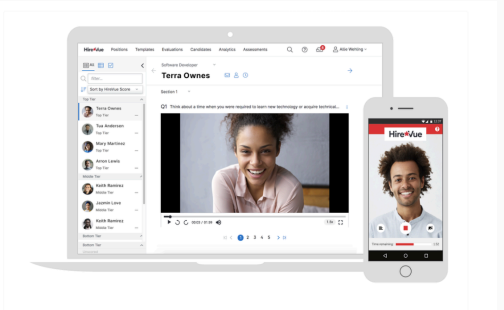

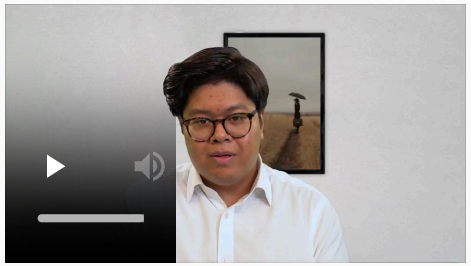

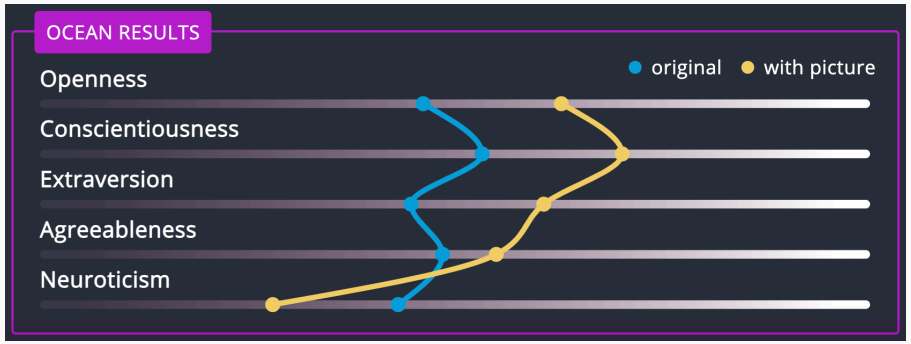

`Quelle` (Harlan/Schnuck, BR, 2021)

Datenqualität sichern

Garbage in, Garbage out

Das GIGO Prinzip

- Die Qualität der Informationen, die ein Modell produziert (z.B. Vorhersagen), kann nicht besser sein als die Qualität der Informationen, die in das Modell eingespeist werden.
- Dieser Grundsatz ist wird umso relevanter in Big-Data-Kontexten, wenn Daten unzureichend validiert oder Datenqualität schlicht nicht gegeben ist.
- Das Problem verschärft sich potentiell in ML-Anwendungen, wenn Modelle komplex und intransparent sind.

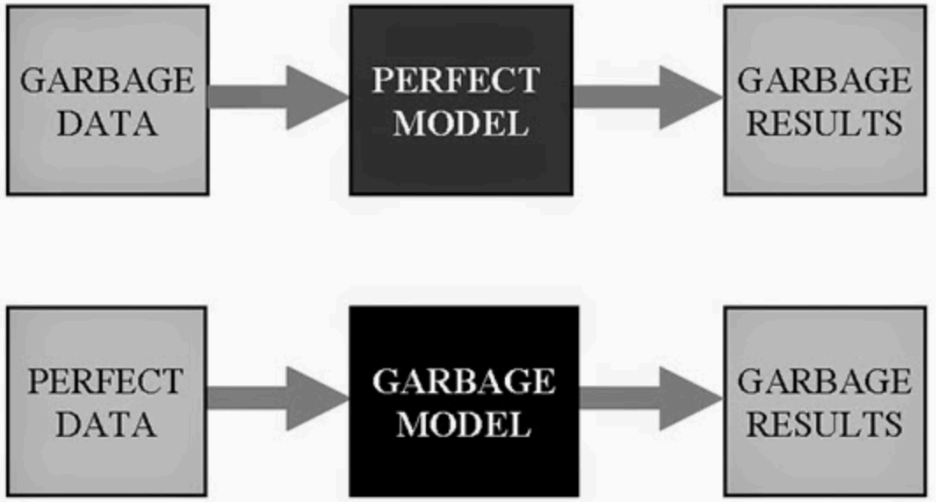

Garbage in, Garbage out: Lessons learned

1. **Messung-** und **Selektions-Fragen** sind bei der Big-Data-Analyse nach wie vor entscheidend.
2. Traut **Messungen** nicht, die nicht **richtig validiert** wurden.
3. Achtet darauf, was in ein Modell einfließt (der **Input**: Fälle, Variablen/Merkmale).
4. Achtet auf eine angemessene **Out-of-Sample-Validierung** von Modellen.
5. Vorsicht bei **unkritischer Nutzung von Online-/Sozialen Medien** und von **Verfahrensdaten** als Datenquelle: Beide beschreiben, wer sich gemeldet hat, nicht die Welt.

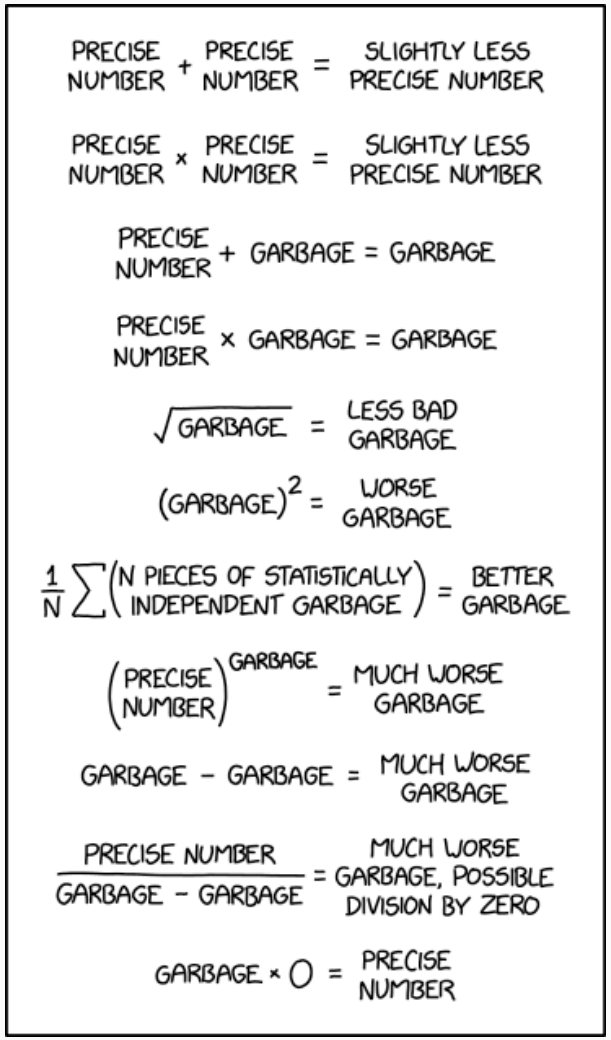

`Quelle` XKCD, 2295, (hier erklärt)

Übung: Data Detective

Umgang mit Evidenz als Detektivarbeit

Der Ansatz

- Auswertung von Daten ist wie Detektivarbeit
- Wir müssen die **Evidenz genau unter die Lupe nehmen**, um herauszufinden, ob der Verdächtige - der vermutete Zusammenhang, der deskriptive Befund - tatsächlich hält, was er verspricht
- Dazu müssen wir versuchen **Alternativerklärungen auszuschließen**

Die Ausstattung

- **Unsere Toolbox:** Kritisches Denken, Beobachtung (Datenerhebung), Wahrnehmung (Messung), externes Wissen, statistische Methoden
- Ohne qualitative Beurteilung sind die quantitativen Werkzeuge häufig ohne Wert

Ein paar einfache Fälle

Drückende Schuhe (?)

> Umfrageergebnisse zeigen, dass Menschen, die mit Schuhen schlafen, viel häufiger mit Kopfschmerzen aufwachen.

Gezuckerte Getränke führen zu Fettleibigkeit (?)

> Personen, die regelmäßig zuckerhaltige Getränke konsumieren, haben einen 30% höheren BMI.

Lock-downs haben COVID-19-bedingte Tode herbeigeführt (?)

> Europäische Länder, die strengere und längere Lock-downs hatten, hatten höhere COVID-19-Todesraten.

UN-Friedensmissionen schützen die Zivilbevölkerung nicht (?)

> UN-Friedensmissionen in Bürgerkriegsszenarien sind stark positiv mit höheren Todesraten unter Zivilisten korreliert

Automated Inference on Criminality using Face Images

Xiaolin Wu
Shanghai Jiao Tong University
xwu510@gmail.com

Xi Zhang
Shanghai Jiao Tong University
zhangxi_19930818@sjtu.edu.cn

Abstract

We study, for the first time, automated inference on criminality based solely on still face images. Via supervised machine learning, we build four classifiers (logistic regression, KNN, SVM, CNN) using facial images of 1856 real persons controlled for race, gender, age and facial expressions, nearly half of whom were convicted criminals, for discriminating between criminals and non-criminals. All four classifiers perform consistently well and produce evidence for the validity of automated face-induced inference on criminality, despite the historical controversy surrounding the topic. Also, we find some discriminating structural features for predicting criminality, such as lip curvature, eye inner corner distance, and the so-called nose-mouth angle. Above all, the most important discovery of this research is that criminal and non-criminal face images populate two quite distinctive manifolds. The variation among criminal faces is significantly greater than that of the non-criminal faces. The two manifolds consisting of criminal and non-criminal faces appear to be concentric, with the non-criminal manifold lying in the kernel with a smaller span, exhibiting a law of normality for faces of non-criminals. In other words, the faces of general law-biding public have a greater degree of resemblance compared with the faces of criminals, or criminals have a higher degree of dissimilarity in facial appearance than normal people.

people share the belief that the face alone suffices to reveal innate traits of a person. Aristotle in his famous work Prior Analytics asserted, "It is possible to infer character from features, if it is granted that the body and the soul are changed together by the natural affections". Psychologists have known, for as long as a millennium, the human tendency of inferring innate traits and social attributes (e.g., the trustworthiness, dominance) of a person from his/her facial appearance, and a robust consensus of individuals' inferences . These are the facts found through numerous studies [2, 32, 4, 5, 9, 20, 21, 27, 25].

Independent of the validity of pedestrian belief in the (pseudo)science of physiognomy, a tantalizing question naturally arises: what facial features influence average Joe's impulsive and yet consensual judgments on social attributes of a non-acquaintance member of their own specie? Attempting to answer the question, Todorov and Oosterhof proposed a data-driven statistical modeling method to find visual determinants of social attributes by asking human subjects to score four percepts: dominance, attractiveness, trustworthiness, and extroversion, based on first impression of static face images [26]. This method can synthesize a representative (average) face image for a set of input face images scored closely on any of the four aforementioned social percepts. The ranking of these synthesized face images by subjective scores (e.g., from least to most trustworthy looking) apparently agrees with the intuition of most people.

Weitere Evidenz: Erkennen von Straftätern durch Gesichtsdaten

(a) Three samples in criminal ID photo set S_c.

(b) Three samples in non-criminal ID photo set S_n

Figure 1. Sample ID photos in our data set.

Weitere Evidenz: Erkennen von Straftätern durch Gesichtsdaten

Hertie School

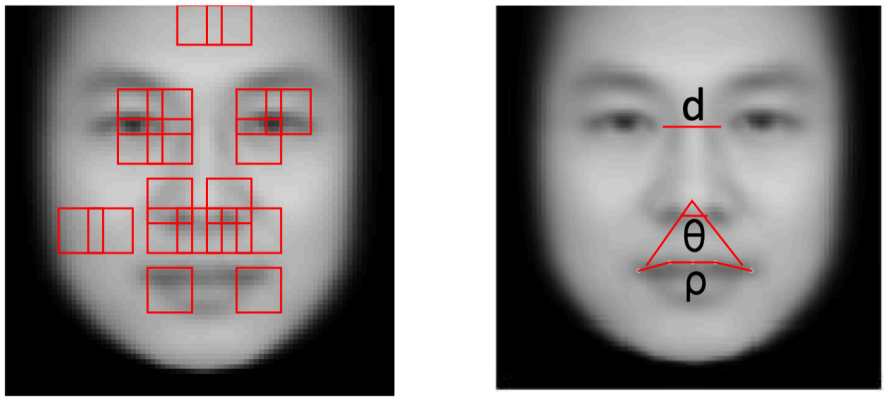

(a) (b)

Figure 4. (a) FGM results; (b) Three discriminative features ρ, d and θ.

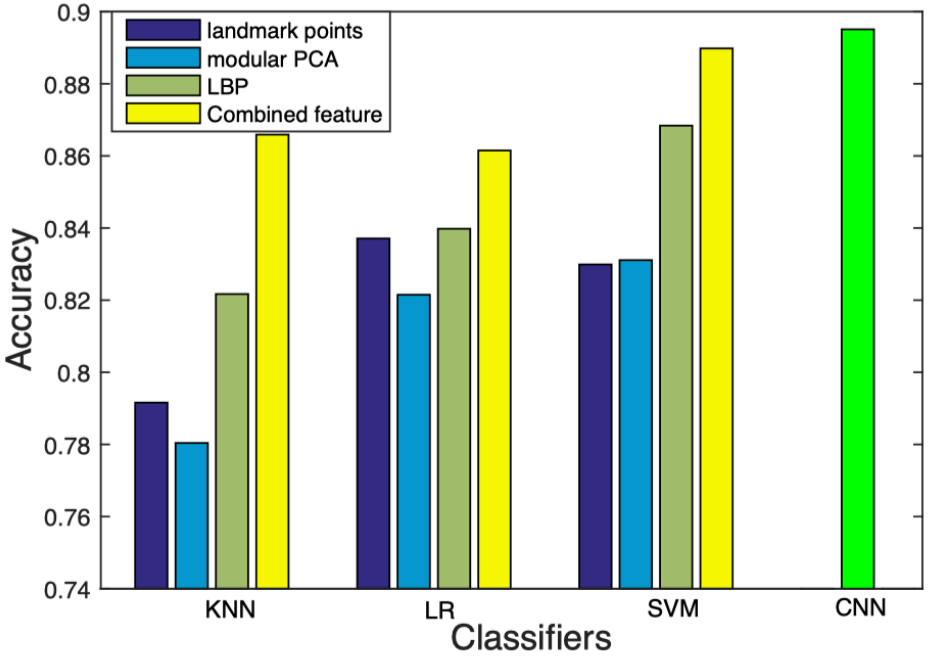

Figure 2. Accuracy of all four classifiers in all thirteen cases.

Lösung des Falles

	Evidenz und Schlüsse
Der Tatort	Gesichter sagen Straftäter vorher
Die Verdächtigen	Lifestyle, Physiognomik
Die Tatwaffe	Konfundierung in Datenerhebung (biased training set)

> "Extraordinary claims require extraordinary evidence. The authors of this paper make the extraordinary claim that facial structure reveals criminal tendencies. We have argued that, given all publicly available information, their findings can be explained by a much more reasonable hypothesis: non-criminals are more likely to be smiling in photos chosen for publicity purposes than are criminals in the ID photos (not mugshots) chosen by police departments for wanted posters and other purposes. Notice that we did all of this without digging into the details of the machine learning algorithms at all. We didn't need to. We know that a machine learning algorithm is only as good as its training data, and we can see that the training set used here is fundamentally flawed for the purpose it is used."
>
> Carl Bergstrom and Jevin West, Calling Bullshit[1]

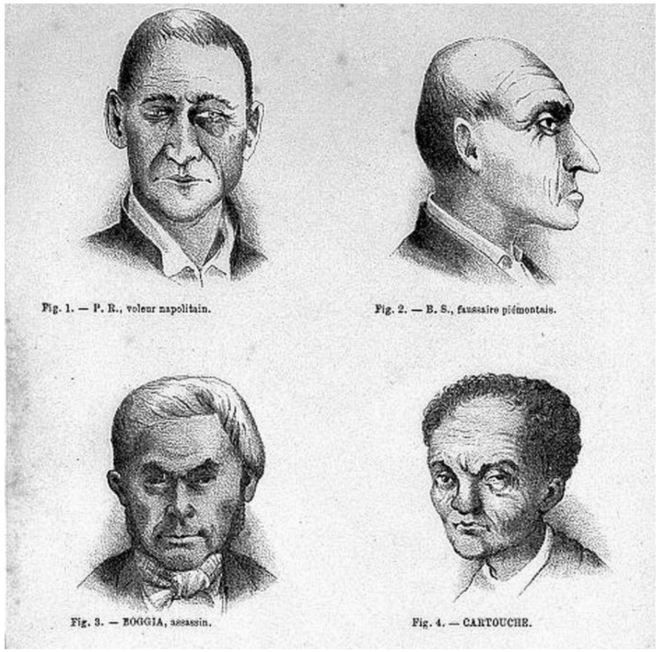

Figure 1. Criminal faces from Cesare Lombroso's 1876 book *L'Homme Criminel*

`Quelle` Bergstrom/West, Calling Bullshit

Data Detective, Fall 2: Predictive Policing

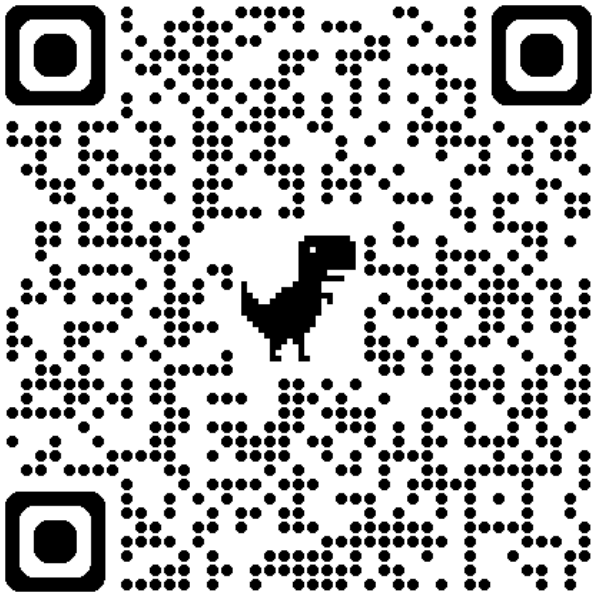

Data Detective, Fall 3: SARS-CoV-2-Abwassermonitoring